RANGKUMAN · MK 4 OPERATIONS & SUPPLY CHAIN MANAGEMENT · MINGGU 7

Antrean (Waiting Line) dan Simulasi

Antrean (waiting line) dan simulasi (Bab 10) sampai agent-based modelling dan generative ABM, dengan kasus KAI Commuter & dilema kapasitas Stasiun Manggarai (serta rujukan Gloria Hospital dan Massachusetts storage initiative). Dibahas: kenapa antrean terbentuk dan trade-off biaya layanan vs biaya menunggu, variabilitas sebagai mesin antrean, lima pilihan struktur sistem antrean, distribusi eksponensial, empat model Jacobs (single-channel, constant service, multichannel, finite population) dan aproksimasi dua momen, contoh Western National Bank, Robot Car Wash, Glenn-Mark, Loose Knit, Little's Law, ledakan antrean di utilisasi tinggi, lini dua tahap Bob & Ray (blocking & starving), kapan rumus gagal, discrete-event simulation, ABM (Schelling, emergence), generative ABM, dan empat pertanyaan diskusi Manggarai.

Materi

1 Tujuan belajar dan peta sesi

1 Memahami apa itu masalah antrean, dan kenapa **biaya menunggu** adalah angka tersulit dalam analisisnya.

2 Membaca sistem antrean sebagai struktur — source population, pola kedatangan, disiplin antrean, konfigurasi layanan, exit.

3 Menerapkan empat model antrean Jacobs dan aproksimasi dua momen untuk menentukan jumlah server dan tingkat layanan.

4 Menjelaskan kapan rumus closed-form gagal, dan apa yang ditambahkan **discrete-event simulation, agent-based modelling, dan generative ABM**.

5 Menerapkan semuanya pada kasus nyata dan membela rekomendasi kapasitas saat ada perbedaan pendapat.

Masalahnya → Strukturnya → Empat model → Simulasi & DES

→ ABM & GABM → Kasus Manggarai

2 Kenapa antrean terbentuk dan tidak bisa sekadar dihapus

- Masalah sentral di jasa adalah mengelola waktu tunggu: manajer menimbang **biaya tambahan layanan yang lebih cepat** terhadap **biaya menunggu**.
- Antrean terbentuk **bahkan saat rata-rata kapasitas melebihi rata-rata permintaan** — karena kedatangan dan waktu layanan acak, bukan karena sistemnya kekecilan.
- Menghapus antrean sepenuhnya berarti membeli kapasitas untuk setiap puncak — kapasitas yang kemudian menganggur sebagian besar hari.
- Jadi keputusannya **ekonomis, bukan teknis**: berapa kapasitas menganggur yang layak dibeli untuk menghapus berapa banyak waktu tunggu.

Biaya layanan
Bisa diamati langsung: teller, jalur, atau mesin tambahan punya gaji, sewa, dan biaya perawatan di anggaran.

Biaya menunggu
Sering tak bisa dihargai. Jacobs bertanya: berapa dolar untuk satu ranjang rumah sakit yang tidak tersedia?

Konsekuensinya
Jika yang menunggu internal — karyawan di mesin fotokopi — itu aritmetika. Jika manusia/pelanggan, masuk penilaian (judgement).

3 Variabilitas adalah mesin antrean

Utilisasi saja tidak memprediksi waktu tunggu. Dua sistem dengan utilisasi sama bisa punya antrean sangat berbeda jika variabilitasnya berbeda.

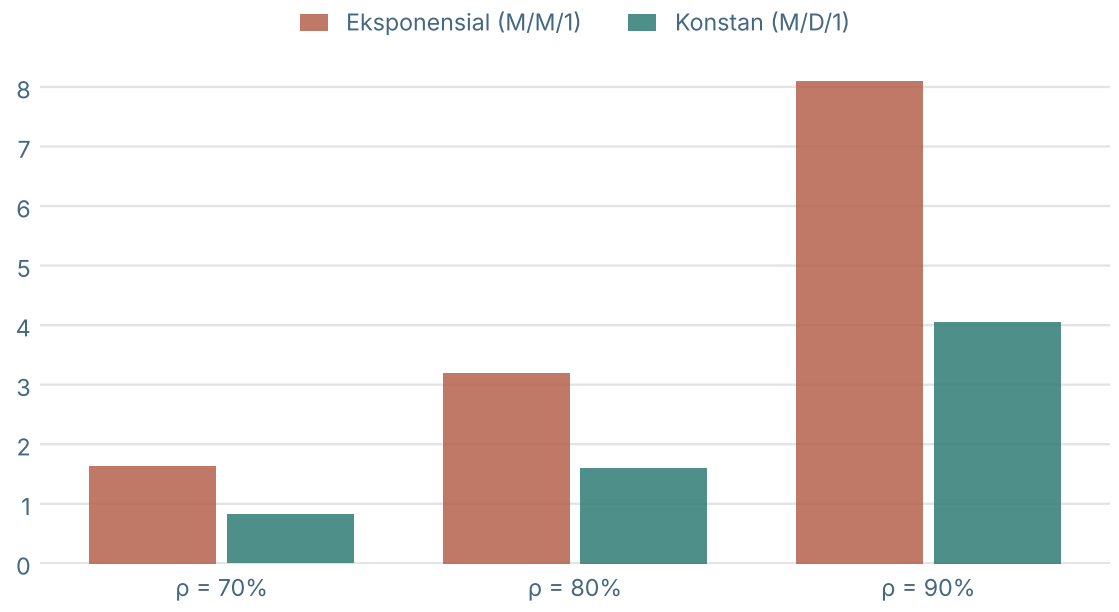
Faktor	Penjelasan
Variabilitas kedatangan	Pelanggan tidak datang pada laju rata-rata. Asumsi standar: kedatangan **Poisson** — acak, independen, tanpa memori.

Variabilitas layanan	Waktu layanan **eksponensial** = kebanyakan pekerjaan pendek, sedikit sangat panjang. Waktu layanan **konstan memotong antrean separuh**.
Utilisasi (ρ)	ρ = λ/μ. Saat ρ mendekati 1, panjang antrean naik **tidak linear — meledak**.
Efek gabungan	Lq sebanding dengan jumlah kuadrat koefisien variasi. Kurangi variabilitas → antrean memendek tanpa menambah kapasitas.

```
Aproksimasi dua momen (Kingman): Wq ≈ [ρ ÷ (1 − ρ)] × [(Ca² + Cs²) ÷ 2] × waktu layanan
```

Ca = koefisien variasi waktu antar-kedatangan; Cs = koefisien variasi waktu layanan (Poisson/eksponensial → C = 1; konstan → C = 0).

Lq: layanan eksponensial vs konstan



> **Ide paling berguna**
> Dua sistem identik yang hanya berbeda distribusi waktu layanan — satu eksponensial, satu konstan — menghasilkan waktu tunggu berbeda **dua kali lipat**. Itu pemotongan antrean "gratis" tanpa server tambahan. Manajer memilih menambah kapasitas karena terlihat; mengurangi variabilitas lebih murah dan biasanya tersedia lebih dulu.

Di grafik konsep Exhibit 10.1, kapasitas digambar datar sementara permintaan naik-turun: setiap batang di atas garis menjadi antrean yang diwarisi periode

berikutnya. Menaikkan kapasitas hanya menggeser garis; meratakan batang sering lebih murah.

4 Anatomi sistem antrean: lima pilihan struktur

Pilihan	Penjelasan	Implikasi
Source population	Terbatas (finite) atau tak terbatas (infinite). Empat mesin tenun = terbatas: setiap kerusakan mengubah laju kedatangan sisanya.	Populasi terbatas → Model 4 dan tabel finite
Arrival pattern	Bisa dikendalikan atau tidak. Poisson sebagai default; janji temu dan promo jam sepi mencoba mengendalikannya.	Poisson kecuali perusahaan aktif menjadwalkan
Queue discipline	First-come-first-served (FCFS) di seluruh Bab 10. Alternatif: prioritas, shortest-job-first.	Semua rumus hari ini mengasumsikan FCFS
Service configuration	Single/multichannel, single/multiphase. Drive-thru = single-channel, multiphase.	**Channel = paralel; phase = berurutan**
Exit	Kembali ke source population, atau peluang rendah untuk kembali.	Hanya penting jika populasinya terbatas

Tiga komponen sistem: (1) source population dan pola kedatangan, (2) sistem layanan, (3) kondisi keluar. **Batas sistem** (garis putus-putus) menentukan apa yang dihitung sebagai waktu tunggu. Pelanggan yang kembali ke source population mengubah laju kedatangan — inilah yang memisahkan Model 1–3 dari Model 4.

Distribusi eksponensial: kebanyakan selang pendek, tetapi ekor kanannya panjang — rata-rata tidak menggambarkan pengalaman pelanggan mana pun. Sifat *memoryless*: berapa lama kamu sudah menunggu tidak mengubah peluang kedatangan berikutnya — asumsi inilah yang memungkinkan rumus closed-form. Asumsi ini patah untuk pasien terjadwal, mesin bersiklus tetap, dan sistem janji temu.

Struktur antrean (Exhibit 10.6): single-channel single-phase, single-channel multiphase, multichannel single-phase, multichannel multiphase, dan campuran (misalnya IGD anak: multi-ke-single channel dengan jalur alternatif untuk kasus P1). Salah memetakan struktur → semua hitungan sesudahnya tidak bermakna, serapi apa pun aritmetikanya.

5 Empat model antrean Jacobs dan rumusnya

Model	Struktur	Populasi	Pola layanan	Contoh
1	Single channel	Tak terbatas	Eksponensial	Drive-thru bank satu teller
2	Single channel	Tak terbatas	**Konstan**	Roller coaster, cuci mobil otomatis
3	Multichannel	Tak terbatas	Eksponensial	Konter suku cadang dengan beberapa petugas
4	Single/multichannel	**Terbatas**	Eksponensial	Mesin rusak yang menunggu teknisi

Cara memilih: mulai dari source population (terbatas → Model 4; rumus infinite akan *salah*, bukan sekadar kurang tepat), lalu pola layanan (konstan → Model 2, antrean separuh). Di luar empat model, **simulasikan** — Jacobs eksplisit: masalah yang lebih rumit umumnya diselesaikan dengan simulasi.

Rumus inti (notasi: λ = laju kedatangan, μ = laju layanan per server, S = jumlah server):

Model	Rumus
1 (M/M/1)	`ρ = λ/μ · Lq = λ² ÷ [μ(μ − λ)] · Ls = λ ÷ (μ − λ) · Wq = Lq/λ · Ws = Ls/λ · Pn = (1 − ρ)ρⁿ · P(n > k) = ρ^(k+1)`
2 (M/D/1)	`Lq = λ² ÷ [2μ(μ − λ)] · Ls = Lq + λ/μ · Wq = Lq/λ`

3 (M/M/S)	`Lq dari tabel (Exhibit 10.9) · Ls = Lq + λ/μ · Wq = Lq/λ · Ws = Wq + 1/μ`
4 (finite)	`X = T ÷ (T + U) (faktor layanan); D dan F dari tabel finite · L = N(1 − F) · H = FNX · J = NF(1 − X) · W = L(T + U) ÷ (N − L)`

(Model 4: N = jumlah sumber, T = waktu layanan, U = waktu antar-kebutuhan layanan, D = peluang harus menunggu, F = faktor efisiensi, L = rata-rata menunggu, H = rata-rata sedang dilayani, J = rata-rata berjalan/produktif.)

```
Little's Law: L = λ × W  (berlaku untuk sistem antrean stabil mana pun)
```

Pakai Little's Law
Rumah sakit jarang mengukur waktu tunggu langsung, tetapi hampir selalu tahu jumlah pasien yang menunggu dan laju kedatangan. Little's Law mengubah dua angka yang mudah didapat menjadi angka ketiga yang sulit diukur. Contoh: rata-rata 30 pasien menunggu, 12 pasien datang per jam → W = 30 ÷ 12 = **2,5 jam**.

6 Contoh 10.1: drive-thru Western National Bank

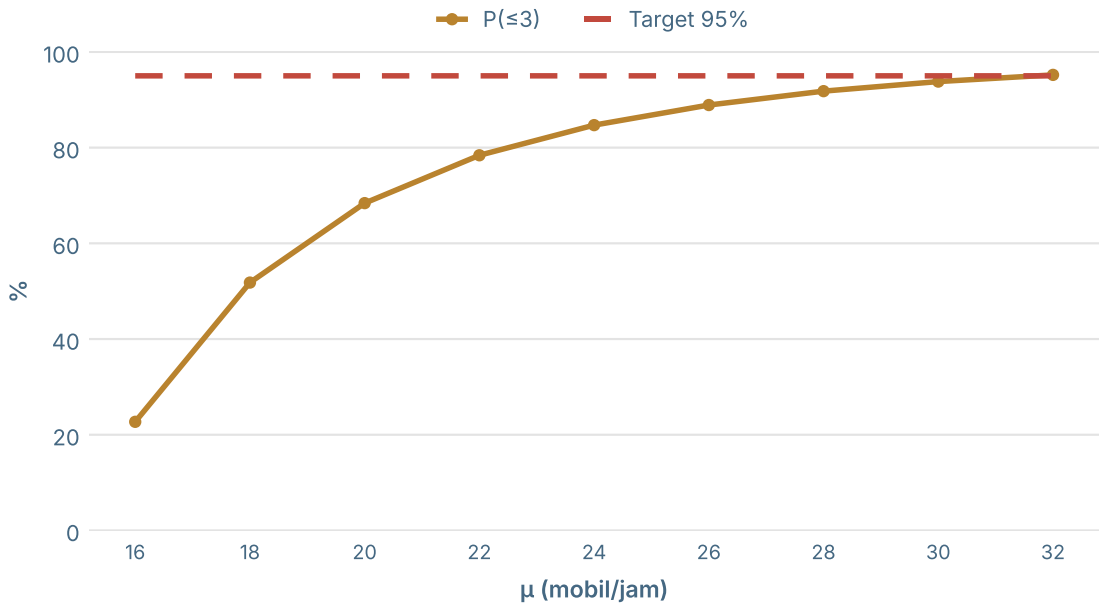
Model 1: satu teller, kedatangan Poisson **λ = 15/jam**, layanan eksponensial **μ = 20/jam**.

1. **Utilisasi**: ρ = 15 ÷ 20 = **75%**
2. **Rata-rata antrean**: $L_q = 15^2 \div [20 \times (20 - 15)] = 225 \div 100 =$ **2,25 mobil**
3. **Rata-rata waktu tunggu**: $W_q = 2{,}25 \div 15 = 0{,}15$ jam = **9 menit**
4. (Tambahan) $L_s = 15 \div 5 = 3$ mobil di sistem; $W_s = 3 \div 15 = 0{,}2$ jam = 12 menit

Pertanyaan tingkat layanan: agar 95% yakin ada **tiga mobil atau kurang**, μ harus naik dari 20 menjadi sekitar **32 per jam**.

$P(n \le 3) = 1 - \rho^4 \rightarrow$ di $\rho = 0{,}75$: $1 - 0{,}316 = 68{,}4\%$ · target 95%: $\rho^4 \le 0{,}05 \rightarrow \rho \le 0{,}473 \rightarrow \mu = 15 \div 0{,}473 \approx 32$

P(≤3 mobil) vs laju layanan μ (λ = 15/jam)



Di utilisasi 75%

Hanya 68,4% waktu ada ≤3 mobil. Hampir sepertiga waktu batasnya terlampaui.

Untuk mencapai 95%

Kemampuan layanan harus naik **60%**. Kapasitas tidak linear terhadap tingkat layanan.

Harga janjinya

Di μ = 32, teller menganggur **53%** waktu. Tingkat layanan dibeli dengan waktu menganggur yang dibayar.

7 Tiga keputusan lain dengan rumus yang sama

#	Keputusan	Model	Inti hasil
1	**Pemilihan peralatan** — Robot Car Wash	Model 2 (layanan konstan)	Unit I memberi waktu tunggu **12,5 menit** padahal toleransi pelanggan 5 menit; Unit II memberi **4 menit** → pilih Unit II.

2	**Jumlah server** — konter Glenn-Mark	Model 3 (multichannel)	Petugas keempat berbiaya **$240/hari** dan menghemat **$342,20** waktu mekanik yang menunggu → tambahkan.
3	**Populasi terbatas** — pabrik Loose Knit	Model 4	Empat mesin, satu teknisi dengan waktu perbaikan 7,5 menit; tabel finite memberi D (peluang menunggu) dan F (efisiensi).
4	**Desain tingkat layanan** — Western National Bank bagian 2	Model 1	Tetapkan tingkat layanan 95%, lalu turunkan laju layanan yang dibutuhkan (μ ≈ 32).

```
Contoh Robot Car Wash (Unit I): λ = 10/jam, layanan konstan 5 menit (μ = 12/jam) → Lq = 10² ÷ [2 × 12 × (12 − 10)] = 100 ÷ 48 = 2,08 → Wq = 2,08 ÷ 10 = 0,208 jam = 12,5 menit
```

Struktur yang sama

Nyatakan menunggu sebagai biaya, nyatakan kapasitas sebagai biaya, cari titik jumlahnya minimum. Perhatikan: di tiga dari empat contoh, yang menunggu adalah **karyawan atau mesin** — justru kasus yang biaya menunggunya bisa diketahui.

8 Kenapa antrean meledak di utilisasi tinggi, dan lini dua tahap Bob & Ray

```
Single channel: Lq = ρ² ÷ (1 − ρ)
```

Utilisasi ρ	Lq
50%	0,50
70%	1,63
85%	4,82 (≈3× dari 70%)
95%	18,05 (>10× dari 70%)

Inti masalahnya

Manajer membaca utilisasi 85% sebagai "masih ada 15% cadangan". Padahal di titik itu antrean sudah beberapa kali lipat dibanding 70%. Itu sebabnya tambahan beban kecil bisa melumpuhkan sistem yang tampak sehat.

Lini dua tahap Bob & Ray (Exhibit 10.12–10.16): blocking dan starving. Output Bob menjadi input Ray, sehingga kedua tahap tidak lagi independen — syarat rumus (Exhibit 10.8) tidak terpenuhi.

Blocking

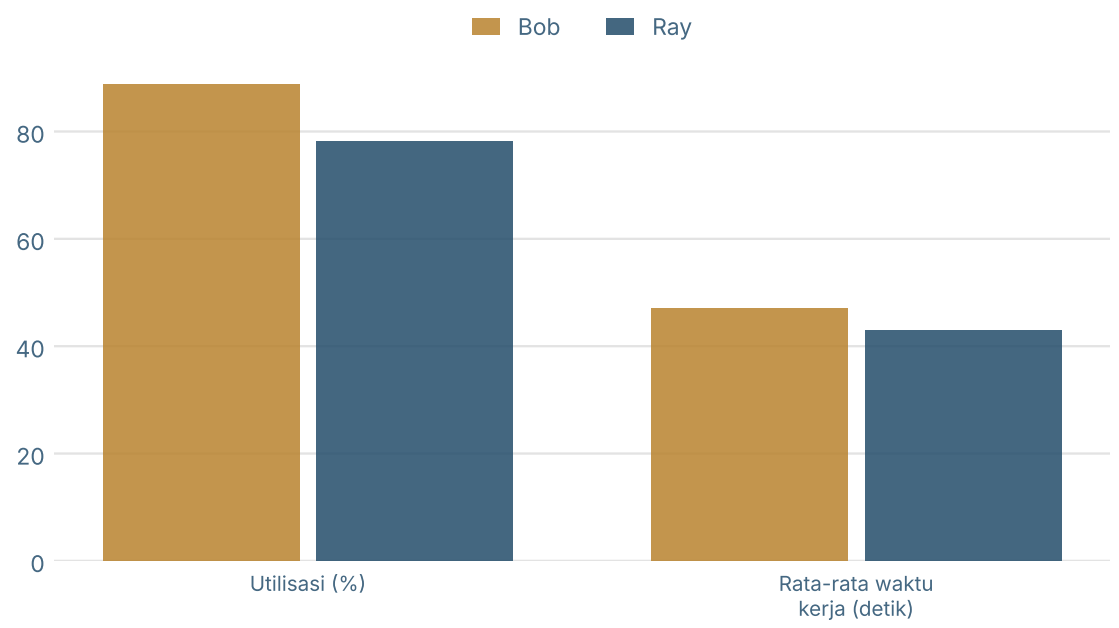
Bob selesai tetapi tidak bisa menyerahkan karena Ray masih sibuk — Bob menunggu Ray.

Starving

Ray menganggur menunggu pekerjaan dari Bob.

Keduanya tidak muncul di model antrean sederhana. Jalan keluarnya: **simulasi** — Exhibit 10.16 menjalankan 30 unit di spreadsheet dan membaca waktu tunggu langsung dari jejak event.

Simulasi Bob & Ray (10 unit)



Output simulasi (10 unit)	Bob	Ray

Utilisasi	470 ÷ 530 = **88,7%**	430 ÷ 550 = **78,2%** (abaikan tunggu awal)
Rata-rata waktu kerja	470 ÷ 10 = **47 detik**	430 ÷ 10 = **43 detik**
Rata-rata waktu output	60 detik per unit	

Satu putaran simulasi: bangkitkan kedatangan/waktu acak → jalankan event satu per satu → catat start, kerja, selesai, tunggu → hitung statistik. Rumus memberi satu rata-rata steady state; simulasi memberi **seluruh distribusi**, termasuk persentil ekstrem dan perilaku sebelum sistem stabil — dua hal yang paling sering ditanyakan di rapat keputusan.

9 Asumsi rumus dan di mana patah

Rumus-rumus ini bersifat **steady state** (proses dianggap berjalan terus). Jacobs menyatakan rumusnya bisa memberi hasil tidak akurat jika laju kedatangan atau layanan berubah sepanjang waktu — yang menggambarkan semua sistem jasa dengan jam makan siang.

Yang diasumsikan model

- Kedatangan Poisson dan independen dari antrean: tidak ada yang melihat antrean lalu pergi.
- Disiplin ketat FCFS, laju konstan selama periode.
- Pelanggan homogen dan pasif: tidak belajar, tidak pindah antrean, tidak beradaptasi.

vs

Yang sebenarnya terjadi

- Pelanggan **balk** (tidak jadi masuk) dan **renege** (keluar dari antrean). Contoh car wash mengakui ini "sangat merumitkan analisis matematis".
- Laju berubah per jam: drive-thru jam 12 dan jam 3 adalah dua sistem berbeda dengan satu set parameter.
- Orang adaptif: **jockeying** (pindah antrean) dan meninggalkan antrean saat tunggu melebihi harapan.

Spektrum pendekatan pemodelan — dari realisme perilaku rendah ke tinggi:

Rumus antrean → Simulasi spreadsheet → Discrete-event simulation → Agent-based modelling → Generative ABM → Agen reinforcement-learning

Keterlacakan turun, realisme naik

Rumus memberi jawaban tepat untuk pertanyaan yang disederhanakan; simulasi memberi jawaban perkiraan untuk pertanyaan realistis.

Validasi makin sulit

Model 1 bisa dicek dengan aljabarnya sendiri. Populasi agen generatif tidak punya "ground truth" seperti itu.

Mulai dari kiri

Geser ke kanan hanya jika terpaksa. Jika Model 3 menjawab pertanyaan staffing, pakai Model 3. Kerumitan adalah biaya, bukan kebajikan.

10 Discrete-event simulation (DES)

Sistem direpresentasikan sebagai **entitas dengan atribut** yang mengubah state pada titik-titik waktu tertentu.

Istilah	Arti
Entity	Objek yang mengalir — pelanggan, mobil, pekerjaan perbaikan
Attribute	Sifat entitas — waktu kedatangan, kebutuhan layanan
Event	Kejadian yang mengubah state sistem — kedatangan, penyelesaian
Resource	Yang diperebutkan entitas — teller, bay, perawat
State	Kondisi sistem saat ini (antrean, server sibuk/menganggur)
Simulation clock	Melompat dari event ke event, bukan per langkah waktu tetap

Ciri khasnya

State hanya berubah di event — jam melompati selang kosong di antaranya. Aplikasi operasi dan supply chain hampir selalu memakai DES, karena momen penting dalam sistem jasa adalah kedatangan, mulai layanan, dan penyelesaian. Tidak ada yang berubah pada antrean di antara dua event.

Yang dibeli simulasi	Menjawab asumsi rumus
Perilaku transien	Rumus hanya steady state; simulasi menunjukkan masa pemanasan, pergantian shift, dan jam sibuk
Aturan perilaku	Balking, reneging, jockeying menjadi aturan yang dikodekan; angka kehilangan penjualan car wash menjadi eksplisit
Topologi rumit	Banyak tahap, kelas prioritas, routing (call center ExtendSim dengan empat jenis panggilan)

Biayanya: jawaban berupa distribusi, bukan satu angka; setiap run butuh replikasi dan membuang masa pemanasan; validasi butuh data nyata, bukan konsistensi internal; asumsi tetap ada, hanya tersembunyi di kode; lebih sulit dibela di depan komite non-teknis; software dan waktu modeling adalah pos anggaran nyata.

Aplikasi DES	Hasil
Restoran & rumah sakit	Bottleneck antrean membuat tunggu duduk lama dan tamu pergi, sementara terburu-buru merusak kunjungan ulang; DES menghitung penyesuaian dari frekuensi kedatangan, waktu proses, jumlah server
Pabrik alat fitness, Yunani	Memodelkan stasiun pemesinan, las, cat selama 2 bulan: lead time terlalu panjang, penjadwalan intuitif, operator kurang terpakai. Rekomendasi memotong lead time **sepertiga** dan waktu tunggu dari **6,8 ke 3,5 hari**
Health technology assessment (Alzheimer, Thailand 2020)	Pasien sebagai entitas dengan atribut demografi dan penyakit unik; mengidentifikasi **donepezil** paling cost-effective — entitas yang tidak bisa dipertukarkan

Sistem sebagai rantai antrean: tiap tahap memberi input ke tahap berikutnya, sehingga proses keberangkatan satu tahap menjadi proses kedatangan tahap

berikut. Kedatangan Poisson di tahap satu tidak tetap Poisson di tahap tiga — independensi yang diasumsikan rumus hilang (contoh alur IGD Anak, SMU869).

11 Agent-based modelling (ABM) dan generative ABM

ABM mensimulasikan sistem kompleks dengan berfokus pada interaksi antar-unit individual (agen). Setiap agen mengikuti aturan dan memutuskan berdasarkan lingkungan, sejarah, dan interaksinya.

Unsur	Arti
Agents	Unit otonom — pelanggan, pengemudi, pedagang, rumah tangga — masing-masing punya state dan sejarah
Rules	Aturan keputusan lokal sederhana (Schelling: tetap tinggal kecuali dikelilingi mayoritas yang berbeda)
Environment	Ruang yang ditempati dan dirasakan agen — grid, jaringan, jalan, tata letak toko
Steps	Mulai dari kondisi awal; di setiap langkah semua agen bereaksi; waktu maju per *tick*, bukan per event
Emergence	Pola tingkat sistem yang tidak diprogram agen mana pun (seperti burung yang membentuk formasi). Output-nya pola, bukan rata-rata

≡ **Hasil pendiri: Schelling (1971)**
Ribuan agen diberi satu aturan: pindah hanya jika menjadi minoritas di lingkungannya. Hasilnya grid yang sepenuhnya tersegregasi — padahal tidak ada agen yang menginginkan segregasi. Informasinya tidak ada di individu, tetapi di **interaksi**. Antrean berperilaku sama: satu pelanggan yang pergi karena antrean panjang memendekkannya untuk semua di belakang, yang mengubah keputusan pendatang berikutnya.

Aspek	DES	ABM
Siapa memutuskan	Entitas pasif: datang, menunggu, dilayani, pergi	Agen memilih antrean mana, dan apakah mau menunggu

Pertanyaannya	Berapa lama tunggu untuk konfigurasi tertentu?	Konfigurasi apa yang muncul dari cara orang berperilaku?
Output	Utilisasi, throughput, rata-rata tunggu	Pola, mungkin yang tidak diantisipasi siapa pun
Umpan balik	Terbatas	Interaksi adalah "warga kelas satu"

Kapan ABM cocok: interaksi rumit antar-agen yang beragam, fenomena emergent, butuh pemodelan dinamis, atau perilaku manusia yang diratakan metode analitis. Aplikasi terdokumentasi: penyebaran COVID-19, optimasi transportasi Singapura, krisis 2008, tata letak toko ritel (masalah antrean terselubung).

Generative ABM (GABM) — lima komponen menggantikan aturan hardcoded:

1. **Profile/State** — siapa agen itu dan posisinya sekarang (persona, peran, situasi).
2. **Memory** — pengalaman agen; observasi lalu diambil untuk keputusan sekarang.
3. **Reasoning module** — konteks dirangkai menjadi prompt untuk large language model.
4. **Interaction interface** — cara agen bertindak dan memersepsi, biasanya dalam bahasa alami.
5. **LLM-generated action** — output yang memperbarui lingkungan dan state agen, kembali ke memori.

```
Agen klasik menjalankan aturan; agen generatif diberi prompt
berisi konteks z pada waktu t, f(z), lalu LLM mengembalikan
tindakan.
```

Kekuatan yang dilaporkan

- Sintesis populasi yang heterogen dan realistis
- Epidemiologi dengan respons perilaku terhadap kebijakan

Alasan berhati-hati

- Tidak ada validasi closed-form
- Output LLM stokastik dan tergantung versi; replikasi sulit
- Biaya per langkah agen jauh lebih mahal dari aturan

- Fenomena sosial yang isi komunikasinya penting
- Simulasi ekonomi digital: negosiasi dan harga

- Bisa mereproduksi stereotip data latih sebagai perilaku

GABM membuat pelanggan simulasi bisa membaca papan, melihat antrean, mengingat tunggu minggu lalu, dan memutuskan tetap tinggal. Tetapi jika pertanyaannya berapa petugas untuk hari Selasa, Model 3 menjawabnya dalam semenit dan lolos rapat. Ini garis depan riset (2023–), belum alat operasi standar; yang hilang: determinisme, auditabilitas, replikasi murah.

12 Kasus Manggarai: antrean di persimpangan terbesar

Persimpangan transit tersibuk di Indonesia, beban tumbuh dua digit per tahun, dan seorang manajer perencanaan operasi (Rangga) dengan tiga minggu untuk membuktikan apa yang sebenarnya membuat antrean panjang.

162.000
Pergerakan penumpang per hari

57,67 jt
Penumpang transit selama 2024

739
Perjalanan kereta per hari

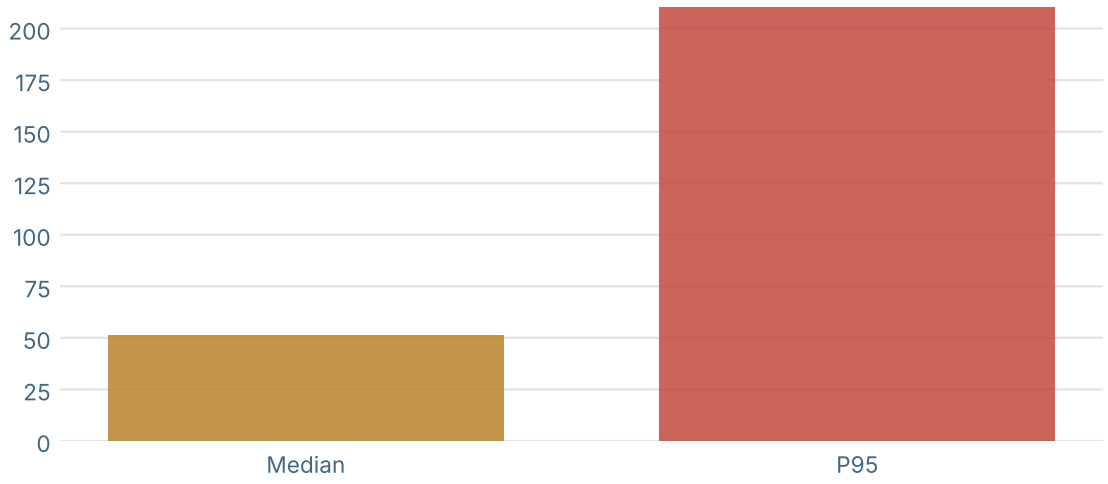
0,84
Utilisasi koridor saat puncak

Empat antrean dalam satu stasiun — Manggarai di jam puncak adalah empat sistem antrean berurutan:

#	Titik	Struktur	Model	Beban
1	Gate tap-in/tap-out	Multichannel, antrean terpisah per gate; layanan nyaris konstan ±2,5 detik	Model 2 murni	Sedang
2	Loket & vending	Multichannel, satu antrean; layanan eksponensial dan sangat bervariasi (ada yang isi saldo, ada yang tanya rute)	Model 3	Rendah

3	Koridor transfer vertikal	Bukan antrean sempit, tetapi kapasitas aliran dua arah; antrean terbentuk hanya saat kedatangan melebihi kapasitas — lalu langsung terbentuk	Masalah kapasitas aliran	Sangat tinggi
4	Menunggu kereta di peron	Layanan *batch* dengan kedatangan layanan terjadwal: seluruh antrean dilayani sekaligus sampai batas kapasitas kereta	Tidak dijangkau keempat model	Titik kritis

Manggarai: median vs P95 waktu tunggu koridor (detik)



Rasio P95/median 4,1. M/M/1 pada ρ = 0,84 memberi rasio ±5,4 — jadi rasio saja belum membuktikan variabilitas berlebih; pola gelombang kedatangan yang membuktikannya.

Empat pertanyaan diskusi (dengan arah jawaban):

1. **Kapasitas atau variabilitas?** Koridor: utilisasi rata-rata 0,84, median Wq 51 detik, P95 Wq 210 detik (4,1× median). *Arah: di M/M/1 dengan ρ = 0,84, Wq = ρ/(1 − ρ) × waktu layanan = 5,25× waktu layanan. Rasio P95/median waktu tunggu (bagi yang menunggu) di M/M/1 sekitar ln 20 ÷ ln 2 ≈ 4,3 — jadi rasio 4,1 saja **belum membuktikan** variabilitas berlebih. Tetapi kedatangan ke koridor bergelombang setelah tiap kereta berhenti → koefisien variasi kedatangan jauh di atas 1. Koridor yang kosong ±60% waktu dan macet ±15% waktu menghasilkan "rata-rata 0,84" yang tidak pernah dialami penumpang mana pun. Bukti sebenarnya ada di perbandingan antar-hari (Exhibit 4).*
2. **Lonjakan 5 Oktober 2024** — lima tindakan KAI Commuter: tambah 4 perjalanan, 49 petugas keamanan, partisi hall, loket portabel, sistem stop-

and-go masuk peron. Klasifikasikan sebagai intervensi pada λ, μ, S, atau persepsi. *Arah: tambah perjalanan = kapasitas batch peron (μ di tahap peron); petugas keamanan = aliran & persepsi; partisi hall = metering λ ke koridor (antrean dipindah ke hall); loket portabel = S; stop-and-go = λ (metering). Kebanyakan bekerja pada λ karena μ dan S berada di luar kendali stasiun — daftar tindakan organisasi adalah peta kendalanya.*

3. **Bangun DES dulu atau rekomendasi sekarang?** Analis termuda ingin simulasi dulu; Budget Planning menolak karena tenggat Gapeka tidak bisa digeser. *Arah: pertanyaan penjadwalan bisa dijawab dengan aritmetika dari 8 minggu data observasi yang sudah ada (tanpa model); pertanyaan investasi modal butuh DES. Bentuk rekomendasi yang menghormati keduanya: keputusan jadwal sekarang + komitmen membangun DES untuk keputusan modal (seperti Massachusetts yang melaporkan dua angka bersama: 1,77 GWh dan 600 MWh). Gloria Hospital punya 7 bulan data yang tak pernah dimodelkan — jangan ulangi.*
4. **Biaya menunggu yang tidak berharga pasar.** Tarif KRL ditetapkan untuk keterjangkauan; penumpang tidak pindah ke pesaing. Bagaimana memasukkan biaya menunggu? *Arah: jika hanya kolom biaya yang berisi angka, perbandingan bias ke opsi termurah. Ketidakmampuan mengatribusikan insiden keselamatan ke tingkat kepadatan tertentu bukan berarti tidak ada hubungan. Seperti Gloria Hospital, pisahkan dua tujuan: tetapkan standar layanan/keselamatan (misalnya batas kepadatan atau P95 tunggu) sebagai **kendala** lebih dulu, baru minimalkan biaya.*

13 Penutup kasus: lima hal yang dibawa pulang

1 **Rata-rata menyembunyikan antrean.** Utilisasi 0,84 terlihat aman padahal tidak. Koridor yang kosong 60% waktu dan macet 15% waktu menghasilkan rata-rata yang tidak pernah dialami siapa pun.

2 **Bukti harus sesuai klaim.** Sebaran P95/median di Exhibit 3 konsisten dengan variabilitas berlebih tetapi tidak membuktikannya. Perbandingan antar-hari di Exhibit 4-lah yang membuktikan.

3 **Kendala menentukan instrumen.** Empat dari lima intervensi bekerja pada λ karena μ dan S di luar kendali stasiun. Baca daftar tindakan sebuah organisasi sebagai peta kendalanya.

4 **Naikkan kerumitan hanya jika terpaksa.** Pertanyaan penjadwalan bisa dijawab dengan aritmetika pada data yang sudah ada. Pertanyaan modal butuh DES. Keduanya bukan pertanyaan yang sama.

5 **Yang tak berharga harus dilindungi.** Tanpa sinyal pasar, standar layanan harus ditetapkan sebagai kendala sebelum perhitungan biaya dimulai — bukan dibiarkan menjadi hasil perhitungan itu.

Poin kunci

1. Antrean terbentuk karena keacakan, bahkan saat kapasitas rata-rata > permintaan; keputusannya ekonomis: biaya layanan vs biaya menunggu (sering tak berharga).
2. Variabilitas adalah mesin antrean; layanan konstan memotong antrean separuh; Kingman: $Wq \approx [\rho/(1-\rho)] \times [(Ca^2 + Cs^2)/2] \times$ waktu layanan.
3. Lima pilihan struktur: source population, arrival pattern, queue discipline, service configuration (channel paralel, phase berurutan), exit.
4. Distribusi eksponensial: memoryless, ekor panjang; patah untuk kedatangan terjadwal.
5. Empat model Jacobs: 1 M/M/1, 2 layanan konstan, 3 multichannel, 4 populasi terbatas; di luar itu simulasi.
6. M/M/1: $\rho = \lambda/\mu$, $Lq = \lambda^2/[\mu(\mu - \lambda)]$, $Wq = Lq/\lambda$; M/D/1: $Lq = \lambda^2/[2\mu(\mu - \lambda)]$; Little's Law $L = \lambda W$.
7. Western National Bank: λ 15, μ 20 → ρ 75%, Lq 2,25, Wq 9 menit; 95% ≤3 mobil butuh $\mu \approx 32$ (teller menganggur 53%).
8. $Lq = \rho^2/(1-\rho)$ meledak: 85% ≈ 3× antrean 70%, 95% > 10×.
9. Bob & Ray: blocking dan starving di lini dua tahap → simulasi (Bob 88,7%, Ray 78,2%).
10. Rumus steady state; patah karena balking, reneging, jockeying, laju berubah; mulai dari model sederhana.
11. DES: entity, attribute, event, resource, state, clock yang melompat; memberi distribusi dan perilaku transien.
12. ABM: agen, aturan, lingkungan, tick, emergence (Schelling); GABM: profile, memory, reasoning LLM, interface, action — riset, hati-hati validasi.

13 Manggarai: empat antrean berurutan; rata-rata 0,84 menyesatkan; kebanyakan intervensi pada λ; standar layanan sebagai kendala.

Studi kasus

Kasus & pembahasan

KAI Commuter & dilema kapasitas Stasiun Manggarai

Data: 162.000 pergerakan penumpang/hari, 57,67 juta penumpang transit 2024, 739 perjalanan/hari, utilisasi koridor transit saat puncak 0,84. Empat antrean seri: (1) gate tap-in/out — multichannel, layanan ~2,5 detik konstan (Model 2); (2) loket & vending — multichannel satu antrean, layanan eksponensial; (3) koridor vertikal — masalah kapasitas aliran dua arah; (4) peron menunggu kereta — *batch service* terjadwal, tidak terjangkau keempat model.

Q1. Kapasitas atau variabilitas? Median Wq 51 detik, P95 210 detik (rasio 4,1). Pada M/M/1, waktu tunggu bersyarat berdistribusi eksponensial: median Wq = $\ln(2\rho)/(\mu-\lambda)$, P95 = $\ln(20\rho)/(\mu-\lambda)$; untuk $\rho = 0{,}84$ rasionya $\ln(16{,}8)/\ln(1{,}68) \approx 2{,}82/0{,}52 \approx$ **5,4**. Jadi rasio 4,1 saja *tidak membuktikan* variabilitas berlebih — sesuai takeaway "bukti harus sesuai klaim". Bukti yang lebih kuat: kedatangan datang bergelombang setiap kereta berhenti (Ca tinggi), dan koridor kosong ~60% waktu tetapi macet ~15% — rata-rata 0,84 adalah angka yang tidak pernah dialami penumpang. Kesimpulan: masalah utamanya **variabilitas (gelombang kedatangan)**, bukan sekadar kurang kapasitas rata-rata; perbandingan antar-hari (Exhibit 4) yang membuktikannya.

Q2. Klasifikasi intervensi 5 Okt 2024: tambah 4 perjalanan → memengaruhi *batch size/frekuensi* peron (secara efektif μ di tahap 4) dan menyebar λ; 49 petugas keamanan → *persepsi* & pengaturan aliran (λ); partisi hall → λ (mengatur kedatangan ke koridor, antrean dipindah ke hall); loket portabel → S (server tambahan di tahap 2); stop-and-go ke peron → λ (metering). Empat dari lima bekerja pada λ karena μ dan S koridor/peron berada di luar kendali stasiun (jadwal Gapeka, infrastruktur). Daftar tindakan organisasi adalah peta kendalanya.

Q3. Simulasi dulu atau rekomendasi sekarang? Keduanya benar untuk pertanyaan berbeda. Pertanyaan *penjadwalan* (pola gelombang, jam puncak, efek metering) bisa dijawab dari 8 minggu data observasi dengan aritmetika & Little's Law. Pertanyaan *investasi modal* struktural butuh DES. Bentuk rekomendasi: tindakan operasional sekarang + komitmen membangun DES untuk keputusan capex dengan tenggat jelas.

Q4. Biaya menunggu yang tak berharga: karena penumpang tidak pindah ke pesaing (permintaan tidak memberi sinyal), biaya menunggu harus dimasukkan sebagai **batas layanan** sebelum perhitungan biaya — misalnya P95 waktu tunggu koridor ≤ X detik dan kepadatan maksimum per m² demi keselamatan — lalu pilih opsi termurah yang memenuhi batas itu. Ketidakmampuan mengatribusi insiden ke tingkat kepadatan tertentu bukan berarti tidak ada hubungan. Pisahkan dua tujuan: keselamatan (constraint) dan efisiensi (objective), seperti kasus Gloria Hospital.

Contoh soal dan pembahasan

Soal 1 · Sedang **Antrean M/M/1**

Kasir: rata-rata 24 pelanggan datang per jam (λ), kasir melayani 30 per jam (μ). Hitung utilisasi, panjang antrean, waktu tunggu, dan waktu total di sistem.

1. $\rho = \lambda \div \mu = 24 \div 30 = 0{,}8$ (80%).
2. $Lq = \lambda^2 \div [\mu(\mu - \lambda)] = 576 \div (30 \times 6) = 3{,}2$ orang
3. $Wq = Lq \div \lambda = 3{,}2 \div 24 = 0{,}133$ jam = 8 menit.
4. $Ws = 1 \div (\mu - \lambda) = 1 \div 6$ jam = 10 menit (8 menit antre + 2 menit dilayani).
5. Peluang kasir kosong $P_o = 1 - \rho = 20\%$.

Jawaban: ρ 80%, Lq 3,2 orang, Wq 8 menit, Ws 10 menit.

Soal 2 Mudah **Little's Law**

Sebuah stasiun dilewati 120 penumpang per jam; tiap penumpang rata-rata berada di stasiun 15 menit. Berapa rata-rata jumlah orang di stasiun?

1. $L = \lambda \times W$
2. Samakan satuan: W = 15 menit = 0,25 jam.
3. L = 120 × 0,25 = 30 orang.

Jawaban: Rata-rata 30 orang di stasiun.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. λ = 15/jam, μ = 20/jam. $L_q = \lambda^2 \div [\mu(\mu-\lambda)]$ = ...

A. 0,75
B. 2,25
C. 3
D. 9

Jawaban: B. 225 ÷ (20 × 5) = 2,25.

2. Little's Law menyatakan...

A. $L = \lambda \times W$
B. $L = \mu - \lambda$
C. $W = \lambda \div \mu$
D. $\rho = \mu \div \lambda$

Jawaban: A. Berlaku untuk sistem stabil apa pun.

3. Pada utilisasi sama, antrean dengan layanan konstan dibanding eksponensial…

A. Sama
B. Dua kali
C. Setengah
D. Nol

Jawaban: C. M/D/1: Lq separuh M/M/1.

---

4. Model yang dipakai bila populasi sumber kecil (4 mesin rusak bergantian)…

A. Model 1
B. Model 2
C. Model 3
D. Model 4 (finite population)

Jawaban: D. Setiap kerusakan mengubah laju kedatangan.

---

5. Pelanggan yang pergi karena antrean panjang disebut…

A. Jockeying
B. Balking/reneging
C. Batching
D. Blocking

Jawaban: B. Balk = tidak jadi masuk; renege = keluar di tengah antrean.

Sumber

- P3MD MK4 OSCM — Meeting 7: Waiting Line and Simulation (slide kelas)
- Jacobs & Chase — OSCM Bab 10 (Exhibit 10.1–10.16); Schelling (1971); Kasus KAI Commuter & Stasiun Manggarai