RANGKUMAN · MK 4 OPERATIONS & SUPPLY CHAIN MANAGEMENT · MINGGU 7

Antrean (Waiting Line) dan Simulasi

Antrean terbentuk bahkan ketika kapasitas rata-rata melebihi permintaan, karena kedatangan dan waktu layanan acak. Dibahas trade-off biaya layanan vs biaya menunggu, variabilitas, lima elemen struktur antrean, empat model Jacobs (single channel, constant service, multichannel, finite population), Little's Law, ledakan antrean di utilisasi tinggi, simulasi diskrit (DES), agent-based modelling, dan generative ABM. Kasus: KAI Commuter dan dilema kapasitas Stasiun Manggarai.

Materi

1 Masalah antrean dan peran variabilitas

Manajer menimbang **biaya layanan lebih cepat** (terlihat: gaji, sewa) vs **biaya menunggu** (sering tidak bisa diberi harga — berapa nilai tempat tidur rumah sakit yang tidak tersedia?). Menghapus antrean sepenuhnya berarti membeli kapasitas untuk setiap puncak yang lalu menganggur sebagian besar hari. Jadi keputusannya ekonomis: berapa kapasitas menganggur yang layak dibeli untuk mengurangi berapa banyak menunggu.

Variabilitas adalah mesin antrean. Dua sistem dengan utilisasi sama bisa punya antrean sangat berbeda bila variabilitasnya berbeda. Kedatangan biasanya Poisson (acak, independen, *memoryless*); waktu layanan eksponensial (kebanyakan pendek, sedikit sangat panjang). Waktu layanan **konstan** memotong antrean menjadi setengah — "gratis" tanpa server tambahan.

```
Aproksimasi dua momen (Kingman): Wq ≈ [ρ ÷ (1 − ρ)] × [(Ca² + Cs²) ÷ 2] × waktu layanan
```

Ca, Cs = koefisien variasi kedatangan dan layanan. Kurangi variabilitas → antrean memendek tanpa menambah kapasitas.

2 Struktur sistem antrean

Elemen	Pilihan
Source population	Terbatas (4 mesin tenun — tiap kerusakan mengubah laju kedatangan) atau tak terbatas
Pola kedatangan	Bisa dikendalikan (janji temu, diskon off-peak) atau tidak; default Poisson
Disiplin antrean	FCFS (diasumsikan semua rumus), prioritas, shortest job first
Konfigurasi layanan	*Channel* = jalur paralel; *phase* = tahap berurutan (drive-thru = single channel, multiphase)
Exit	Kembali ke populasi (penting bila populasi terbatas) atau tidak

Salah memetakan struktur → semua perhitungan berikutnya tidak bermakna, serapi apa pun aritmetikanya.

3 Empat model dan rumusnya

λ = laju kedatangan, μ = laju layanan per server, $\rho = \lambda/\mu$.

Model	Kapan	Rumus kunci
1 — Single channel (M/M/1)	Satu server, layanan eksponensial	$Lq = \lambda^2 \div [\mu(\mu-\lambda)]$; $Ls = \lambda \div (\mu-\lambda)$; $Wq = Lq \div \lambda$; $Ws = 1 \div (\mu-\lambda)$; $Pn = (1-\rho)\rho^n$
2 — Constant service (M/D/1)	Layanan konstan (cucian mobil otomatis, roller coaster)	$Lq = \lambda^2 \div [2\mu(\mu-\lambda)]$ (setengah Model 1)
3 — Multichannel (M/M/S)	Beberapa server paralel	Lq dari tabel/rumus Erlang; $Wq = Lq \div \lambda$
4 — Finite population	Populasi kecil (mesin yang rusak)	Tabel finite queuing (faktor D dan F)

Little's Law (berlaku untuk sistem stabil apa pun):

$$L = \lambda \times W$$

Rumah sakit jarang mengukur waktu tunggu langsung, tapi tahu jumlah pasien menunggu dan laju kedatangan — Little's Law memberi yang ketiga.

Contoh 10.1 Western National Bank (drive-thru): λ = 15/jam, μ = 20/jam → ρ = 75%; Lq = 225 ÷ (20×5) = **2,25 mobil**; Wq = 2,25 ÷ 15 jam = **9 menit**. P(≤3 mobil) = 1 − ρ^4 = 68,4%. Untuk 95% keyakinan ≤3 mobil, $\rho^4 \leq 0{,}05$ → $\rho \leq 0{,}473$ → μ ≈ **32/jam** (naik 60%), dan teller menganggur ~53% waktu. Tingkat layanan dibeli dengan waktu menganggur yang dibayar.

Contoh lain: Robot Car Wash (Model 2) — Unit I menghasilkan tunggu 12,5 menit vs toleransi 5 menit; Unit II 4 menit → pilih Unit II. Glenn-Mark (Model 3) — klerk ke-4 biaya $240/hari menghemat waktu mekanik $342,20 → tambah. Loose Knit (Model 4) — 4 mesin, satu teknisi 7,5 menit.

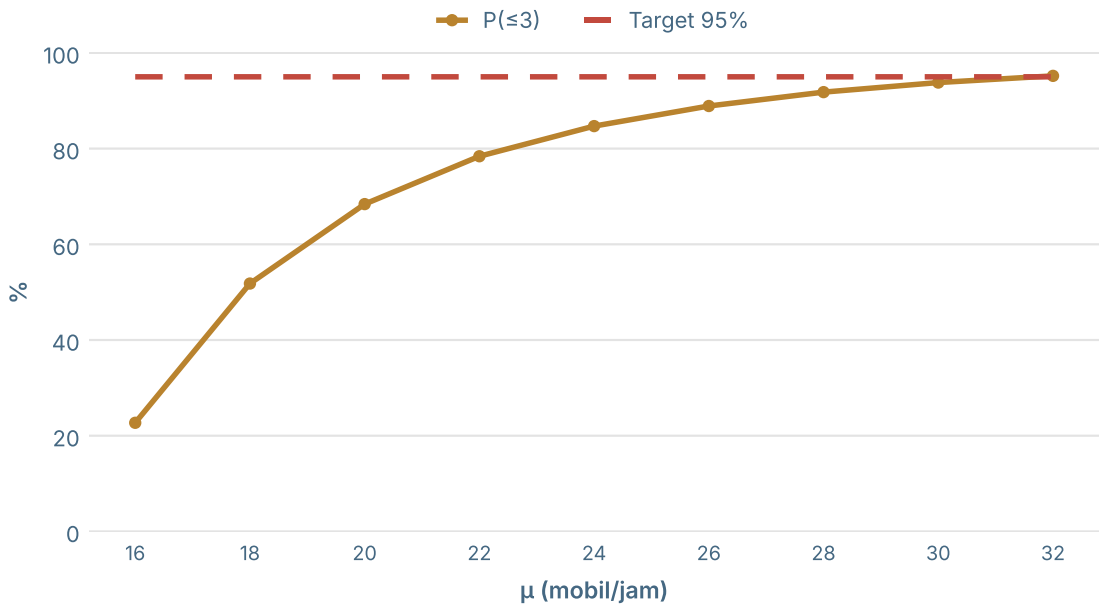
Kenapa antrean meledak: untuk single channel, Lq = $\rho^2 \div (1-\rho)$. ρ=0,70 → 1,63; ρ=0,85 → 4,82; ρ=0,95 → 18,05. Manajer membaca 85% sebagai "masih ada 15% cadangan", padahal antrean sudah ~3x dibanding 70%.

4 Simulator antrean: rasakan sendiri ledakan antrean

Pendalaman

Nilai awal = drive-thru Western National Bank (λ = 15/jam, μ = 20/jam → ρ = 75%, Lq 2,25 mobil, Wq 9 menit). Naikkan λ ke 18 atau 19, lihat waktu tunggu melonjak.

P(≤3 mobil) vs laju layanan μ (λ = 15/jam)



Untuk menjamin 95% waktu ada ≤3 mobil, $\rho^4 \leq 0{,}05 \rightarrow \rho \leq 0{,}473 \rightarrow \mu \approx 32$/jam. Layanan harus 60% lebih cepat, dan teller akan menganggur ±53% waktu. **Tingkat layanan dibeli dengan waktu menganggur.**

5 Saat rumus berhenti bekerja: simulasi

Rumus bersifat *steady-state* dan mengasumsikan kedatangan Poisson independen, FCFS, laju konstan, pelanggan homogen & pasif. Kenyataannya pelanggan **balk** (tidak jadi masuk), **renege** (pergi di tengah antrean), dan **jockey** (pindah jalur); laju berubah per jam.

Antrean dua tahap (Bob & Ray): output Bob menjadi input Ray, sehingga terjadi *blocking* (Bob menunggu Ray) dan *starving* (Ray menganggur menunggu Bob) — tidak tertangkap model sederhana. Simulasi spreadsheet 10 unit: utilisasi Bob 470/530 = 88,7%, Ray 430/550 = 78,2%; rata-rata kerja Bob 47 detik, Ray 43 detik; output ~60 detik per unit.

Discrete-Event Simulation (DES): entity (pelanggan), attribute (waktu datang, kebutuhan layanan), event (kedatangan, selesai), resource (teller, perawat), state, dan simulation clock yang *melompat dari event ke event*. DES memberi seluruh distribusi (termasuk P95) dan perilaku transien (rush hour), bisa memasukkan aturan balking/reneging dan topologi kompleks. Biayanya: hasil

berupa distribusi, perlu replikasi & warm-up, validasi butuh data nyata. Contoh: pabrik alat fitness di Yunani — lead time turun sepertiga, waktu tunggu 6,8 → 3,5 hari.

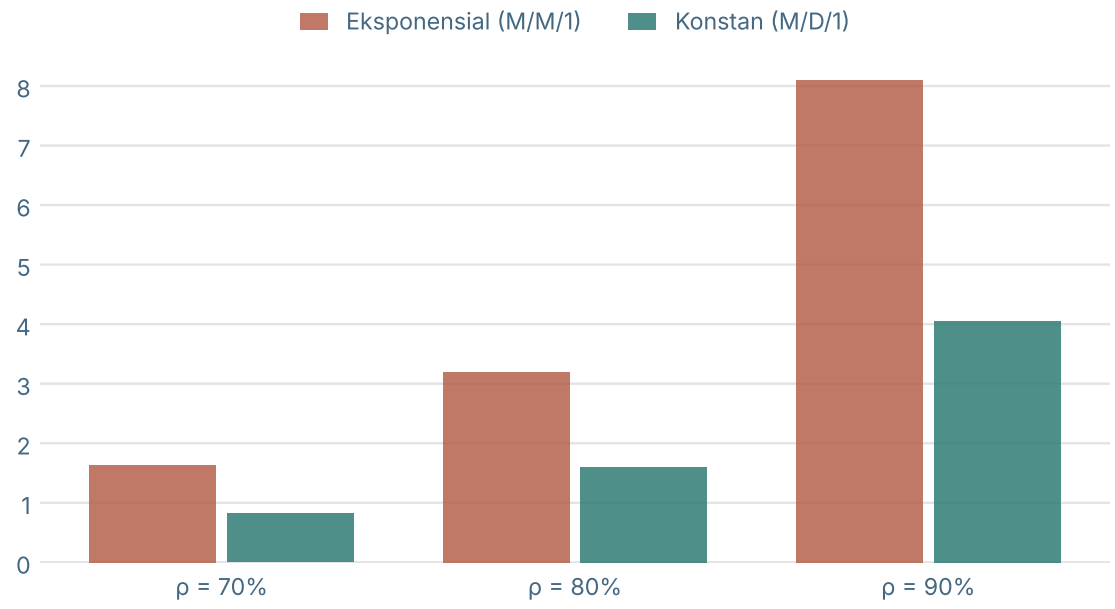
Agent-Based Modelling (ABM): agen otonom dengan aturan lokal; hasilnya pola *emergent* yang tidak diprogram (Schelling 1971: aturan "pindah bila minoritas lokal" menghasilkan segregasi total). DES: entitas pasif, menanyakan "berapa lama tunggunya?"; ABM: agen memutuskan, menanyakan "konfigurasi apa yang muncul dari perilaku orang?".

Generative ABM: aturan diganti LLM — profil, memori, modul penalaran, antarmuka bahasa alami. Realistis tetapi tanpa validasi closed-form, stokastik, mahal, dan bisa mereproduksi stereotip. *Mulai dari kiri (rumus), bergerak ke kanan hanya bila terpaksa.*

6 Variabilitas: layanan konstan memotong antrean separuh

Pendalaman

Lq: layanan eksponensial vs konstan




```
Kingman: Wq ≈ [ρ ÷ (1 − ρ)] × [(Ca² + Cs²) ÷ 2] × waktu layanan
```

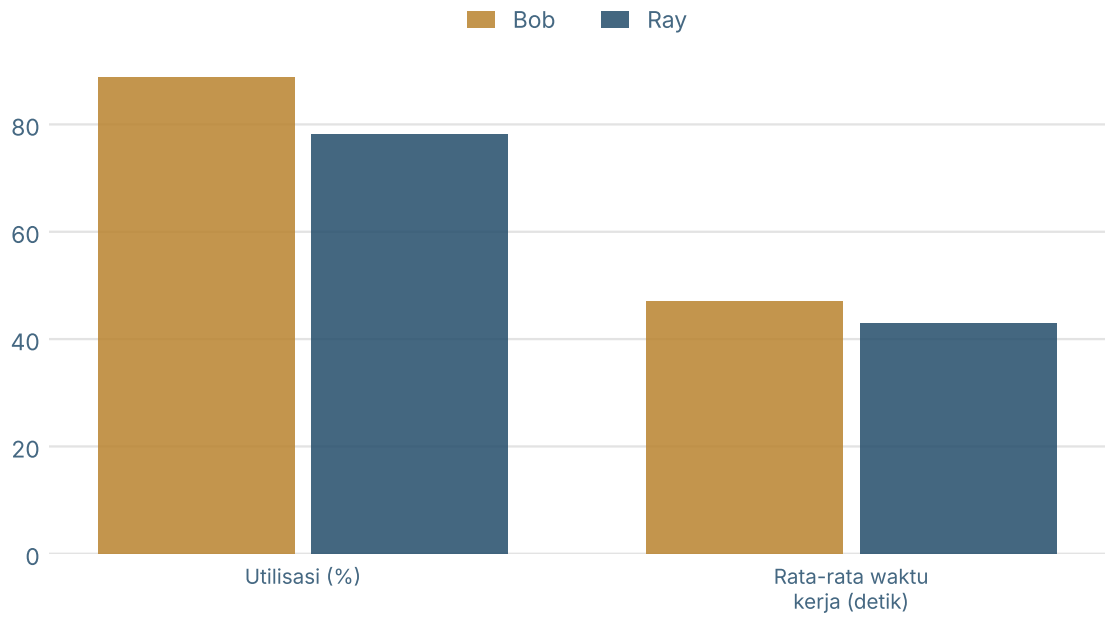
Pada utilisasi yang sama, layanan eksponensial (Cs = 1) menghasilkan antrean dua kali layanan konstan (Cs = 0). Mengurangi variabilitas (standarisasi proses,

jadwal kedatangan) sering lebih murah daripada menambah server.

7 Bob & Ray dan Manggarai: ketika rumus tidak cukup

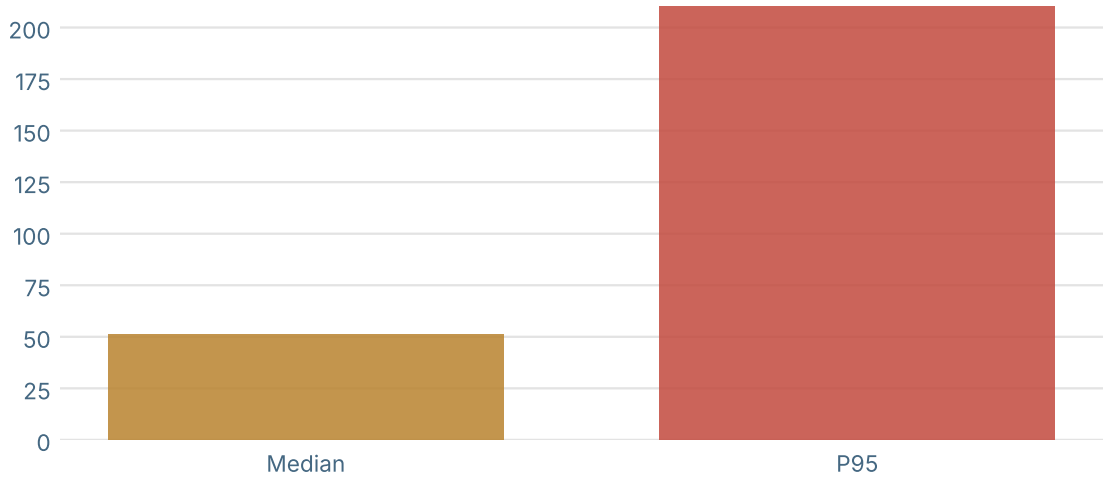
Pendalaman

Simulasi Bob & Ray (10 unit)



Bob lebih sibuk (88,7%) daripada Ray (78,2%), tetapi keduanya saling menunggu: blocking dan starving. Rumus M/M/1 tidak menangkap interaksi ini, sehingga dipakai simulasi.

Manggarai: median vs P95 waktu tunggu koridor (detik)



Rasio P95/median 4,1. M/M/1 pada ρ = 0,84 memberi rasio ±5,4 — jadi rasio saja belum membuktikan variabilitas berlebih; pola gelombang kedatangan yang membuktikannya.

Intervensi 5 Okt 2024	Bekerja pada
Tambah 4 perjalanan kereta	Kapasitas peron/batch (μ di tahap peron), menyebar λ
49 petugas keamanan	Pengaturan aliran & persepsi (λ)
Partisi hall	λ ke koridor (antrean dipindah ke hall)
Loket portabel	S (server tambahan di loket)
Stop-and-go ke peron	λ (metering)

Poin kunci

1. Antrean muncul karena variabilitas, bukan hanya kekurangan kapasitas.
2. Layanan konstan memotong antrean setengahnya.
3. Model 1: $L_q = \lambda^2/[\mu(\mu-\lambda)]$, $W_q = L_q/\lambda$.
4. Little's Law: $L = \lambda W$.
5. L_q naik eksplosif saat $\rho \to 1$ (85% bukan 'aman').
6. Rata-rata menyembunyikan antrean — lihat P95.
7. Naikkan kompleksitas model (DES, ABM, GABM) hanya bila terpaksa.

Studi kasus

Kasus & pembahasan

KAI Commuter & dilema kapasitas Stasiun Manggarai

Data: 162.000 pergerakan penumpang/hari, 57,67 juta penumpang transit 2024, 739 perjalanan/hari, utilisasi koridor transit saat puncak 0,84. Empat antrean seri: (1) gate tap-in/out — multichannel, layanan ~2,5 detik konstan (Model 2); (2) loket & vending — multichannel satu antrean, layanan eksponensial; (3) koridor vertikal — masalah kapasitas aliran dua arah; (4) peron menunggu kereta — *batch service* terjadwal, tidak terjangkau keempat model.

Q1. Kapasitas atau variabilitas? Median Wq 51 detik, P95 210 detik (rasio 4,1). Pada M/M/1, waktu tunggu bersyarat berdistribusi eksponensial: median $W_q = \ln(2\rho)/(\mu-\lambda)$, P95 $= \ln(20\rho)/(\mu-\lambda)$; untuk $\rho = 0{,}84$ rasionya $\ln(16{,}8)/\ln(1{,}68) \approx 2{,}82/0{,}52 \approx$ **5,4**. Jadi rasio 4,1 saja *tidak membuktikan* variabilitas berlebih — sesuai takeaway "bukti harus sesuai klaim". Bukti yang lebih kuat: kedatangan datang bergelombang setiap kereta berhenti (Ca tinggi), dan koridor kosong ~60% waktu tetapi macet ~15% — rata-rata 0,84 adalah angka yang tidak pernah dialami penumpang. Kesimpulan: masalah utamanya **variabilitas (gelombang kedatangan)**, bukan sekadar kurang kapasitas rata-rata; perbandingan antar-hari (Exhibit 4) yang membuktikannya.

Q2. Klasifikasi intervensi 5 Okt 2024: tambah 4 perjalanan → memengaruhi *batch size/frekuensi* peron (secara efektif μ di tahap 4) dan menyebar λ; 49 petugas keamanan → *persepsi* & pengaturan aliran (λ); partisi hall → λ (mengatur kedatangan ke koridor, antrean dipindah ke hall); loket portabel → S (server tambahan di tahap 2); stop-and-go ke peron → λ (metering). Empat dari lima bekerja pada λ karena μ dan S koridor/peron berada di luar kendali stasiun (jadwal Gapeka, infrastruktur). Daftar tindakan organisasi adalah peta kendalanya.

Q3. Simulasi dulu atau rekomendasi sekarang? Keduanya benar untuk pertanyaan berbeda. Pertanyaan *penjadwalan* (pola gelombang, jam puncak, efek metering) bisa dijawab dari 8 minggu data observasi dengan aritmetika & Little's Law. Pertanyaan *investasi modal* struktural butuh DES. Bentuk rekomendasi: tindakan operasional sekarang + komitmen membangun DES untuk keputusan capex dengan tenggat jelas.

Q4. Biaya menunggu yang tak berharga: karena penumpang tidak pindah ke pesaing (permintaan tidak memberi sinyal), biaya menunggu harus dimasukkan sebagai **batas layanan** sebelum perhitungan biaya — misalnya P95 waktu tunggu koridor ≤ X detik dan kepadatan maksimum per m^2 demi keselamatan — lalu pilih opsi termurah yang memenuhi batas itu. Ketidakmampuan mengatribusi insiden ke tingkat kepadatan tertentu bukan berarti tidak ada hubungan. Pisahkan dua tujuan: keselamatan (constraint) dan efisiensi (objective), seperti kasus Gloria Hospital.

Contoh soal dan pembahasan

Soal 1 · Sedang **Antrean M/M/1**

Kasir: rata-rata 24 pelanggan datang per jam (λ), kasir melayani 30 per jam (μ). Hitung utilisasi, panjang antrean, waktu tunggu, dan waktu total di sistem.

1. $\rho = \lambda \div \mu = 24 \div 30 = 0{,}8$ (80%).
2. $Lq = \lambda^2 \div [\mu(\mu - \lambda)] = 576 \div (30 \times 6) = 3{,}2$ orang
3. $Wq = Lq \div \lambda = 3{,}2 \div 24 = 0{,}133$ jam = 8 menit.
4. $Ws = 1 \div (\mu - \lambda) = 1 \div 6$ jam = 10 menit (8 menit antre + 2 menit dilayani).
5. Peluang kasir kosong $P_o = 1 - \rho = 20\%$.

Jawaban: ρ 80%, Lq 3,2 orang, Wq 8 menit, Ws 10 menit.

Soal 2 Mudah **Little's Law**

Sebuah stasiun dilewati 120 penumpang per jam; tiap penumpang rata-rata berada di stasiun 15 menit. Berapa rata-rata jumlah orang di stasiun?

1. $L = \lambda \times W$
2. Samakan satuan: W = 15 menit = 0,25 jam.
3. L = 120 × 0,25 = 30 orang.

Jawaban: Rata-rata 30 orang di stasiun.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. λ = 15/jam, μ = 20/jam. $L_q = \lambda^2 \div [\mu(\mu-\lambda)]$ = ...

A. 0,75
B. 2,25
C. 3
D. 9

Jawaban: B. 225 ÷ (20 × 5) = 2,25.

2. Little's Law menyatakan...

A. $L = \lambda \times W$
B. $L = \mu - \lambda$
C. $W = \lambda \div \mu$
D. $\rho = \mu \div \lambda$

Jawaban: A. Berlaku untuk sistem stabil apa pun.

3. Pada utilisasi sama, antrean dengan layanan konstan dibanding eksponensial...

A. Sama
B. Dua kali
C. Setengah
D. Nol

Jawaban: C. M/D/1: Lq separuh M/M/1.

---

4. Model yang dipakai bila populasi sumber kecil (4 mesin rusak bergantian)...

A. Model 1
B. Model 2
C. Model 3
D. Model 4 (finite population)

Jawaban: D. Setiap kerusakan mengubah laju kedatangan.

---

5. Pelanggan yang pergi karena antrean panjang disebut...

A. Jockeying
B. Balking/reneging
C. Batching
D. Blocking

Jawaban: B. Balk = tidak jadi masuk; renege = keluar di tengah antrean.

Sumber

- [STS] Meeting 7 - Waiting Line and Simulation (MK4)
- Jacobs & Chase, Bab 10
- KAI Commuter & Manggarai case
- Schelling (1971), Dynamic Models of Segregation