RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 2

How to Deal with Data

Sebelum menganalisis, pahami data: satu baris itu tentang apa (grain), apa kuncinya, jenis data (terstruktur sampai tidak terstruktur), metadata dan kamus data, skala data (nominal–rasio) dan apa yang boleh dihitung, bentuk kolom (rata-rata vs median, sebaran, nol), delapan cacat data, dan di mana harus diperbaiki (capture, definition, pipeline).

Materi

1 Satu baris, satu hal

"Berapa orang tinggal di rumahmu?" — anak yang kuliah di luar kota, ART yang menginap, ibu yang tinggal 4 bulan setahun → empat orang bisa memberi empat jawaban. Di kantor: marketing 840.000 pelanggan aktif, finance 610.000, operasi 1.200.000. **Tidak ada yang salah hitung — tiga definisi "aktif", tidak ada yang tertulis.**

Grain: sebelum membaca angka, tanyakan "satu baris ini apa?". Tabel order (SO-4471, SO-4472, SO-4473) berisi 5 baris = 3 order = 2 hari = 1 atau 3 pelanggan. Penjualan yang sama bisa dihitung empat cara: per order line (41.800 baris — produk apa dibeli bersama), per order (18.400 — ukuran order tipikal), per pengiriman (22.100 — kesibukan armada), per pelanggan (3.150 — siapa pembeli kita). Bagi dengan baris yang salah → rata-rata yang tidak ditanyakan siapa pun.

Key = kolom (atau gabungan kolom) yang membuat tiap baris unik (di contoh: nomor order + item). Tanpa key, hal yang sama bisa tercatat dua kali tanpa ketahuan. Satu tabel jarang cukup: pelanggan, order, dan produk dihubungkan lewat nomor pelanggan dan kode item.

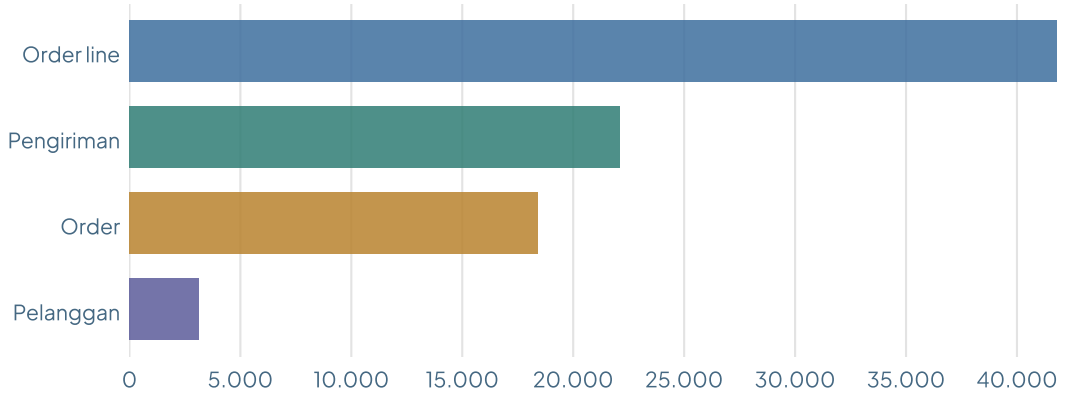
Jenis data: terstruktur (baris & kolom: penjualan, gaji), semi-terstruktur (form keluhan: tanggal, cabang + paragraf bebas), tidak terstruktur (rekaman

telepon, foto lokasi, kontrak). Sebagian besar data organisasi tidak berbentuk baris-kolom.

2 Satu penjualan, empat jumlah baris

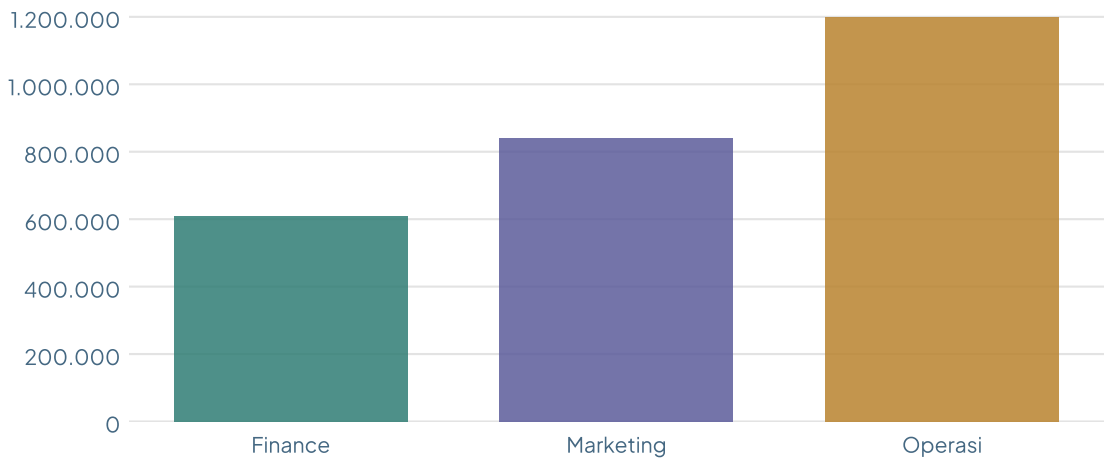
Pendalaman

Penjualan yang sama, dihitung per…



Jika total penjualan Rp9,2 M dibagi 41.800 baris, kamu mendapat "rata-rata per item" (±Rp220 rb). Dibagi 3.150 pelanggan, kamu mendapat "rata-rata per pelanggan" (±Rp2,9 jt). Keduanya benar — tetapi menjawab pertanyaan yang berbeda. *(Total Rp9,2 M di sini ilustratif.)*

'Pelanggan aktif' menurut tiga divisi



Tidak ada yang salah hitung — tiga definisi yang tidak tertulis.

3 Metadata dan kamus data

Angka "1.240" di mejamu belum bisa dipakai: zak, ton, atau rupiah? Satu depot atau nasional? Minggu, bulan, atau tahun? Dihitung kapan, sistem apa? **Metadata mengubah angka menjadi fakta.** Contoh lengkap: zak semen 40 kg yang dikirim, depot Bandung, 1–7 November 2023, sistem despatch tabel dispatch_line, diekstrak 8 Nov 06.00, pemilik Kepala Logistik.

Enam hal yang dibutuhkan setiap kolom: nama (sama di setiap laporan), makna (satu kalimat yang bisa dipahami karyawan baru), unit, sumber (sistem & field), refresh (seberapa sering & seberapa tua), pemilik (siapa yang ditanya bila janggal).

Definisi harus tinggal di **kamus data yang dirujuk laporan** — bukan di kepala analis atau catatan kaki satu slide. Metadata yang sudah otomatis ada: timestamp, siapa yang mengubah, asal data, versi ekstrak. *Laporan tanpa metadata tidak bisa dicek, jadi harus dipercaya begitu saja.*

4 Skala data dan apa yang boleh dihitung

Tipe	Contoh	Urutan?	Jarak sama?	Boleh dihitung
Nominal	Kode cabang, jenis produk	Tidak	Tidak	Frekuensi, modus
Ordinal	Kepuasan 1–5	Ya	Tidak	Median, persentase "baik ke atas"
Interval	Suhu, tahun kalender	Ya	Ya, tanpa nol sejati	Selisih, rata-rata
Rasio	Ton, rupiah, hari	Ya	Ya, ada nol sejati	Semua, termasuk rasio

Jebakan: rata-rata nomor cabang 3, 7, 12 = 7,3 (tidak ada cabang 7,3). Rata-rata kepuasan 3,7 dari 5 bermasalah karena jarak "buruk→cukup" belum tentu sama dengan "baik→sangat baik" — lebih aman laporkan *% yang menjawab baik atau*

lebih. On-time naik 80% → 84% = naik **4 poin persentase**, atau naik **5 persen** (4/80) — keduanya benar, pastikan yang dimaksud.

Tanggal: bukan teks (06/11/2023 = 6 Nov di Jakarta, 11 Juni di New York), bukan angka (boleh dikurangi, tidak boleh dijumlah), punya zona waktu (23.40 di Makassar = hari sebelumnya di Jakarta), dan datang berpasangan (kapan terjadi vs kapan diinput).

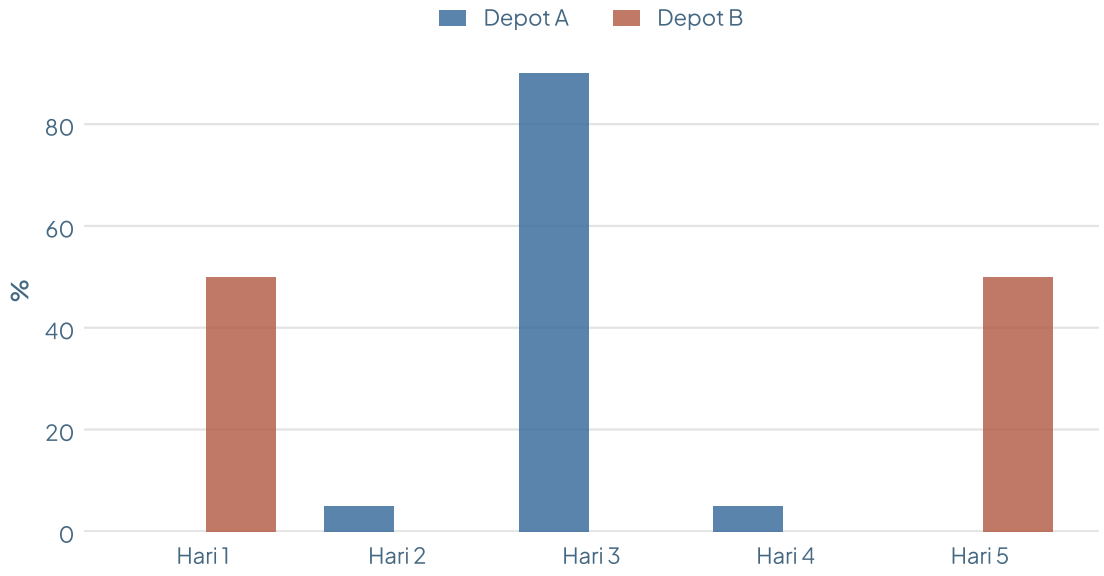
Dicatat atau dihitung? Kuantitas & harga satuan dicatat; nilai baris (qty × harga) dan margin dihitung. *Kolom terhitung bukan bukti — ia pendapat tentang dua kolom lain.*

5 Bentuk kolom

- **Rata-rata vs median:** order rata-rata 340 zak, median 120 zak — beberapa order sangat besar menarik rata-rata ke atas; 9 dari 10 order lebih kecil dari rata-rata. Bila data miring, rata-rata menggambarkan hampir tidak ada orang.
- **Sebaran:** depot A dan B sama-sama rata-rata 3 hari; di A hampir semua tiba hari ke-3, di B setengah hari ke-1 dan setengah hari ke-5 — tidak ada yang mengalami 3 hari. *Rata-rata tanpa sebaran adalah setengah angka.*
- **Selalu minta:** median, rentang (8 dari 10 baris di antara berapa?), jumlah data (n), dan satu gambar bentuk kolom.
- **Kolom yang mayoritas nol:** rata-rata belanja marketing per cabang Rp14 juta, padahal 30 dari 40 cabang tidak belanja sama sekali; 10 yang belanja rata-rata Rp56 juta. Hitung nol sebelum membagi.

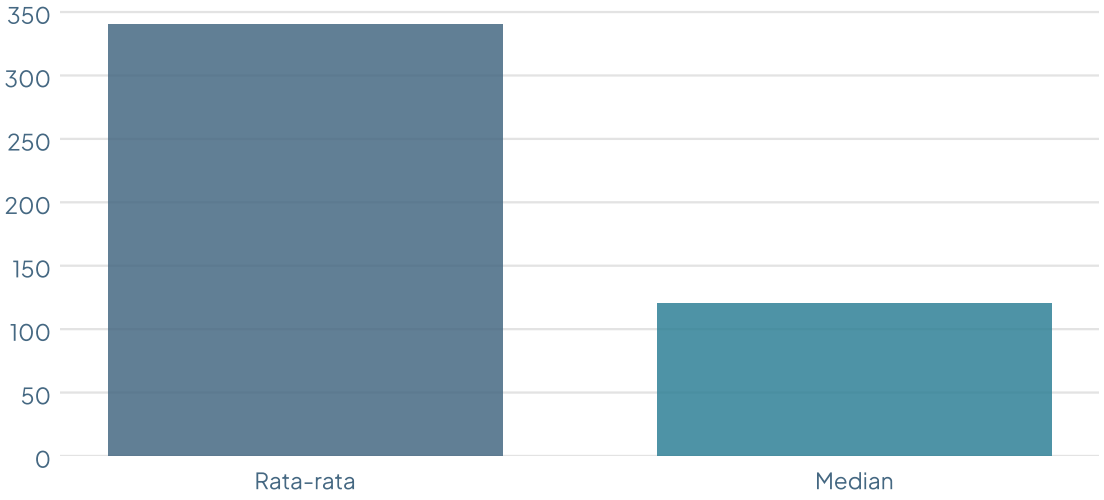
6 Bentuk kolom: rata-rata bisa menipu Pendalaman

Distribusi waktu kirim: rata-rata sama (3 hari)



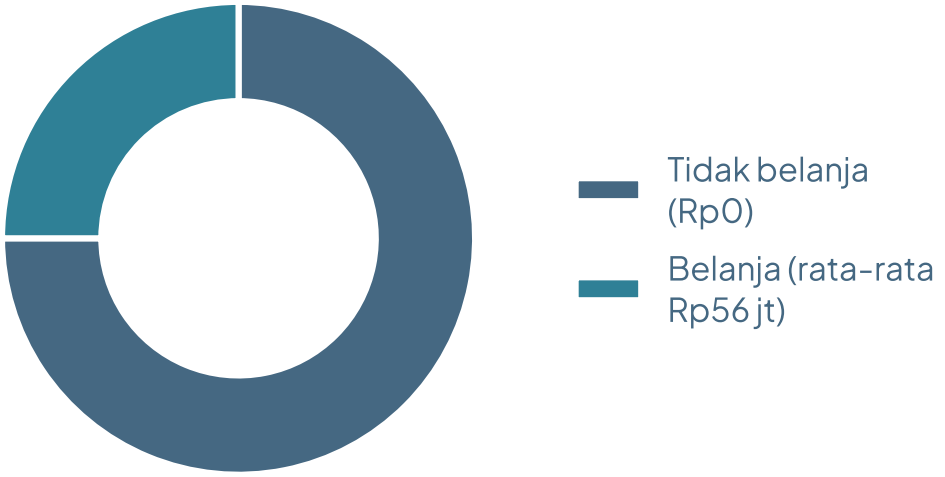
Depot A dan B sama-sama rata-rata 3 hari. Di A hampir semua kiriman tiba di hari ke-3. Di B separuh tiba hari ke-1, separuh hari ke-5 — **tidak ada satu pun pelanggan B yang mengalami "3 hari"**.

Ukuran order: rata-rata vs median (zak)



9 dari 10 order lebih kecil dari rata-rata.

40 cabang dan belanja marketing



30 dari 40 cabang tidak belanja marketing sama sekali. "Rata-rata Rp14 juta per cabang" menyembunyikan dua kelompok: 30 cabang dengan Rp0 dan 10 cabang dengan rata-rata Rp56 juta. Hitung nol sebelum membagi.

7 Delapan cacat data dan siapa yang memperbaiki

Cacat	Contoh	Langkah pertama	Perbaiki di
Missing	1 dari 10 baris tanpa nomor pelanggan — itu penjualan tunai	Tanya kenapa kosong (menghapusnya = menghapus pelanggan terkecil)	Capture
Duplicate	CV Karya Baja / CV. Karya Baja / KARYA BAJA CV	Cari key yang tidak berubah (NPWP)	Capture
Inconsistent	Bandung / Bdg / BANDUNG; status 1, open, closed	Daftar pilihan tetap	Capture

Wrong unit	Pabrik 1.240 ton; depot 31.000 zak; finance 1.562 (juta)	Unit di nama kolom (value_idr_thousand)	Definition
Stale	Pengiriman kemarin dicampur daftar cabang tahun lalu	Cetak umur tiap sumber di laporan	Pipeline
Wrong grain	Cabang + total Jawa Barat dalam satu kolom → dihitung dua kali	Satu grain per tabel	Definition
Outlier	Satu order 40x lainnya	Baca record-nya dulu; jangan hapus karena merusak rata-rata	— (tidak selalu salah)
Undefined	"Pelanggan aktif", "on-time", "revenue"	Sepakati satu makna dan tulis	Definition (kerja manajemen)

Tiga tempat memperbaiki: *Capture* (ubah form/aturan agar nilai buruk tidak bisa masuk — termurah, memperbaiki semua baris mendatang; pemilik: manajer proses), *Definition* (sepakati makna — gratis ditulis, mahal disepakati; pemilik: yang memimpin rapat), *Pipeline* (bersihkan dalam perjalanan ke laporan — tim data; tidak pernah selesai). **Membersihkan di hilir adalah perbaikan, bukan menghentikan kebocoran.**

Saat meminta data: sebutkan keputusannya, satu baris = apa, periode, kolom & maknanya, definisi kata yang ambigu. **Tanyakan balik:** seberapa tua ekstraknya, berapa baris dibuang, dari sistem mana, siapa yang dihubungi bila janggal.

8 Tiga tempat memperbaiki: biaya vs cakupan Pendalaman

↕ Baris atas: memperbaiki semua data mendatang · bawah: hanya data yang sudah ada

Capture
Ubah form/aturan input. Pemilik: manajer proses. Sekali benar, semua

Definition
Gratis ditulis, mahal disepakati (rapat lintas divisi).

baris berikutnya benar.

—
Kombinasi jarang terjadi.

Pipeline
Tim data membersihkan di hilir — tidak pernah selesai.

↔ Kolom kiri: murah per perbaikan · kanan: mahal per perbaikan

Poin kunci

1. Tanya dulu: satu baris = apa?
2. Key membuat baris unik.
3. Metadata: nama, makna, unit, sumber, refresh, pemilik.
4. Skala menentukan operasi yang boleh.
5. Rata-rata tanpa sebaran = setengah angka; cek median & nol.
6. 8 cacat data; perbaiki di capture bila bisa.

Studi kasus

Kasus & pembahasan

Menghubungkan: BetonPrima dan 'Rp14 juta per cabang'

BetonPrima (minggu 1) adalah contoh cacat *undefined/inconsistent di titik capture*: alasan churn dipaksa ke satu pilihan drop-down sehingga "terlambat saat hujan" tercatat sebagai "harga". Perbaikan yang benar ada di **capture** (form multi-alasan + kolom komentar wajib), bukan sekadar membersihkan di pipeline.

Latihan: laporan bilang "rata-rata waktu kirim 3,1 hari, aman". Pertanyaan yang harus kamu ajukan: satu baris = pengiriman atau order? Median dan P90–nya berapa? Berapa yang kosong tanggal terimanya? Definisi "tiba" = sopir sampai atau kontraktor tanda tangan? Data diekstrak kapan?

Contoh soal dan pembahasan

Soal 1 · Mudah **Poin persentase vs persen**

Conversion rate naik dari 2,0% menjadi 2,5%. Tulis kenaikannya dengan dua cara.

1. Selisih langsung: 2,5 – 2,0 = **0,5 poin persentase**.
2. Kenaikan relatif: 0,5 ÷ 2,0 = **25%**.

Jawaban: Naik 0,5 poin persentase, atau naik 25%. Keduanya benar — sebutkan yang dimaksud.

Soal 2 · Mudah **Rata-rata vs median, dan kolom bernilai nol**

(a) Tujuh order (zak): 5, 6, 7, 8, 9, 10, 120. Hitung rata-rata dan median. (b) 50 toko, 35 tidak belanja iklan sama sekali, total belanja Rp600 juta. Hitung rata-rata semua toko dan rata-rata toko yang belanja.

1. (a) Total = 165 → rata-rata 165 ÷ 7 = 23,6. Median (nilai tengah ke-4) = 8.
2. Satu order 120 menarik rata-rata hingga tiga kali median; 6 dari 7 order di bawah rata-rata.
3. (b) Rata-rata semua = 600 ÷ 50 = 12 juta.
4. Yang belanja hanya 15 toko → 600 ÷ 15 = 40 juta.

Jawaban: (a) Rata-rata 23,6 vs median 8 → laporkan median. (b) Rp12 juta (semua) vs Rp40 juta (yang belanja) — hitung nol dulu sebelum membagi.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. Pertanyaan pertama sebelum membaca angka di tabel…

A. Berapa totalnya?
B. Satu baris ini apa? (grain)
C. Siapa pembuatnya?
D. Warna apa?

Jawaban: B. Grain menentukan apa arti rata-rata.

---

2. Kepuasan 1–5 adalah skala…

A. Nominal
B. Ordinal
C. Interval
D. Rasio

Jawaban: B. Urutan ada, jarak tidak pasti sama.

---

3. On-time naik 80% → 84%. Pernyataan yang benar…

A. Naik 4 poin persentase atau naik 5%
B. Naik 4% saja
C. Naik 84%
D. Naik 20%

Jawaban: A. 4 ÷ 80 = 5%.

---

4. CV Karya Baja / CV. Karya Baja / KARYA BAJA CV adalah cacat…

A. Missing
B. Duplicate
C. Stale
D. Outlier

Jawaban: B. Cari key yang tidak berubah (NPWP).

---

5. Tempat memperbaiki data yang paling murah dan berlaku untuk semua baris mendatang…

A. Pipeline
B. Capture
C. Dashboard
D. Model

Jawaban: B. Cegah nilai buruk masuk.

Sumber

- Materi Lengkap P3MD — How to Deal with Data (MK6)