RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 4

Predictive Analytics

Prediksi = memakai masa lalu untuk menebak yang belum terjadi — tidak memberi tahu hal baru, tapi memberi tahu lebih cepat. Tiga jenis: klasifikasi, regresi, time series. Model harus mengalahkan 'sama seperti tahun lalu'. Contoh Titanic (aturan, decision tree, Naive Bayes, KNN, neural net; confusion matrix; train/test; cross-validation) dan California housing (regresi, MAE/RMSE/MAPE/R^2), lalu jebakan: leakage, overfitting, imbalance, outlier, concept drift, kalender, self-fulfilling, Simpson, selection bias, model decay.

Materi

1 Apa itu prediksi dan jenisnya

Pelanggan telat bayar Jan, tepat Feb, telat Mar & Apr → peluang telat Mei = 3/4 (berapa kali terjadi ÷ berapa kali bisa terjadi). Gaji 4,0 → 4,6 → 5,2 → 5,8 → tahun ke-5 ≈ 6,4. Dengan tiga kolom (tahun, pendidikan, rating) polanya tetap ada tapi tak terlihat mata — menemukannya adalah tugas mesin.

Jenis	Pertanyaan	Contoh
Klasifikasi	Baris ini masuk kelompok mana?	Apakah pelanggan akan menutup akun? Masuk segmen mana dari 4?
Regresi	Angka berapa untuk baris ini?	Berapa belanja pelanggan tahun ini?
Time series	Apa berikutnya dalam deret ini?	Berapa unit terjual Maret?

Cara membedakan: jawabannya kategori? → klasifikasi. Angka yang datang berurutan waktu? → time series. Selain itu → regresi. "Pelanggan mana yang mirip?" bukan prediksi (tidak ada kolom jawaban → clustering).

Kenapa memprediksi: kamu selalu akhirnya tahu — prediksi membuatmu tahu lebih cepat. Contoh: operator telko BUMN dengan 10.000 pelanggan bisnis

dan anggaran 500 tawaran retensi/bulan; tanpa model dipilih acak, dengan model diberikan ke 500 yang paling mungkin pergi.

Forecast termurah: bulan depan = bulan ini; Desember depan = Desember lalu. Gratis. *Model yang tidak bisa mengalahkan "sama seperti tahun lalu" bukan model — itu biaya.*

2 Klasifikasi, regresi, atau time series? Pohon keputusan cepat

Pendalaman

1. **Ada kolom jawaban?** Tidak → bukan prediksi (clustering: "siapa yang mirip?").
2. **Jawabannya kategori?** Ya → **klasifikasi** (churn ya/tidak, segmen A–D).
3. **Angka yang datang berurutan waktu?** Ya → **time series** (penjualan Maret).
4. **Selain itu** → **regresi** (belanja pelanggan tahun ini).
5. **Selalu bandingkan dengan baseline gratis**: "sama seperti bulan/tahun lalu".

3 Klasifikasi: Titanic

891 penumpang (kelas, jenis kelamin, umur, tarif, selamat?). Dibagi **712 latih** dan **179 uji**.

Naive Bayes untuk perempuan kelas 3: P(selamat) ∝ 273/712 × 188/273 × 95/273 = 0,383 × 0,689 × 0,348 = 0,0918; P(meninggal) ∝ 0,617 × 0,148 × 0,674 = 0,0615 → P(selamat) = 0,0918 ÷ (0,0918 + 0,0615) = **0,599**.

Metode	Benar per 100
Bilang tidak ada yang selamat (baseline)	61,5
Perempuan selamat, laki-laki tidak	77,7
Decision tree 2 pertanyaan	78,2

Naive Bayes	78,8
Nearest neighbours (k=5)	82,7
Neural network 3 hidden layer	79,9

Confusion matrix (Naive Bayes, 179 uji: TP 48, FP 17, FN 21, TN 93):

- Accuracy = (TP+TN)/semua = 141/179 = 0,788
- Precision = TP/(TP+FP) = 48/65 = 0,738 — saat bilang selamat, seberapa sering benar
- Recall = TP/(TP+FN) = 48/69 = 0,696 — berapa banyak yang selamat ditemukan
- Specificity = TN/(TN+FP) = 93/110 = 0,845
- NPV = TN/(TN+FN) = 93/114 = 0,816
- F1 = 2TP/(2TP+FP+FN) = 96/134 = 0,716

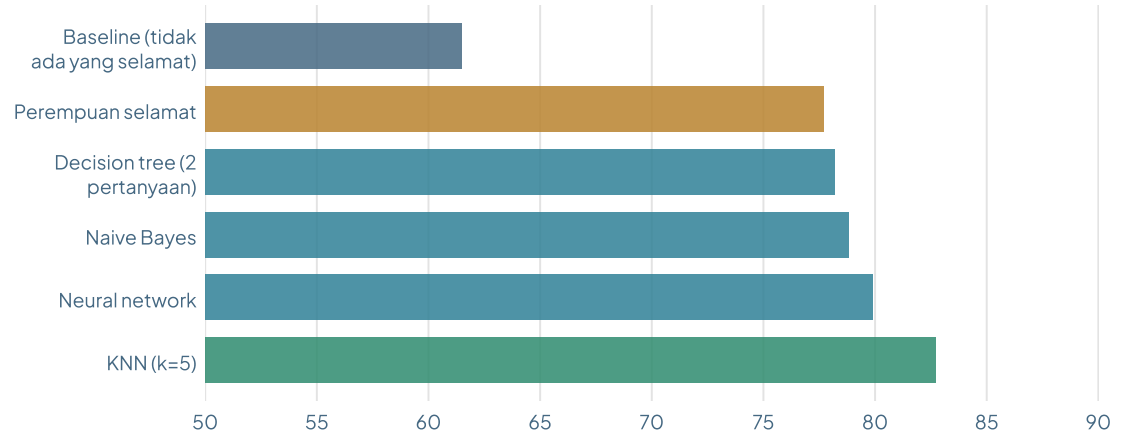
Kelebihan/kekurangan: aturan manual (gratis, tergantung penulis), decision tree (mudah dibaca, bisa menghafal bila terlalu dalam), Naive Bayes (cepat, asumsi kolom independen), KNN (tanpa training, lambat, perlu scaling), neural network (pola kompleks, tidak bisa dijelaskan); juga logistic regression (probabilitas, bobot terbaca), random forest (akurat, stabil), gradient boosting (sering paling akurat di data tabel, perlu tuning), SVM.

Train/test: menilai model pada baris yang sudah dilihatnya = menguji hafalan. Satu split bisa menipu (78,2–83,2 tergantung split). **Cross-validation 5 putaran:** 76,0 / 77,0 / 78,1 / 77,5 / 82,6 → rata-rata 78,2. **Underfitting** (terlalu sederhana: skor latih & uji rendah) vs **overfitting** (skor latih tinggi, uji jauh lebih rendah).

4 Titanic: perbandingan metode dan kalkulator confusion matrix

Pendalaman

Titanic: benar per 100 penumpang uji



Aturan sederhana "perempuan selamat" (77,7) sudah jauh di atas baseline (61,5). Model yang lebih rumit hanya menambah sedikit — neural network bahkan kalah dari KNN di data sekecil ini.

Coba ini

Ubah sel menjadi TP 0, FP 0, FN 10, TN 990 (fraud 1%). Accuracy 99%, tetapi recall 0% — itulah *accuracy paradox*.

5 Regresi: harga rumah California

20.640 lingkungan (pendapatan median, umur bangunan, kamar/rumah → harga median). Baseline: selalu jawab rata-rata $207.195.

Regresi linear = titik awal + Σ(bobot × kolom). Contoh: 1.730 + 44.476×5,74 + 1.684×17 − 2.815×6,16 = 1.730 + 255.184 + 28.622 − 17.350 = **$268.186** (harga sebenarnya $218.600).

Metrik	Rumus	Hasil
MAE	rata-rata |gap|	60.332
MSE	rata-rata gap²	6,59 miliar

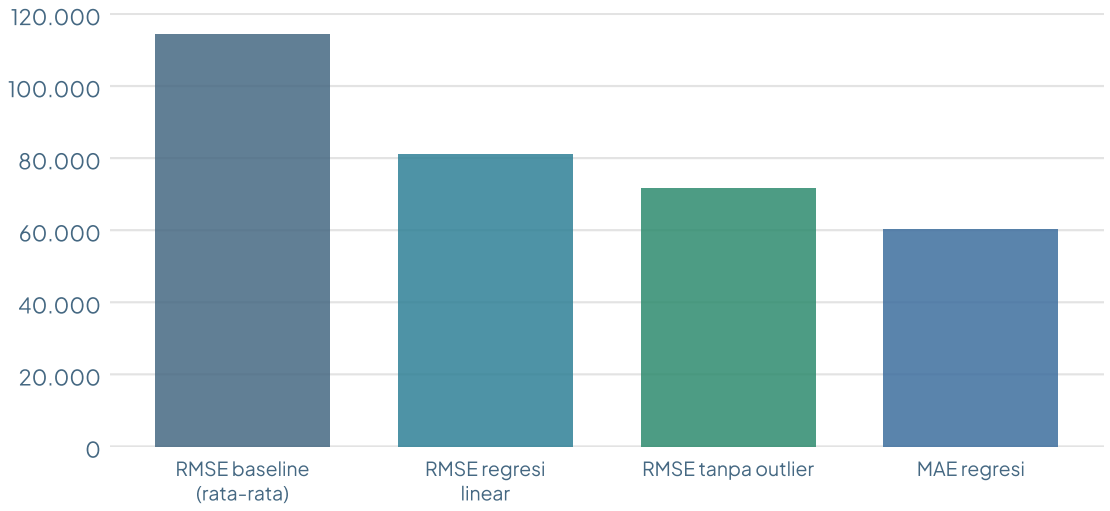
RMSE	√MSE (kembali ke dolar)	81.173 (baseline 114.486)
MAPE	rata-rata |gap| ÷ harga asli	37,7%
R^2	1 – Σgap² ÷ Σ(asli – rata-rata)²	0,497

Varian: Ridge (menahan bobot), Lasso (membuang kolom lemah), Elastic net, random forest, gradient boosting, tree, KNN, neural net.

6 California: seberapa jauh regresi mengalahkan rata-rata

Pendalaman

Harga rumah California: error (US$)



RMSE turun dari $114.486 (selalu jawab rata-rata) ke $81.173 — perbaikan 29%. R^2 0,497 artinya model menjelaskan sekitar separuh variasi harga; separuh sisanya dari hal yang tidak ada di data (lokasi detail, kondisi rumah, dll.).

```
Contoh: 1.730 + 44.476×5,74 + 1.684×17 - 2.815×6,16 = $268.186
(aktual $218.600, gap $49.586)
```

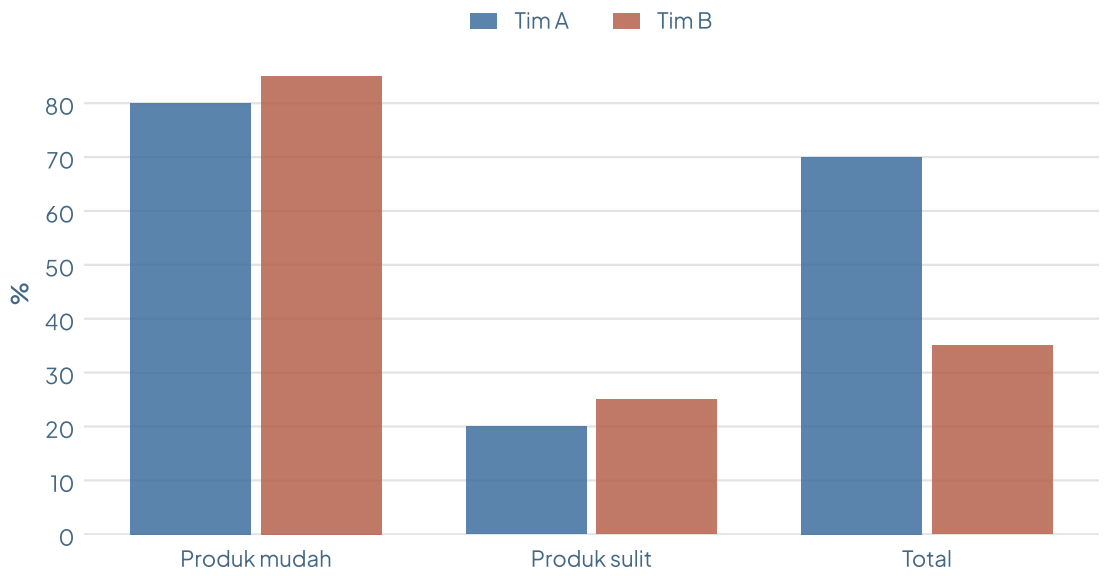
7 Yang bisa salah

- **Data leakage** — kolom yang baru terisi setelah jawaban diketahui (mis. "refund processed" untuk memprediksi penutupan akun). Model membaca jawaban, bukan memprediksi.
- **Overfitting** — model menghafal baris latihan.
- **Class imbalance & accuracy paradox** — bila kejadian langka (fraud 1%), model "selalu tidak" akurasinya 99% tapi tidak menemukan satu kasus pun. Lihat recall/precision.
- **Outlier** — RMSE 81.173 dengan semua baris, 71.706 tanpa outlier.
- **Concept drift** — pola yang dipelajari berakhir: aturan (subsidi dicabut — berbulan-bulan peringatan), pesaing (potong harga 20% — berminggu-minggu), dunia (banjir, pandemi, kurs — tanpa peringatan).
- **Efek kalender** — Idulfitri maju ~11 hari tiap tahun; Februari 19 hari kerja vs Maret 22 (16% lebih banyak hari jual).
- **Self-fulfilling / self-defeating** — model bilang cabang akan buruk → anggaran dipotong → benar-benar buruk; model bilang 500 akan churn → ditelepon semua → banyak bertahan (model tampak salah).
- **Simpson's paradox** — Tim A: produk mudah 80/100 (80%), sulit 4/20 (20%), total 84/120 = 70%. Tim B: mudah 17/20 (85%), sulit 25/100 (25%), total 42/120 = 35%. B lebih baik di kedua produk, tapi jauh lebih buruk total — karena B diberi lebih banyak produk sulit.
- **Selection bias** — data hanya dari yang diterima (karyawan yang direkrut); solusi: terima sampel acak kecil yang biasanya ditolak.
- **Model decay** — model masih jalan tapi tidak ada yang mengecek.
- **Korelasi ≠ kausalitas** — penjualan payung berkorelasi dengan macet; mengurangi payung tidak melancarkan jalan.

"All models are wrong, but some are useful." — George Box

8 Simpson's paradox dalam grafik Pendalaman

Tingkat keberhasilan per jenis produk



A: 100 mudah + 20 sulit. B: 20 mudah + 100 sulit.

Tim B lebih baik di produk mudah (85% vs 80%) **dan** produk sulit (25% vs 20%), tetapi total tim B 35% vs tim A 70%. Penyebabnya: tim B mendapat 100 produk sulit, tim A hanya 20. Selalu cek komposisi kelompok sebelum menyimpulkan.

Poin kunci

1. Klasifikasi, regresi, time series.
2. Kalahkan baseline naif dulu.
3. Uji di data yang belum pernah dilihat; pakai cross-validation.
4. Confusion matrix: precision, recall, F1.
5. Regresi: MAE, RMSE, MAPE, R^2.
6. Waspadai leakage, imbalance, drift, Simpson, selection bias.
7. Korelasi bukan kausalitas.

Studi kasus

Kasus & pembahasan

Retensi pelanggan bisnis telko: memilih 500 dari 10.000

Keputusan: siapa yang mendapat 500 tawaran retensi per bulan. **Jenis:** klasifikasi (akan berhenti dalam 3 bulan: ya/tidak), dipakai untuk *mengurutkan*. **Data yang aman:** lama berlangganan, tren pemakaian, keluhan, keterlambatan bayar — *bukan* kolom yang terisi setelah pelanggan memutuskan pergi (leakage). **Evaluasi:** bukan akurasi (churn jarang), tetapi berapa banyak churner yang tertangkap di 500 teratas (precision@500, recall). **Jebakan:** setelah ditelepon banyak yang bertahan → model terlihat "salah" (self-defeating); maka simpan kelompok kontrol acak kecil yang tidak ditelepon untuk mengukur efek sebenarnya (uplift). Bandingkan dengan baseline: pilih 500 secara acak, atau 500 dengan tagihan terbesar.

Contoh soal dan pembahasan

Soal 1 · Sedang **Confusion matrix untuk kejadian langka**

Model deteksi fraud pada 1.000 transaksi: TP 30, FP 20, FN 10, TN 940. Hitung accuracy, precision, recall, specificity, dan F1.

1. Accuracy = (30 + 940) ÷ 1.000 = 97%.
2. Precision = TP ÷ (TP + FP) = 30 ÷ 50 = 60% → dari yang ditandai fraud, 60% benar.
3. Recall = TP ÷ (TP + FN) = 30 ÷ 40 = 75% → 75% fraud tertangkap.
4. Specificity = TN ÷ (TN + FP) = 940 ÷ 960 = 97,9%.
5. F1 = 2TP ÷ (2TP + FP + FN) = 60 ÷ 90 = 0,667.
6. Bandingkan dengan model "selalu bukan fraud": accuracy 96% tapi recall 0%.

Jawaban: Accuracy 97%, precision 60%, recall 75%, specificity 97,9%, F1 0,67.

Soal 2 Sedang **MAE vs RMSE**

Empat prediksi harga punya error (aktual – prediksi, Rp juta): 10, –20, 5, –15. Hitung MAE dan RMSE.

1. MAE = (10 + 20 + 5 + 15) ÷ 4 = 50 ÷ 4 = 12,5.
2. MSE = (100 + 400 + 25 + 225) ÷ 4 = 750 ÷ 4 = 187,5.
3. RMSE = √187,5 = 13,7.
4. RMSE > MAE karena error besar (–20) dikuadratkan → RMSE lebih "menghukum" kesalahan besar.

Jawaban: MAE 12,5; RMSE 13,7.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. Memprediksi apakah pelanggan akan menutup akun adalah…

A. Regresi
B. Klasifikasi
C. Time series
D. Clustering

Jawaban: B. Jawabannya kategori.

2. TP 48, FP 17. Precision = …

A. 0,696
B. 0,738
C. 0,788
D. 0,845

Jawaban: B. 48 ÷ 65.

3. Kolom 'refund processed' untuk memprediksi penutupan akun adalah contoh…

A. Overfitting
B. Data leakage
C. Concept drift
D. Selection bias

Jawaban: B. Kolom terisi setelah jawaban diketahui.

---

4. R^2 0,497 berarti…

A. Model salah 49,7%
B. Model menjelaskan ±50% variasi harga
C. Akurasi 49,7%
D. Error $49.700

Jawaban: B. $1 - \Sigma gap^2/\Sigma(asli - rata\text{-}rata)^2$.

---

5. Model bilang 500 pelanggan akan churn, semua ditelepon, banyak bertahan. Model tampak salah karena…

A. Overfitting
B. Self-defeating prediction
C. Leakage
D. Outlier

Jawaban: B. Simpan kelompok kontrol untuk mengukur uplift.

Sumber

- MATERI WEEK4 MK06 P3MD BA — Predictive Analytics