RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 7

# Financial Analytics

Di mana analitik dipakai di keuangan (forecast penjualan, perencanaan kas, credit scoring, deteksi fraud, risiko kurs, penilaian investasi). Dua kasus: (1) forecast penjualan bulanan distributor makanan dengan regresi trend + musim + kolom Lebaran, serta nowcasting; (2) credit scoring dengan logistic regression, decision tree, random forest — memilih cut-off dan isu keadilan (kolom jenis kelamin).

## Materi

### 1 Forecast penjualan bulanan untuk anggaran 2027

Distributor makanan (fiktif; tanggal Lebaran nyata) menyusun anggaran tiap Oktober. Metode lama: salin bulan tahun lalu + pertumbuhan tahun lalu (error rata-rata 6,7% di 12 bulan uji).

**Dekomposisi deret 2019–2026:** trend (Rp38 → 70 M/bulan), musim (pola tahunan), dan sisa yang tidak terjelaskan — nilai terbesar jatuh di bulan Lebaran, yang **maju ~11 hari tiap tahun** (2019: 5 Juni → bulan tersibuk Mei; 2023: 22 April → April; 2024: 10 April → Maret; 2026: 20 Maret → Maret). Musim tetap per bulan tidak bisa menangkapnya.

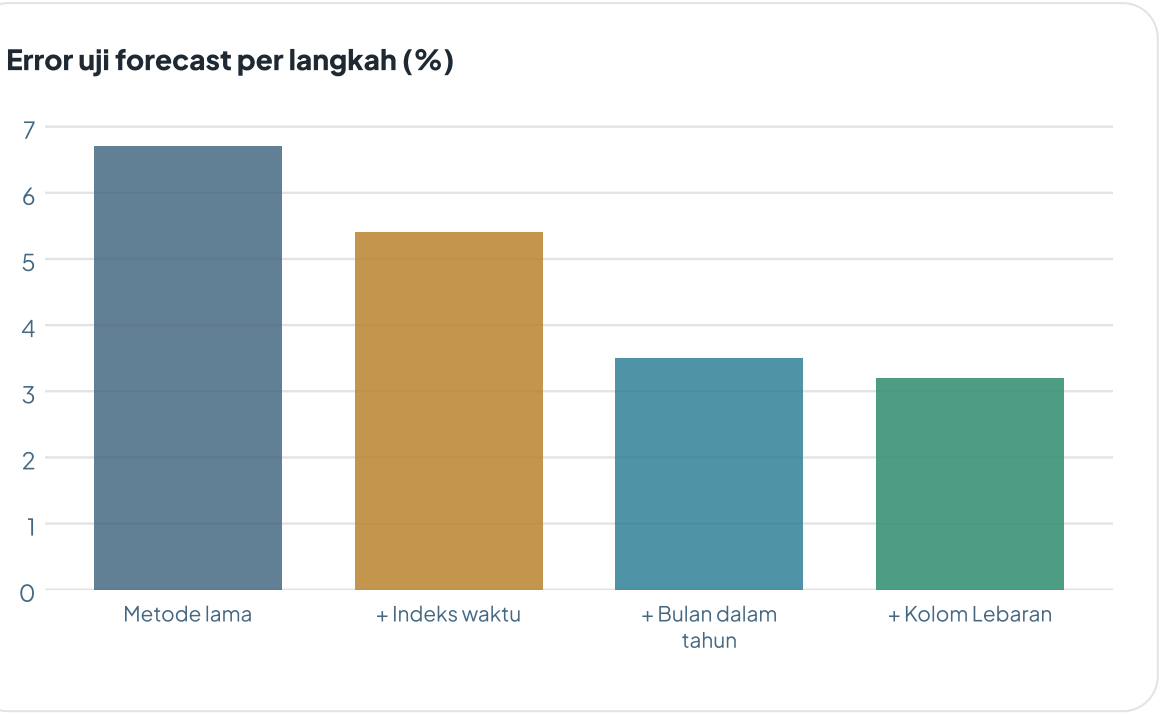
| Langkah | Kolom ditambah | Menangkap | Error uji |
|---|---|---|---|
| Metode lama | — | — | 6,7% |
| 1 | Indeks waktu | Pertumbuhan | 5,4% |
| 2 | Bulan dalam tahun | Musim tahunan | 3,5% |
| 3 | Hari sibuk sebelum Lebaran & hari libur Lebaran | Lebaran | **3,2%** |

Bulan pandemi (Apr 2020–Mar 2021) diberi flag di setiap langkah. **Efek estimasi:** tiap hari sibuk sebelum Lebaran +1,7%; tiap hari libur Lebaran –3,5%; Desember +14,2% vs Januari; tiap bulan tambahan +0,6% (pertumbuhan); bulan pandemi –12,9%.

**Dampaknya pada 2027** (Lebaran ~10 Maret → hari sibuk jatuh di Februari): tanpa kolom Lebaran, Feb 64,0 & Mar 78,2 (tersibuk Maret); dengan kolom Lebaran, Feb 78,0 & Mar 64,9 (tersibuk **Februari**). Tanpa kolom itu, Rp14 M ditaruh di bulan yang salah — berbahaya untuk perencanaan kas & stok. Laporkan forecast dengan rentang 80%.

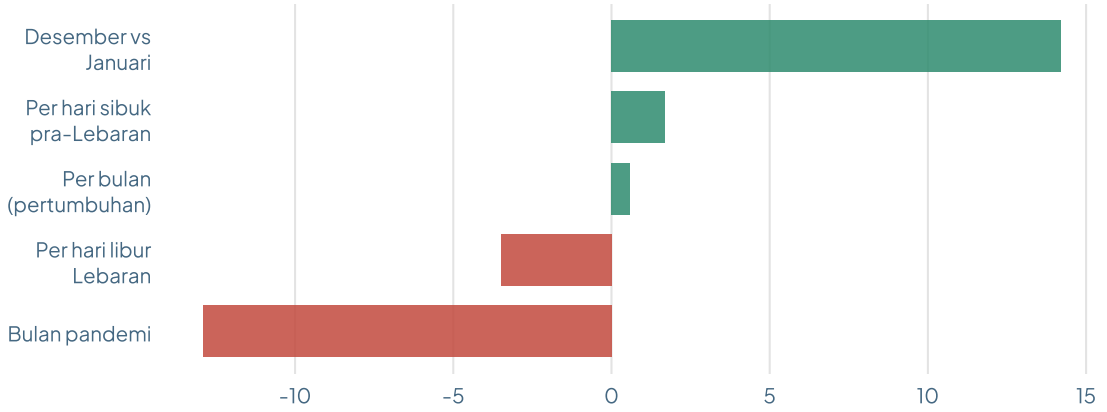
## 2 Forecast anggaran 2027 dalam grafik

Pendalaman

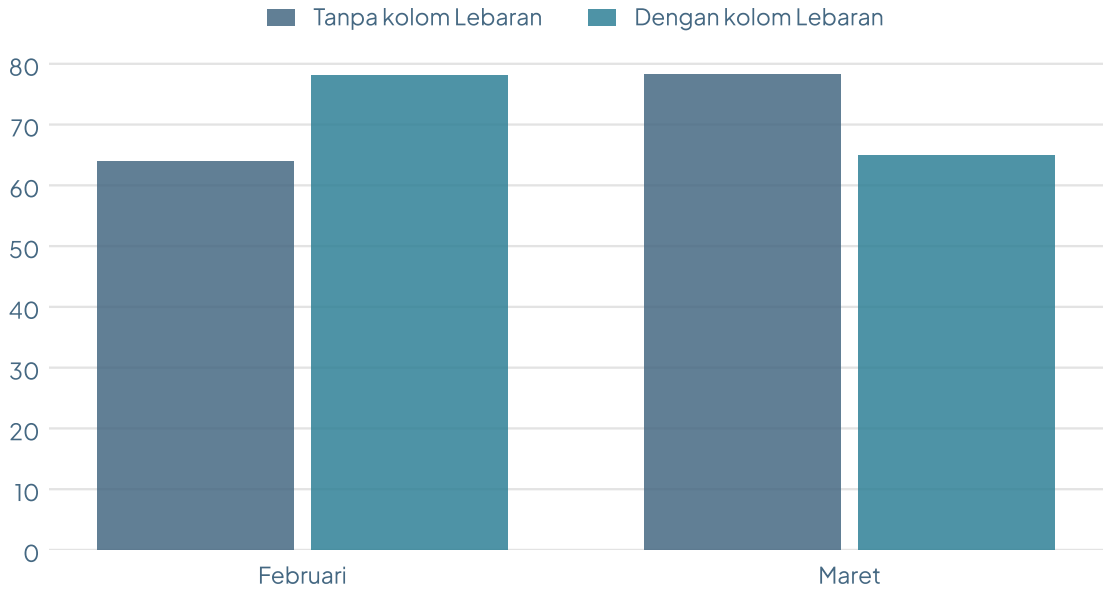



Setiap kolom tambahan memotong error: dari 6,7% (salin tahun lalu) menjadi 3,2% setelah memasukkan hari sibuk dan libur Lebaran. Lompatan terbesar datang dari pola bulanan (5,4% → 3,5%).

**Efek estimasi tiap kolom (%)**




**Forecast Februari & Maret 2027 (Rp M)**




Lebaran 2027 jatuh sekitar 10 Maret, jadi hari-hari sibuk sebelum Lebaran ada di Februari. Model tanpa kolom Lebaran menaruh puncak di Maret; model dengan kolom Lebaran memindahkannya ke Februari — selisih ±Rp14 M di bulan yang salah.

## 3 Nowcasting bulan berjalan

Buku tutup 10 hari setelah akhir bulan; manajemen butuh angka lebih cepat. **Nowcasting** = estimasi bulan ini dari hari yang sudah tercatat.

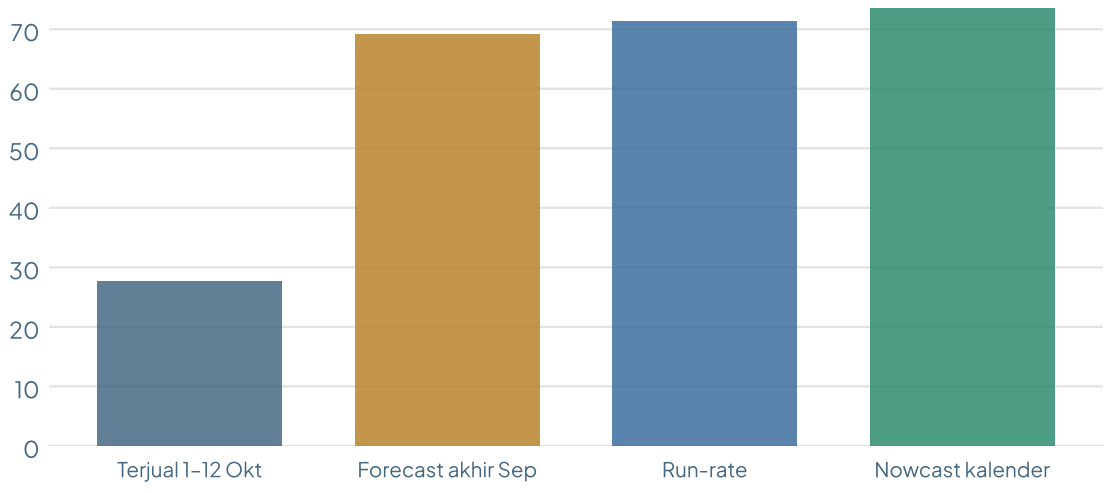
| Metode (Oktober 2026, hari ke-12) | Hitungan | Rp M |
|---|---|---|
| Terjual 1–12 Okt | | 27,6 |
| Run-rate (semua hari dianggap sama) | 27,6 × 31 ÷ 12 | 71,3 |
| Calendar-based (porsi bulan yang biasanya sudah tercapai) | 27,6 ÷ 0,375 | 73,5 |
| Forecast saja (dibuat akhir September) | | 69,2 |

Pada tanggal 12, Oktober tipikal sudah mencapai 37,5% penjualannya, bukan 38,7% (12/31 hari). Rata-rata 12 bulan uji: mulai hari ke-5, nowcast berbasis kalender mengalahkan forecast.

## 4 Tiga cara menebak Oktober di tanggal 12

Pendalaman

**Estimasi penjualan Oktober 2026 (Rp M)**




Run-rate menganggap semua hari sama (12/31 = 38,7%). Padahal pada tanggal 12, Oktober tipikal baru mencapai 37,5% penjualannya — sehingga nowcast berbasis kalender memberi angka sedikit lebih tinggi (Rp73,5 M).

## 5 Credit scoring

Pemberi pinjaman konsumen (fiktif) dengan 999 aplikasi: 650 lunas, 349 gagal bayar (34,9%). Gagal bayar = kehilangan pinjaman; penolakan yang salah = kehilangan pelanggan. Latih 749, uji 250.

| Metode | Akurasi | Default tertangkap | Pembayar baik ditolak |
|---|---|---|---|
| Setujui semua | 65,2% | 0 dari 87 | 0 dari 163 |
| Logistic regression | 77,2% | **53** dari 87 | 23 |
| Decision tree | 76,0% | 45 | 18 |
| Random forest | **79,2%** | 50 | 15 |

Random forest akurasi tertinggi; logistic paling banyak menangkap default. Pilihan bergantung pada **biaya dua jenis kesalahan** yang tidak sama (ingat critical ratio minggu 5).

**Decision tree sebagai aturan** (contoh): ≤27 tahun, pinjaman ≤16 bulan, tidak sewa rumah → 23,8% default → setujui; ≤27, ≤16 bulan, sewa → 75,9% → tolak; >27, ≤45 bulan, jumlah ≤11.850 → 21,0% (499 pemohon) → setujui; >27, jumlah >11.850 → 100% (6 pemohon) → tolak. Pohon bertanya umur dulu, lalu lama pinjaman.

**Memilih cut-off** (model mengurutkan; manajemen menentukan batas):

| Setujui | Default di antara yang disetujui | Pembayar baik ditolak | Default disetujui |
|---|---|---|---|
| Semua | 34,8% | 0 | 87 |
| Top 80% | 22,5% | 8 | 45 |
| Top 70% | 20,0% | 23 | 35 |
| Top 60% | 16,7% | 38 | 25 |

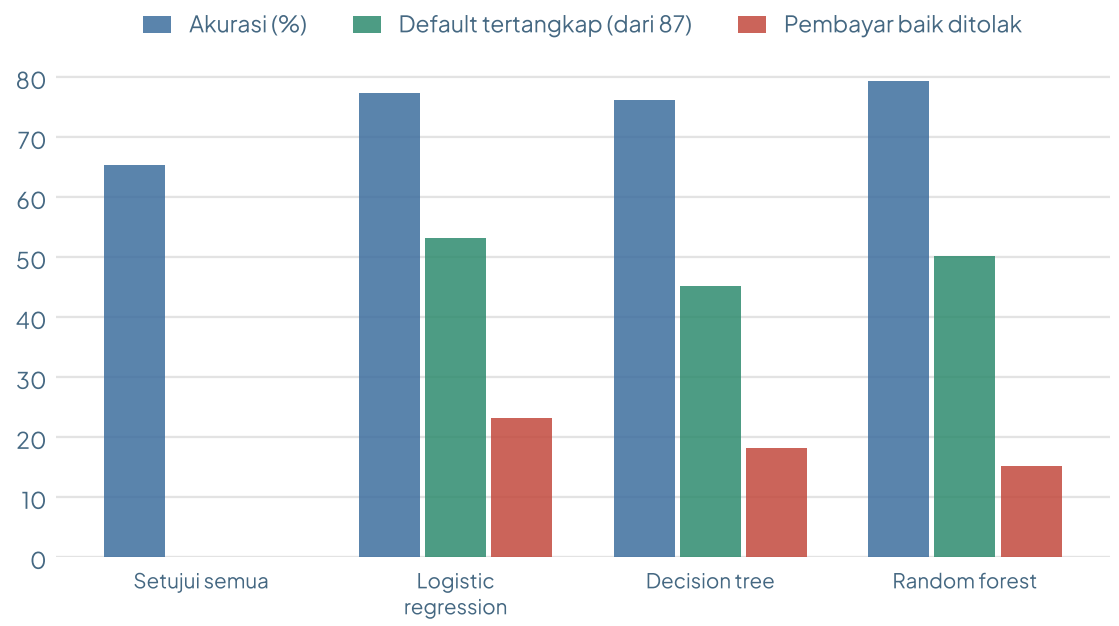
| | | | |
|---|---|---|---|
| Top 50% | 13,6% | 55 | 17 |

**Keadilan:** default perempuan 48,9% vs laki-laki 28,7% di data ini. Dengan kolom jenis kelamin akurasi 77,2% (53 default tertangkap); tanpa itu 74,0% (49). Menyimpan kolom itu adalah *keputusan kebijakan* (etika, regulasi, risiko diskriminasi), bukan keputusan teknis. Catatan: PNS punya default tertinggi tapi hanya 17 pemohon — terlalu sedikit untuk disimpulkan.

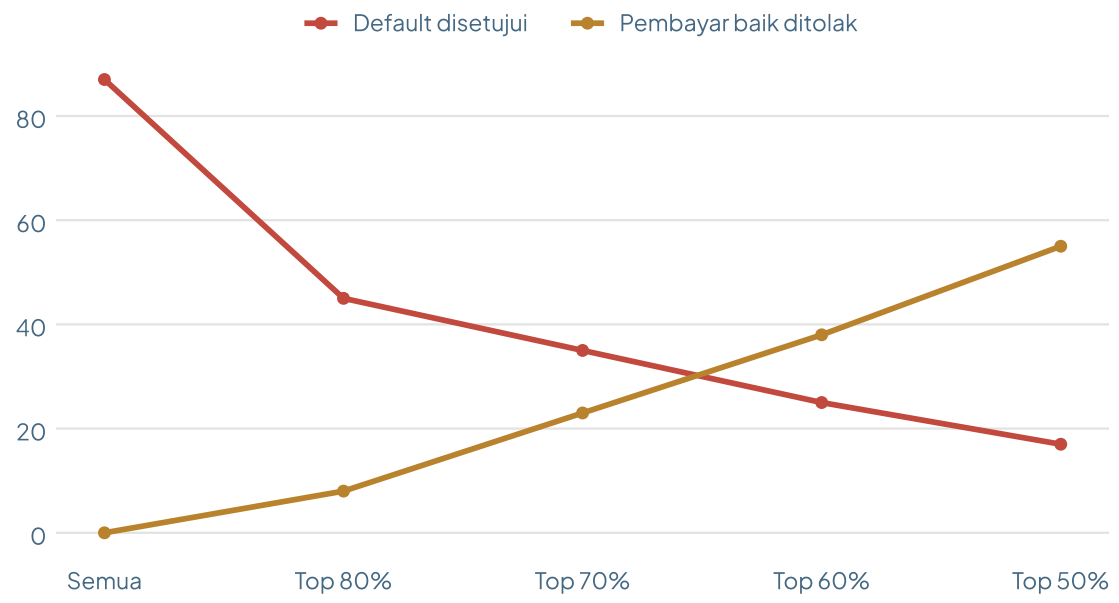
## 6 Credit scoring: metode dan cut-off dalam grafik

Pendalaman

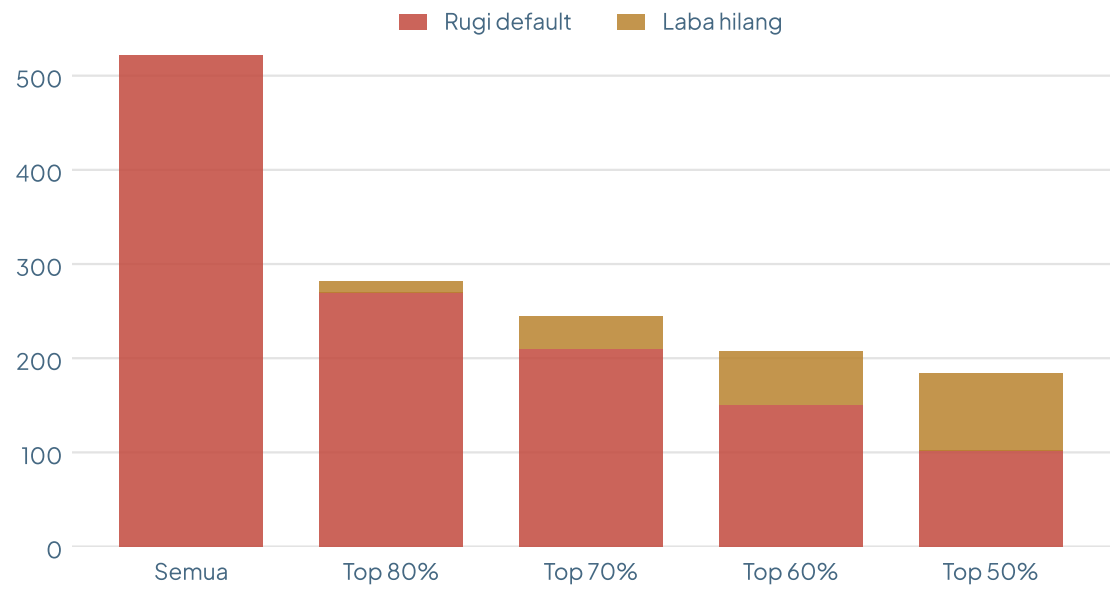
**Perbandingan metode (250 data uji)**



**Trade-off cut-off**




**Total biaya kesalahan (Rp jt; default Rp6 jt, pembayar baik Rp1,5 jt)**




Dengan asumsi latihan (rugi Rp6 jt per default, laba Rp1,5 jt per pembayar baik), Top 60% (Rp207 jt) memang lebih baik dari Top 70% (Rp244,5 jt) — dan kalau tabel diteruskan, **Top 50% bahkan lebih murah lagi (Rp184,5 jt)**. Cut-off optimum sangat bergantung pada rasio dua biaya kesalahan; jika laba per pembayar baik naik, cut-off bergeser ke menyetujui lebih banyak.

**Keadilan**

Default perempuan 48,9% vs laki-laki 28,7% di data ini. Kolom jenis kelamin menaikkan akurasi (77,2% vs 74,0%), tetapi memakainya adalah keputusan etis dan hukum, bukan sekadar teknis.

## Poin kunci

1. Analitik keuangan: forecast, kas, kredit, fraud, kurs, investasi.
2. Regresi trend + bulan + kolom Lebaran menurunkan error 6,7% → 3,2%.
3. Lebaran maju ~11 hari/tahun — musim per bulan tidak cukup.
4. Nowcast berbasis kalender > run-rate.
5. Credit scoring: model mengurutkan, manajemen memilih cut-off.
6. Fitur sensitif (jenis kelamin) adalah keputusan kebijakan.

## Studi kasus

Kasus & pembahasan

### Latihan: menilai aplikasi baru dan menetapkan cut-off

**Aplikasi baru:** umur 25, pinjaman 24 bulan untuk usaha, tabungan rendah, sewa rumah. Menurut aturan pohon: ≤27 tahun dan pinjaman >16 bulan dengan tabungan diketahui → kelompok default 87,3% → **tolak**, atau tawarkan alternatif (tenor lebih pendek, jumlah lebih kecil, agunan).

**Cut-off:** misalkan rugi rata-rata per default = Rp6 juta dan laba per pembayar baik = Rp1,5 juta. Bandingkan Top 70% (35 default × 6 = Rp210 jt rugi; menolak 23 pembayar baik × 1,5 = Rp34,5 jt laba hilang) dengan Top 60% (25 × 6 = 150; 38 × 1,5 = 57). Total biaya: 244,5 vs 207 → Top 60% lebih baik pada asumsi ini. Jika laba per pembayar baik naik, cut-off optimum bergeser ke menyetujui lebih banyak. Inilah cara menghubungkan model prediktif (minggu 4) dengan keputusan preskriptif (minggu 5).

## Contoh soal dan pembahasan

Soal 1 Mudah **Nowcasting**

Sampai tanggal 10, penjualan bulan ini Rp40 M (bulan 30 hari). Data historis: pada tanggal 10 biasanya 30% penjualan bulanan sudah tercapai. Bandingkan run-rate dan nowcast berbasis kalender.

1. Run-rate = 40 × 30 ÷ 10 = 120 (anggap semua hari sama).
2. Kalender = 40 ÷ 0,30 = 133,3.
3. Selisih Rp13 M muncul karena awal bulan biasanya lebih sepi.

**Jawaban:** Run-rate Rp120 M; nowcast kalender Rp133 M (lebih akurat bila pola harian stabil).

Soal 2 Sedang **Memilih cut-off kredit**

Rugi per default Rp8 juta; laba per pembayar baik Rp2 juta. Top 70%: 30 default disetujui, 20 pembayar baik ditolak. Top 60%: 22 default disetujui, 35 pembayar baik ditolak. Pilih yang mana?

1. Top 70%: 30 × 8 + 20 × 2 = 240 + 40 = 280.
2. Top 60%: 22 × 8 + 35 × 2 = 176 + 70 = 246.

**Jawaban:** Top 60% (biaya kesalahan Rp246 juta vs Rp280 juta).

Soal 3 Mudah **MAPE**

Aktual 100, 120, 90; forecast 110, 115, 99. Hitung MAPE.

1. |error| ÷ aktual: 10/100 = 10%; 5/120 = 4,17%; 9/90 = 10%.
2. MAPE = (10 + 4,17 + 10) ÷ 3 = 8,06%.

**Jawaban:** MAPE ± 8,1%.

## Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

**1. Kenapa musim tetap per bulan tidak cukup untuk Lebaran?**

A. Lebaran maju ±11 hari tiap tahun
B. Lebaran selalu di bulan yang sama
C. Data tidak ada
D. Karena pandemi

**Jawaban: A.** Kalender Hijriah.

**2. Terjual 27,6 di tanggal 12; biasanya 37,5% bulan sudah tercapai. Nowcast…**

A. 69,2
B. 71,3
C. 73,5
D. 80,0

**Jawaban: C.** 27,6 ÷ 0,375.

**3. Metode yang paling banyak menangkap default di data uji…**

A. Random forest
B. Logistic regression
C. Decision tree
D. Setujui semua

**Jawaban: B.** 53 dari 87, walau akurasinya bukan tertinggi.

**4. Siapa yang menentukan cut-off persetujuan kredit?**

A. Model
B. Manajemen, berdasarkan biaya kesalahan
C. Pelanggan
D. Regulator saja

**Jawaban: B.** Model mengurutkan; manajemen memutuskan batas.

---

**5. Dengan biaya latihan, total biaya Top 60% adalah…**

A. 184,5
B. 207
C. 244,5
D. 282

**Jawaban: B.** $25 \times 6 + 38 \times 1{,}5$.

---

**Sumber**

- Materi P3MD WEEK 7 — Financial Analytics (MK6)