RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 7

Financial Analytics

Di mana analitik dipakai di keuangan (forecast penjualan, perencanaan kas, credit scoring, deteksi fraud, risiko kurs, penilaian investasi). Dua kasus: (1) forecast penjualan bulanan distributor makanan dengan regresi trend + musim + kolom Lebaran, serta nowcasting; (2) credit scoring dengan logistic regression, decision tree, random forest — memilih cut-off dan isu keadilan (kolom jenis kelamin).

Materi

1 Forecast penjualan bulanan untuk anggaran 2027

Distributor makanan (fiktif; tanggal Lebaran nyata) menyusun anggaran tiap Oktober. Metode lama: salin bulan tahun lalu + pertumbuhan tahun lalu (error rata-rata 6,7% di 12 bulan uji).

Dekomposisi deret 2019–2026: trend (Rp38 → 70 M/bulan), musim (pola tahunan), dan sisa yang tidak terjelaskan — nilai terbesar jatuh di bulan Lebaran, yang **maju ~11 hari tiap tahun** (2019: 5 Juni → bulan tersibuk Mei; 2023: 22 April → April; 2024: 10 April → Maret; 2026: 20 Maret → Maret). Musim tetap per bulan tidak bisa menangkapnya.

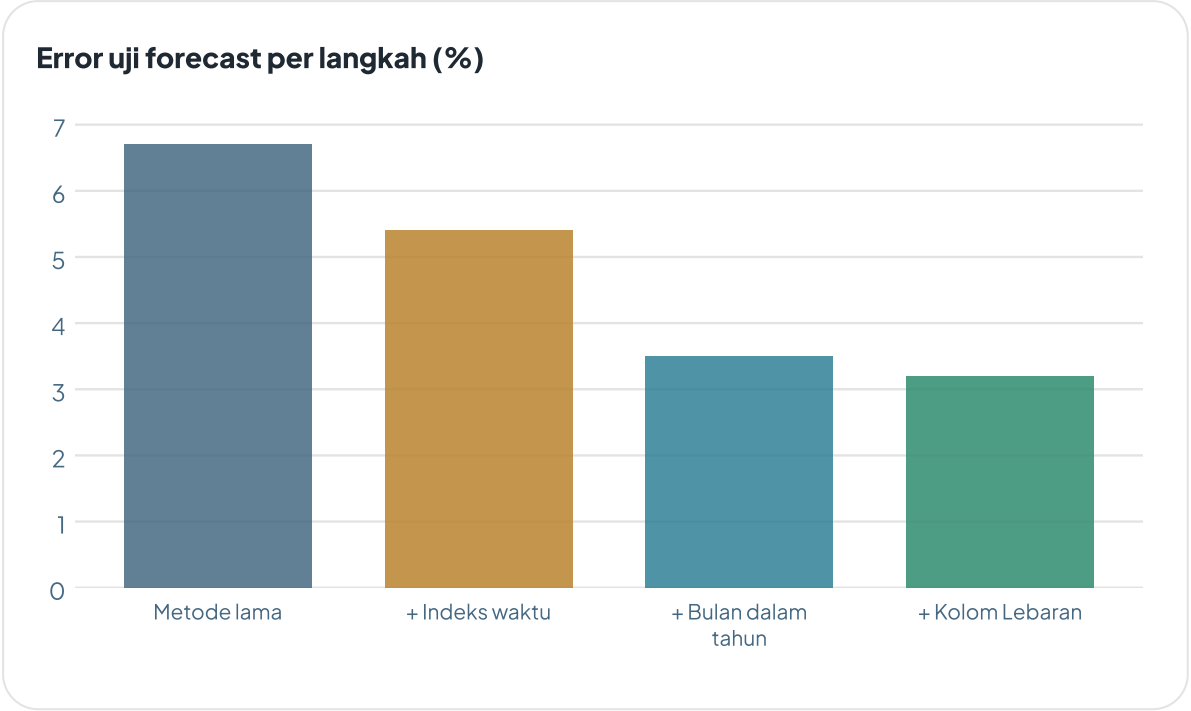
Langkah	Kolom ditambah	Menangkap	Error uji
Metode lama	—	—	6,7%
1	Indeks waktu	Pertumbuhan	5,4%
2	Bulan dalam tahun	Musim tahunan	3,5%
3	Hari sibuk sebelum Lebaran & hari libur Lebaran	Lebaran	**3,2%**

Bulan pandemi (Apr 2020–Mar 2021) diberi flag di setiap langkah. **Efek estimasi:** tiap hari sibuk sebelum Lebaran +1,7%; tiap hari libur Lebaran –3,5%; Desember +14,2% vs Januari; tiap bulan tambahan +0,6% (pertumbuhan); bulan pandemi –12,9%.

Dampaknya pada 2027 (Lebaran ~10 Maret → hari sibuk jatuh di Februari): tanpa kolom Lebaran, Feb 64,0 & Mar 78,2 (tersibuk Maret); dengan kolom Lebaran, Feb 78,0 & Mar 64,9 (tersibuk **Februari**). Tanpa kolom itu, Rp14 M ditaruh di bulan yang salah — berbahaya untuk perencanaan kas & stok. Laporkan forecast dengan rentang 80%.

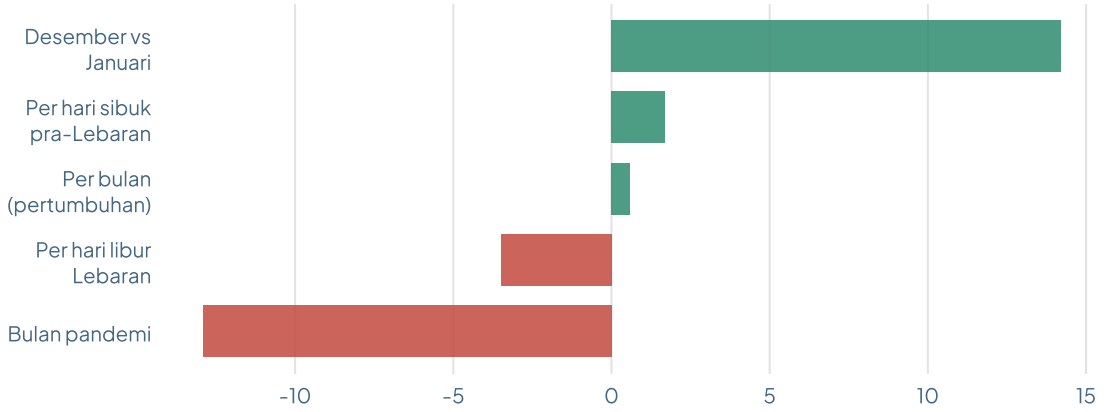
2 Forecast anggaran 2027 dalam grafik

Pendalaman

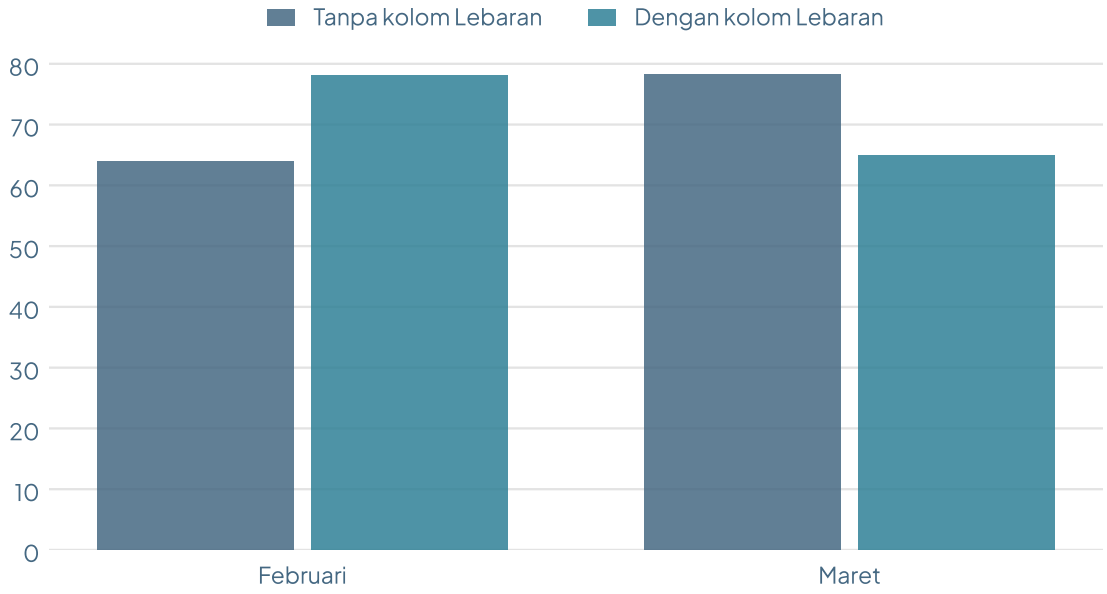


Setiap kolom tambahan memotong error: dari 6,7% (salin tahun lalu) menjadi 3,2% setelah memasukkan hari sibuk dan libur Lebaran. Lompatan terbesar datang dari pola bulanan (5,4% → 3,5%).

Efek estimasi tiap kolom (%)



Forecast Februari & Maret 2027 (Rp M)



Lebaran 2027 jatuh sekitar 10 Maret, jadi hari-hari sibuk sebelum Lebaran ada di Februari. Model tanpa kolom Lebaran menaruh puncak di Maret; model dengan kolom Lebaran memindahkannya ke Februari — selisih ±Rp14 M di bulan yang salah.

3 Nowcasting bulan berjalan

Buku tutup 10 hari setelah akhir bulan; manajemen butuh angka lebih cepat. **Nowcasting** = estimasi bulan ini dari hari yang sudah tercatat.

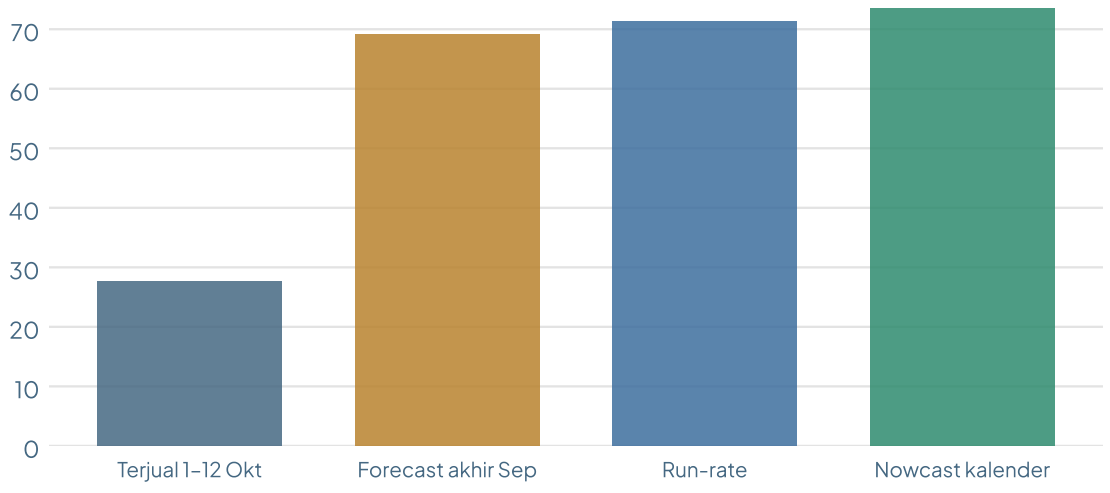
Metode (Oktober 2026, hari ke-12)	Hitungan	Rp M
Terjual 1–12 Okt		27,6
Run-rate (semua hari dianggap sama)	27,6 × 31 ÷ 12	71,3
Calendar-based (porsi bulan yang biasanya sudah tercapai)	27,6 ÷ 0,375	73,5
Forecast saja (dibuat akhir September)		69,2

Pada tanggal 12, Oktober tipikal sudah mencapai 37,5% penjualannya, bukan 38,7% (12/31 hari). Rata-rata 12 bulan uji: mulai hari ke-5, nowcast berbasis kalender mengalahkan forecast.

4 Tiga cara menebak Oktober di tanggal 12

Pendalaman

Estimasi penjualan Oktober 2026 (Rp M)



Run-rate menganggap semua hari sama (12/31 = 38,7%). Padahal pada tanggal 12, Oktober tipikal baru mencapai 37,5% penjualannya — sehingga nowcast berbasis kalender memberi angka sedikit lebih tinggi (Rp73,5 M).

5 Credit scoring

Pemberi pinjaman konsumen (fiktif) dengan 999 aplikasi: 650 lunas, 349 gagal bayar (34,9%). Gagal bayar = kehilangan pinjaman; penolakan yang salah = kehilangan pelanggan. Latih 749, uji 250.

Metode	Akurasi	Default tertangkap	Pembayar baik ditolak
Setujui semua	65,2%	0 dari 87	0 dari 163
Logistic regression	77,2%	**53** dari 87	23
Decision tree	76,0%	45	18
Random forest	**79,2%**	50	15

Random forest akurasi tertinggi; logistic paling banyak menangkap default. Pilihan bergantung pada **biaya dua jenis kesalahan** yang tidak sama (ingat critical ratio minggu 5).

Decision tree sebagai aturan (contoh): ≤27 tahun, pinjaman ≤16 bulan, tidak sewa rumah → 23,8% default → setujui; ≤27, ≤16 bulan, sewa → 75,9% → tolak; >27, ≤45 bulan, jumlah ≤11.850 → 21,0% (499 pemohon) → setujui; >27, jumlah >11.850 → 100% (6 pemohon) → tolak. Pohon bertanya umur dulu, lalu lama pinjaman.

Memilih cut-off (model mengurutkan; manajemen menentukan batas):

Setujui	Default di antara yang disetujui	Pembayar baik ditolak	Default disetujui
Semua	34,8%	0	87
Top 80%	22,5%	8	45
Top 70%	20,0%	23	35
Top 60%	16,7%	38	25

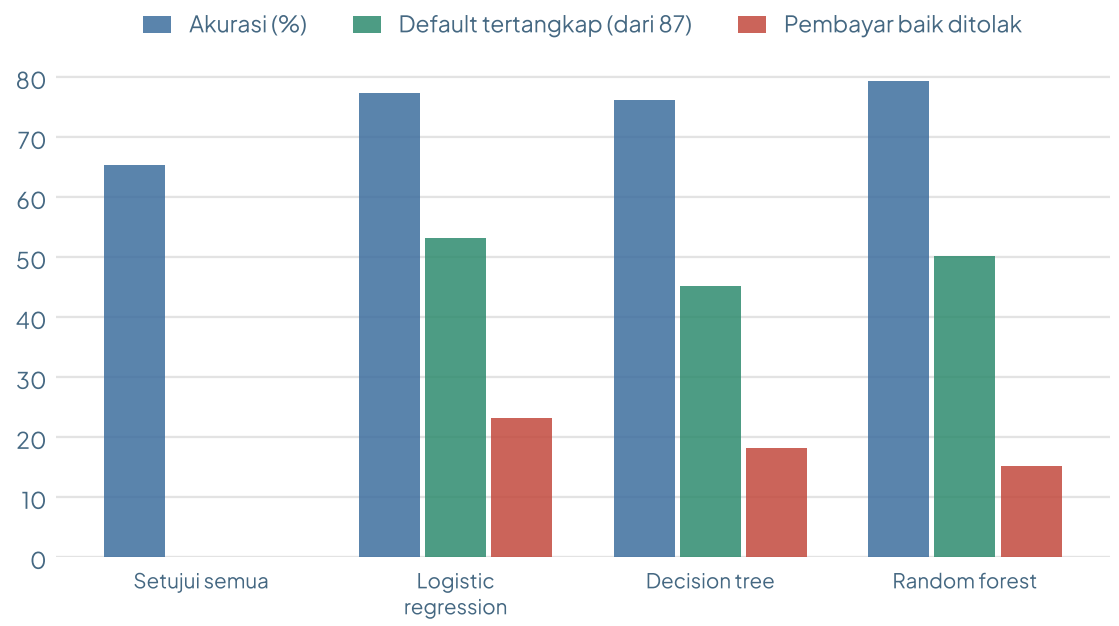
Top 50%	13,6%	55	17

Keadilan: default perempuan 48,9% vs laki-laki 28,7% di data ini. Dengan kolom jenis kelamin akurasi 77,2% (53 default tertangkap); tanpa itu 74,0% (49). Menyimpan kolom itu adalah *keputusan kebijakan* (etika, regulasi, risiko diskriminasi), bukan keputusan teknis. Catatan: PNS punya default tertinggi tapi hanya 17 pemohon — terlalu sedikit untuk disimpulkan.

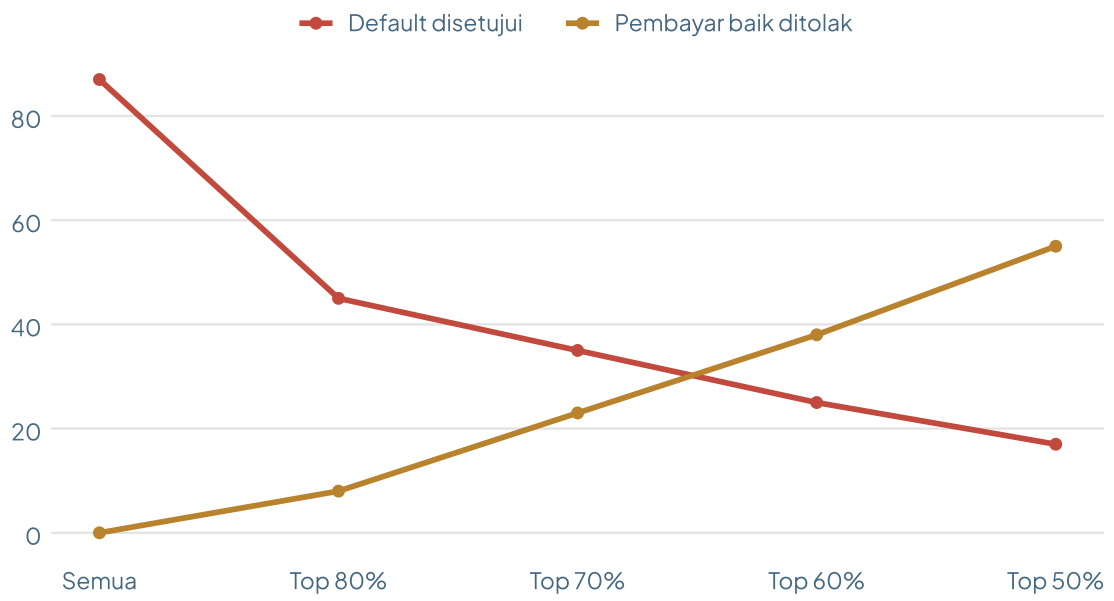
6 Credit scoring: metode dan cut-off dalam grafik

Pendalaman

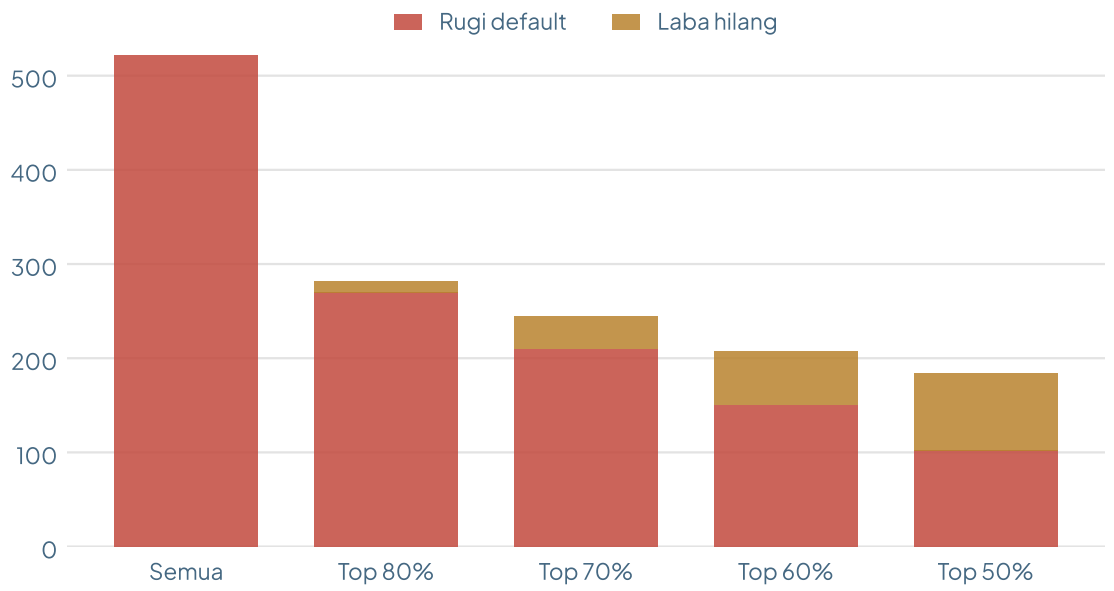
Perbandingan metode (250 data uji)



Trade-off cut-off



Total biaya kesalahan (Rp jt; default Rp6 jt, pembayar baik Rp1,5 jt)



Dengan asumsi latihan (rugi Rp6 jt per default, laba Rp1,5 jt per pembayar baik), Top 60% (Rp207 jt) memang lebih baik dari Top 70% (Rp244,5 jt) — dan kalau tabel diteruskan, **Top 50% bahkan lebih murah lagi (Rp184,5 jt)**. Cut-off optimum sangat bergantung pada rasio dua biaya kesalahan; jika laba per pembayar baik naik, cut-off bergeser ke menyetujui lebih banyak.

Keadilan

Default perempuan 48,9% vs laki-laki 28,7% di data ini. Kolom jenis kelamin menaikkan akurasi (77,2% vs 74,0%), tetapi memakainya adalah keputusan etis dan hukum, bukan sekadar teknis.

7 Mengukur akurasi forecast dan membaca rentang 80%

Angka "error rata-rata 3,2%" di kasus distributor adalah **MAPE** (mean absolute percentage error): rata-rata selisih absolut antara forecast dan aktual, dalam persen dari aktual.

```
MAPE = (1/n) × Σ |aktual - forecast| ÷ aktual × 100%
```

Bulan	Aktual (Rp M)	Forecast	|Selisih| ÷ aktual
1	64	60	4 ÷ 64 = 6,25%
2	70	73	3 ÷ 70 = 4,29%
3	58	61	3 ÷ 58 = 5,17%
4	66	66	0%
MAPE			**3,93%**

Ukuran lain: **MAE** (rata-rata selisih dalam rupiah — mudah dipahami manajer: "rata-rata meleset Rp2,5 M") dan **RMSE** (menghukum kesalahan besar lebih berat). MAPE tidak cocok bila ada bulan dengan penjualan mendekati nol, karena pembaginya sangat kecil.

Selalu uji di data yang tidak dipakai melatih model
Seperti di slide: model dilatih sampai Agustus 2025, lalu meramal 12 bulan berikutnya sekaligus. Error di data latih hampir selalu lebih kecil dan memberi rasa percaya diri yang palsu.

Membaca rentang 80%. Rentang 80% berarti: jika model ini dipakai berkali-kali, sekitar 8 dari 10 bulan nilai aktualnya jatuh di dalam rentang, dan 2 dari 10 jatuh di luar (1 di atas, 1 di bawah). Untuk anggaran, gunakan angka tengah sebagai target, batas bawah untuk merencanakan kas minimum, dan batas atas

untuk memastikan stok dan armada cukup. Semakin jauh ke depan, rentangnya semakin lebar.

Penerapan lain di keuangan (dari peta slide): *perencanaan kas* (apakah kas cukup setiap hari — mirip cash budget MK2 Week 3), *deteksi fraud* (transaksi yang tidak mirip pola biasanya, misalnya analisis anomali), *risiko kurs* (seberapa jauh kurs bisa bergerak — Value at Risk), dan *penilaian investasi* (asumsi mana yang paling menentukan NPV — analisis sensitivitas dan simulasi).

Poin kunci

1. Analitik keuangan: forecast, kas, kredit, fraud, kurs, investasi.
2. Regresi trend + bulan + kolom Lebaran menurunkan error 6,7% → 3,2%.
3. Lebaran maju ~11 hari/tahun — musim per bulan tidak cukup.
4. Nowcast berbasis kalender > run-rate.
5. Credit scoring: model mengurutkan, manajemen memilih cut-off.
6. Fitur sensitif (jenis kelamin) adalah keputusan kebijakan.

Studi kasus

Kasus & pembahasan

Latihan: menilai aplikasi baru dan menetapkan cut-off

Aplikasi baru: umur 25, pinjaman 24 bulan untuk usaha, tabungan rendah, sewa rumah. Menurut aturan pohon: ≤27 tahun dan pinjaman >16 bulan dengan tabungan diketahui → kelompok default 87,3% → **tolak**, atau tawarkan alternatif (tenor lebih pendek, jumlah lebih kecil, agunan).

Cut-off: misalkan rugi rata-rata per default = Rp6 juta dan laba per pembayar baik = Rp1,5 juta. Bandingkan Top 70% (35 default × 6 = Rp210 jt rugi; menolak 23 pembayar baik × 1,5 = Rp34,5 jt laba hilang) dengan Top 60% (25 × 6 = 150; 38 × 1,5 = 57). Total biaya: 244,5 vs 207 → Top 60% lebih baik pada asumsi ini.

Jika laba per pembayar baik naik, cut-off optimum bergeser ke menyetujui lebih banyak. Inilah cara menghubungkan model prediktif (minggu 4) dengan keputusan preskriptif (minggu 5).

Contoh soal dan pembahasan

Soal 1 Mudah **Nowcasting**

Sampai tanggal 10, penjualan bulan ini Rp40 M (bulan 30 hari). Data historis: pada tanggal 10 biasanya 30% penjualan bulanan sudah tercapai. Bandingkan run-rate dan nowcast berbasis kalender.

1. Run-rate = 40 × 30 ÷ 10 = 120 (anggap semua hari sama).
2. Kalender = 40 ÷ 0,30 = 133,3.
3. Selisih Rp13 M muncul karena awal bulan biasanya lebih sepi.

Jawaban: Run-rate Rp120 M; nowcast kalender Rp133 M (lebih akurat bila pola harian stabil).

Soal 2 Sedang **Memilih cut-off kredit**

Rugi per default Rp8 juta; laba per pembayar baik Rp2 juta. Top 70%: 30 default disetujui, 20 pembayar baik ditolak. Top 60%: 22 default disetujui, 35 pembayar baik ditolak. Pilih yang mana?

1. Top 70%: 30 × 8 + 20 × 2 = 240 + 40 = 280.
2. Top 60%: 22 × 8 + 35 × 2 = 176 + 70 = 246.

Jawaban: Top 60% (biaya kesalahan Rp246 juta vs Rp280 juta).

Soal 3 Mudah **MAPE**

Aktual 100, 120, 90; forecast 110, 115, 99. Hitung MAPE.

1. |error| ÷ aktual: 10/100 = 10%; 5/120 = 4,17%; 9/90 = 10%.
2. MAPE = (10 + 4,17 + 10) ÷ 3 = 8,06%.

Jawaban: MAPE ± 8,1%.

Soal 4 Sedang **Efek Lebaran dalam forecast**

Forecast dasar (trend + bulan) untuk Februari = Rp60 M. Di Februari ada 10 hari sibuk sebelum Lebaran (+1,7% per hari) dan 3 hari libur Lebaran (−3,5% per hari). Efeknya multiplikatif. Berapa forecast Februari?

1. Faktor hari sibuk = $1{,}017^{10} \approx 1{,}184$.
2. Faktor libur = $0{,}965^{3} \approx 0{,}899$.
3. Forecast = $60 \times 1{,}184 \times 0{,}899 \approx$ **Rp63,8 M**.
4. Tanpa kolom Lebaran, angka ini akan jatuh di bulan yang salah — penting untuk rencana kas dan stok.

Jawaban: ±Rp63,8 M.

Soal 5 Sedang **Metrik credit scoring dari data uji**

Logistic regression pada 250 aplikasi uji: 87 default, 163 pembayar baik. Model menangkap 53 default (ditolak) dan salah menolak 23 pembayar baik. Hitung accuracy, recall default, precision, dan tingkat default di antara yang disetujui.

1. TP = 53; FN = 87 − 53 = 34; FP = 23; TN = 163 − 23 = 140.
2. Accuracy = (53 + 140) ÷ 250 = **77,2%**. Recall = 53 ÷ 87 ≈ **60,9%**. Precision = 53 ÷ (53 + 23) ≈ **69,7%**.
3. Disetujui = FN + TN = 34 + 140 = 174. Default di antara yang disetujui = 34 ÷ 174 ≈ **19,5%** (turun dari 34,8% jika semua disetujui).

Jawaban: Accuracy 77,2%; recall 60,9%; precision 69,7%; default di antara yang disetujui 19,5%.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. Kenapa musim tetap per bulan tidak cukup untuk Lebaran?

A. Lebaran maju ±11 hari tiap tahun
B. Lebaran selalu di bulan yang sama
C. Data tidak ada
D. Karena pandemi

Jawaban: A. Kalender Hijriah.

2. Terjual 27,6 di tanggal 12; biasanya 37,5% bulan sudah tercapai. Nowcast…

A. 69,2
B. 71,3
C. 73,5
D. 80,0

Jawaban: C. 27,6 ÷ 0,375.

3. Metode yang paling banyak menangkap default di data uji…

A. Random forest
B. Logistic regression
C. Decision tree
D. Setujui semua

Jawaban: B. 53 dari 87, walau akurasinya bukan tertinggi.

---

4. Siapa yang menentukan cut-off persetujuan kredit?

A. Model
B. Manajemen, berdasarkan biaya kesalahan
C. Pelanggan
D. Regulator saja

Jawaban: B. Model mengurutkan; manajemen memutuskan batas.

---

5. Dengan biaya latihan, total biaya Top 60% adalah…

A. 184,5
B. 207
C. 244,5
D. 282

Jawaban: B. $25 \times 6 + 38 \times 1{,}5$.

Sumber

- Materi P3MD WEEK 7 — Financial Analytics (MK6)