RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 7

Financial Analytics

Di mana analitik dipakai di keuangan (forecast penjualan, perencanaan kas, credit scoring, deteksi fraud, risiko kurs, penilaian investasi). Dua kasus: (1) forecast penjualan bulanan distributor makanan dengan regresi trend + musim + kolom Lebaran, serta nowcasting; (2) credit scoring dengan logistic regression, decision tree, random forest — memilih cut-off dan isu keadilan (kolom jenis kelamin).

Materi

1 Forecast penjualan bulanan untuk anggaran 2027

Distributor makanan (fiktif; tanggal Lebaran nyata) menyusun anggaran tiap Oktober. Metode lama: salin bulan tahun lalu + pertumbuhan tahun lalu (error rata-rata 6,7% di 12 bulan uji).

Dekomposisi deret 2019–2026: trend (Rp38 → 70 M/bulan), musim (pola tahunan), dan sisa yang tidak terjelaskan — nilai terbesar jatuh di bulan Lebaran, yang **maju ~11 hari tiap tahun** (2019: 5 Juni → bulan tersibuk Mei; 2023: 22 April → April; 2024: 10 April → Maret; 2026: 20 Maret → Maret). Musim tetap per bulan tidak bisa menangkapnya.

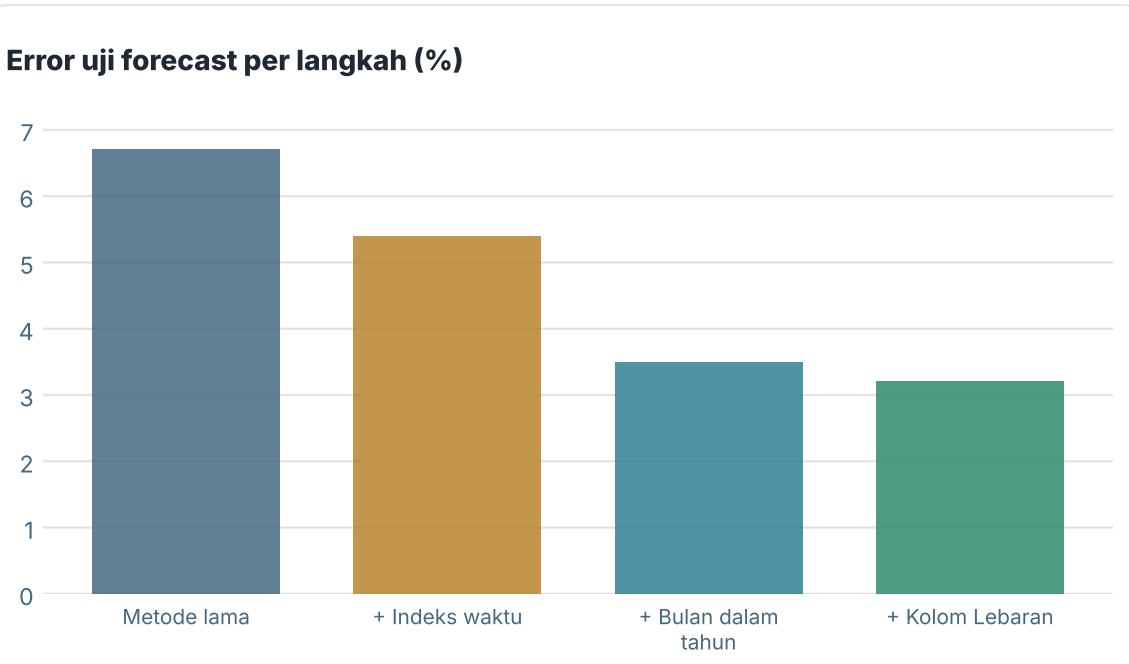
Langkah	Kolom ditambah	Menangkap	Error uji
Metode lama	—	—	6,7%
1	Indeks waktu	Pertumbuhan	5,4%
2	Bulan dalam tahun	Musim tahunan	3,5%
3	Hari sibuk sebelum Lebaran & hari libur Lebaran	Lebaran	**3,2%**

Bulan pandemi (Apr 2020–Mar 2021) diberi flag di setiap langkah. **Efek estimasi:** tiap hari sibuk sebelum Lebaran +1,7%; tiap hari libur Lebaran −3,5%; Desember +14,2% vs Januari; tiap bulan tambahan +0,6% (pertumbuhan); bulan pandemi −12,9%.

Dampaknya pada 2027 (Lebaran ~10 Maret → hari sibuk jatuh di Februari): tanpa kolom Lebaran, Feb 64,0 & Mar 78,2 (tersibuk Maret); dengan kolom Lebaran, Feb 78,0 & Mar 64,9 (tersibuk **Februari**). Tanpa kolom itu, Rp14 M ditaruh di bulan yang salah — berbahaya untuk perencanaan kas & stok. Laporkan forecast dengan rentang 80%.

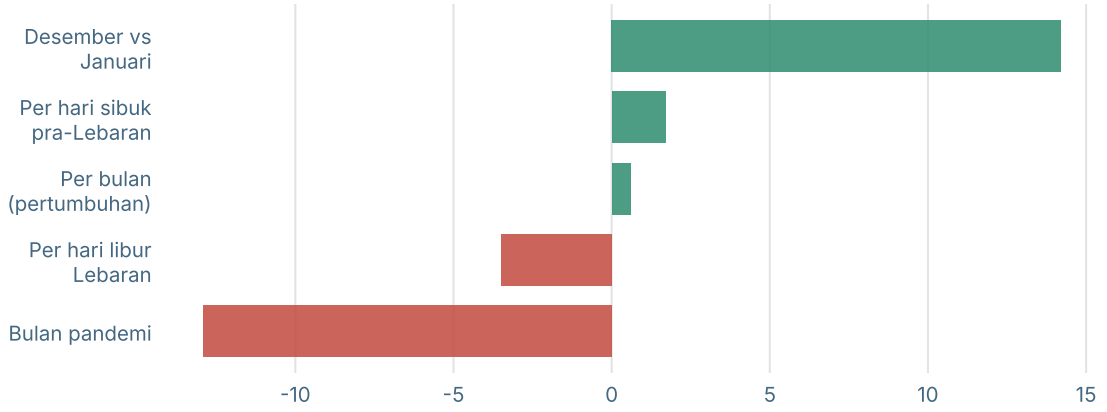
2 Forecast anggaran 2027 dalam grafik

Pendalaman

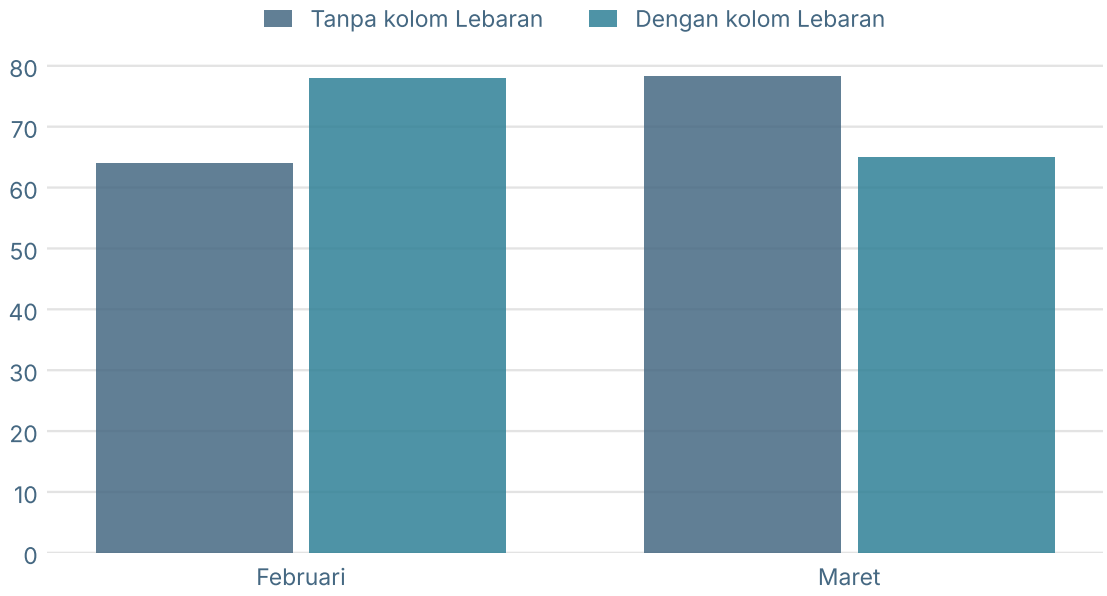


Setiap kolom tambahan memotong error: dari 6,7% (salin tahun lalu) menjadi 3,2% setelah memasukkan hari sibuk dan libur Lebaran. Lompatan terbesar datang dari pola bulanan (5,4% → 3,5%).

Efek estimasi tiap kolom (%)



Forecast Februari & Maret 2027 (Rp M)



Lebaran 2027 jatuh sekitar 10 Maret, jadi hari-hari sibuk sebelum Lebaran ada di Februari. Model tanpa kolom Lebaran menaruh puncak di Maret; model dengan kolom Lebaran memindahkannya ke Februari — selisih ±Rp14 M di bulan yang salah.

3 Nowcasting bulan berjalan

Buku tutup 10 hari setelah akhir bulan; manajemen butuh angka lebih cepat. **Nowcasting** = estimasi bulan ini dari hari yang sudah tercatat.

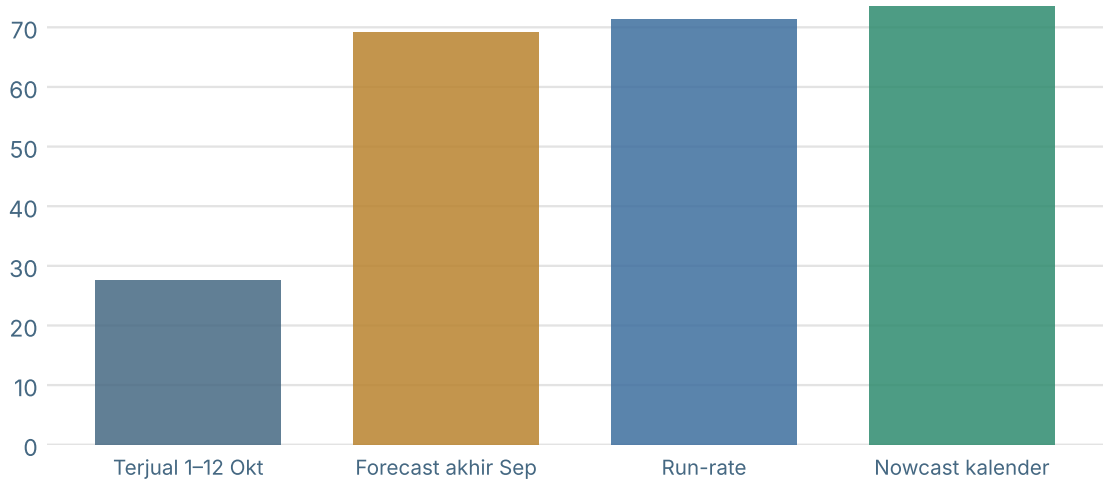
Metode (Oktober 2026, hari ke-12)	Hitungan	Rp M
Terjual 1–12 Okt		27,6
Run-rate (semua hari dianggap sama)	27,6 × 31 ÷ 12	71,3
Calendar-based (porsi bulan yang biasanya sudah tercapai)	27,6 ÷ 0,375	73,5
Forecast saja (dibuat akhir September)		69,2

Pada tanggal 12, Oktober tipikal sudah mencapai 37,5% penjualannya, bukan 38,7% (12/31 hari). Rata-rata 12 bulan uji: mulai hari ke-5, nowcast berbasis kalender mengalahkan forecast.

4 Tiga cara menebak Oktober di tanggal 12

Pendalaman

Estimasi penjualan Oktober 2026 (Rp M)



Run-rate menganggap semua hari sama (12/31 = 38,7%). Padahal pada tanggal 12, Oktober tipikal baru mencapai 37,5% penjualannya — sehingga nowcast berbasis kalender memberi angka sedikit lebih tinggi (Rp73,5 M).

5 Credit scoring

Pemberi pinjaman konsumen (fiktif) dengan 999 aplikasi: 650 lunas, 349 gagal bayar (34,9%). Gagal bayar = kehilangan pinjaman; penolakan yang salah = kehilangan pelanggan. Latih 749, uji 250.

Metode	Akurasi	Default tertangkap	Pembayar baik ditolak
Setujui semua	65,2%	0 dari 87	0 dari 163
Logistic regression	77,2%	**53** dari 87	23
Decision tree	76,0%	45	18
Random forest	**79,2%**	50	15

Random forest akurasi tertinggi; logistic paling banyak menangkap default. Pilihan bergantung pada **biaya dua jenis kesalahan** yang tidak sama (ingat critical ratio minggu 5).

Decision tree sebagai aturan (contoh): ≤27 tahun, pinjaman ≤16 bulan, tidak sewa rumah → 23,8% default → setujui; ≤27, ≤16 bulan, sewa → 75,9% → tolak; >27, ≤45 bulan, jumlah ≤11.850 → 21,0% (499 pemohon) → setujui; >27, jumlah >11.850 → 100% (6 pemohon) → tolak. Pohon bertanya umur dulu, lalu lama pinjaman.

Memilih cut-off (model mengurutkan; manajemen menentukan batas):

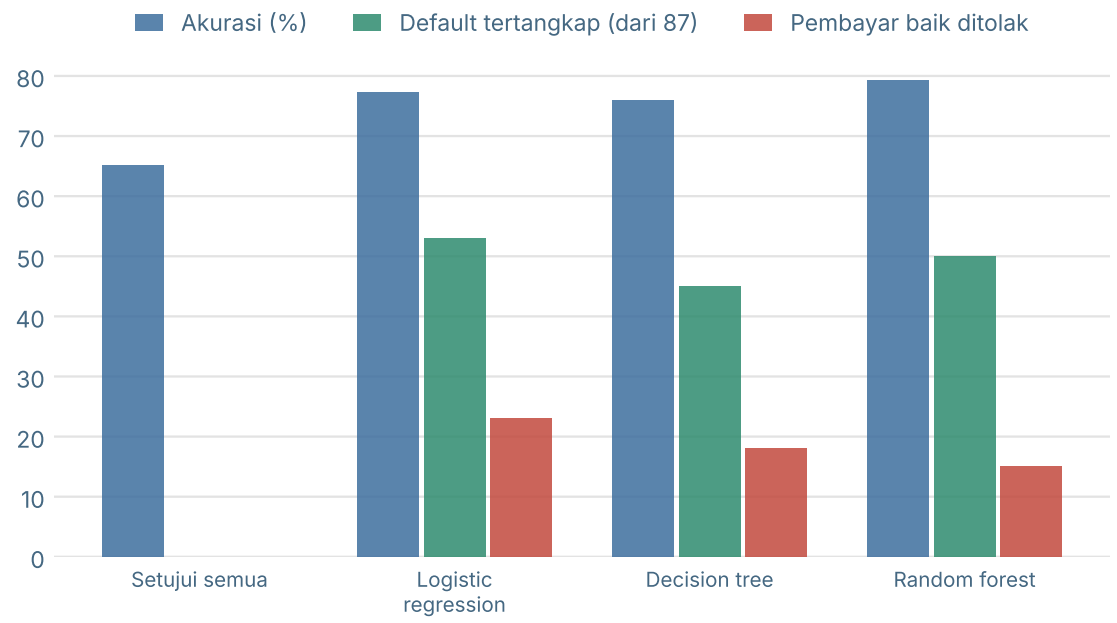
Setujui	Default di antara yang disetujui	Pembayar baik ditolak	Default disetujui
Semua	34,8%	0	87
Top 80%	22,5%	8	45
Top 70%	20,0%	23	35
Top 60%	16,7%	38	25
Top 50%	13,6%	55	17

Keadilan: default perempuan 48,9% vs laki-laki 28,7% di data ini. Dengan kolom jenis kelamin akurasi 77,2% (53 default tertangkap); tanpa itu 74,0% (49). Menyimpan kolom itu adalah *keputusan kebijakan* (etika, regulasi, risiko diskriminasi), bukan keputusan teknis. Catatan: PNS punya default tertinggi tapi hanya 17 pemohon — terlalu sedikit untuk disimpulkan.

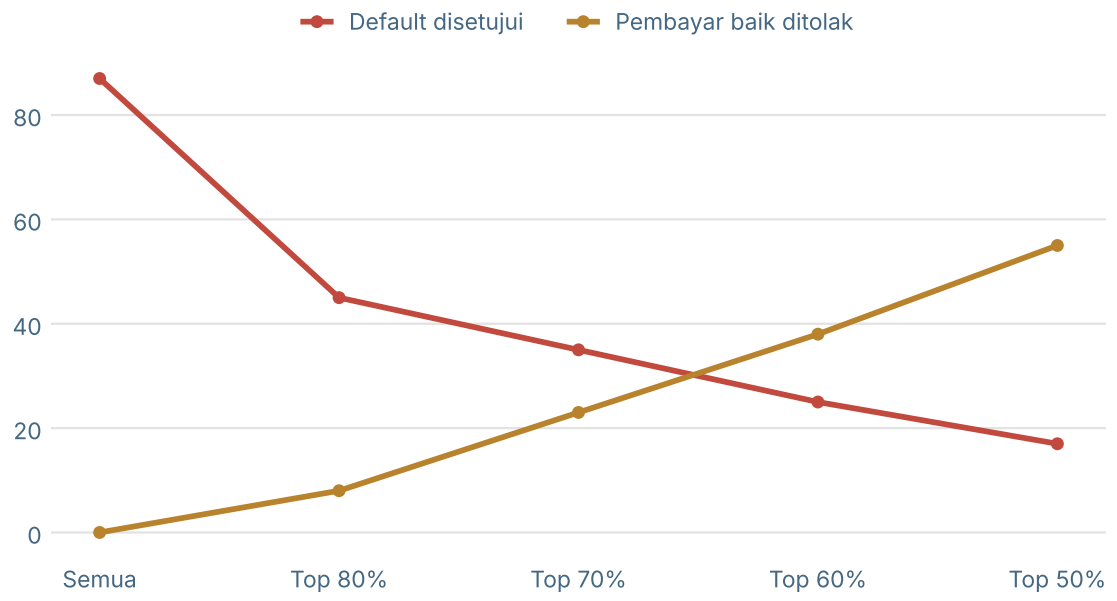
6 Credit scoring: metode dan cut-off dalam grafik

Pendalaman

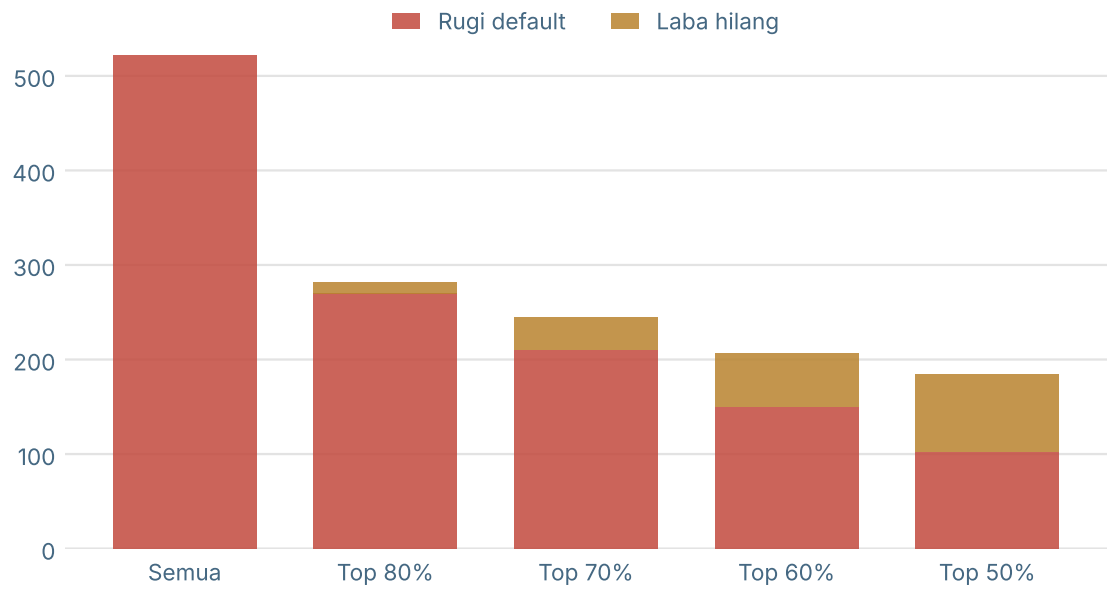
Perbandingan metode (250 data uji)



Trade-off cut-off



Total biaya kesalahan (Rp jt; default Rp6 jt, pembayar baik Rp1,5 jt)



Dengan asumsi latihan (rugi Rp6 jt per default, laba Rp1,5 jt per pembayar baik), Top 60% (Rp207 jt) memang lebih baik dari Top 70% (Rp244,5 jt) — dan kalau tabel diteruskan, **Top 50% bahkan lebih murah lagi (Rp184,5 jt)**. Cut-off optimum sangat bergantung pada rasio dua biaya kesalahan; jika laba per pembayar baik naik, cut-off bergeser ke menyetujui lebih banyak.

Keadilan

Default perempuan 48,9% vs laki-laki 28,7% di data ini. Kolom jenis kelamin menaikkan akurasi (77,2% vs 74,0%), tetapi memakainya adalah keputusan etis dan hukum, bukan sekadar teknis.

Poin kunci

1. Analitik keuangan: forecast, kas, kredit, fraud, kurs, investasi.
2. Regresi trend + bulan + kolom Lebaran menurunkan error 6,7% → 3,2%.
3. Lebaran maju ~11 hari/tahun — musim per bulan tidak cukup.
4. Nowcast berbasis kalender > run-rate.
5. Credit scoring: model mengurutkan, manajemen memilih cut-off.
6. Fitur sensitif (jenis kelamin) adalah keputusan kebijakan.

Studi kasus

Kasus & pembahasan

Latihan: menilai aplikasi baru dan menetapkan cut-off

Aplikasi baru: umur 25, pinjaman 24 bulan untuk usaha, tabungan rendah, sewa rumah. Menurut aturan pohon: ≤27 tahun dan pinjaman >16 bulan dengan tabungan diketahui → kelompok default 87,3% → **tolak**, atau tawarkan alternatif (tenor lebih pendek, jumlah lebih kecil, agunan).

Cut-off: misalkan rugi rata-rata per default = Rp6 juta dan laba per pembayar baik = Rp1,5 juta. Bandingkan Top 70% (35 default × 6 = Rp210 jt rugi; menolak 23 pembayar baik × 1,5 = Rp34,5 jt laba hilang) dengan Top 60% (25 × 6 = 150; 38 × 1,5 = 57). Total biaya: 244,5 vs 207 → Top 60% lebih baik pada asumsi ini. Jika laba per pembayar baik naik, cut-off optimum bergeser ke menyetujui lebih banyak. Inilah cara menghubungkan model prediktif (minggu 4) dengan keputusan preskriptif (minggu 5).

Contoh soal dan pembahasan

Soal 1 · Mudah · **Nowcasting**

Sampai tanggal 10, penjualan bulan ini Rp40 M (bulan 30 hari). Data historis: pada tanggal 10 biasanya 30% penjualan bulanan sudah tercapai. Bandingkan run-rate dan nowcast berbasis kalender.

1. Run-rate = 40 × 30 ÷ 10 = 120 (anggap semua hari sama).
2. Kalender = 40 ÷ 0,30 = 133,3.
3. Selisih Rp13 M muncul karena awal bulan biasanya lebih sepi.

Jawaban: Run-rate Rp120 M; nowcast kalender Rp133 M (lebih akurat bila pola harian stabil).

Soal 2 · Sedang · **Memilih cut-off kredit**

Rugi per default Rp8 juta; laba per pembayar baik Rp2 juta. Top 70%: 30 default disetujui, 20 pembayar baik ditolak. Top 60%: 22 default disetujui, 35 pembayar baik ditolak. Pilih yang mana?

1. Top 70%: 30 × 8 + 20 × 2 = 240 + 40 = 280.
2. Top 60%: 22 × 8 + 35 × 2 = 176 + 70 = 246.

Jawaban: Top 60% (biaya kesalahan Rp246 juta vs Rp280 juta).

Soal 3 Mudah **MAPE**

Aktual 100, 120, 90; forecast 110, 115, 99. Hitung MAPE.

1. |error| ÷ aktual: 10/100 = 10%; 5/120 = 4,17%; 9/90 = 10%.
2. MAPE = (10 + 4,17 + 10) ÷ 3 = 8,06%.

Jawaban: MAPE ± 8,1%.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. Kenapa musim tetap per bulan tidak cukup untuk Lebaran?

A. Lebaran maju ±11 hari tiap tahun
B. Lebaran selalu di bulan yang sama
C. Data tidak ada
D. Karena pandemi

Jawaban: A. Kalender Hijriah.

2. Terjual 27,6 di tanggal 12; biasanya 37,5% bulan sudah tercapai. Nowcast...

A. 69,2
B. 71,3
C. 73,5
D. 80,0

Jawaban: C. 27,6 ÷ 0,375.

3. Metode yang paling banyak menangkap default di data uji...

A. Random forest
B. Logistic regression
C. Decision tree
D. Setujui semua

Jawaban: B. 53 dari 87, walau akurasinya bukan tertinggi.

4. Siapa yang menentukan cut-off persetujuan kredit?

A. Model
B. Manajemen, berdasarkan biaya kesalahan
C. Pelanggan
D. Regulator saja

Jawaban: B. Model mengurutkan; manajemen memutuskan batas.

---

5. Dengan biaya latihan, total biaya Top 60% adalah…

A. 184,5
B. 207
C. 244,5
D. 282

Jawaban: B. 25 × 6 + 38 × 1,5.

Sumber

- Materi P3MD WEEK 7 — Financial Analytics (MK6)