RANGKUMAN · MK 6 BUSINESS ANALYTICS · MINGGU 10

Advanced Analytics: Big Data Analytics

Minggu ini masuk ke analitik lanjutan pertama: big data. Data disebut big data bukan karena ukuran tertentu, tetapi karena melebihi kemampuan alat konvensional (spreadsheet, membaca manual). Ciri-cirinya empat V: volume, velocity, variety, dan veracity. Internet adalah sumber big data utama, dengan manfaat kecepatan, cakupan murah, suara pelanggan yang tidak diminta, dan peringatan dini (contoh: Google Flu Trends, Billion Prices Project, ulasan Yelp di Boston, PetaBencana.id). Karena data internet besar, tidak terstruktur, dan kotor, dibutuhkan metode berbeda. Studi kasusnya 11.488 posting tentang BrandX (fiktif) pada September 2026, dianalisis dengan tiga metode: analisis sentimen (lexicon vs IndoBERT), topic modeling dengan BERTopic, dan social network analysis (in-degree, betweenness, komunitas). Setiap hasil dibaca dengan baseline, tren, alasan, dan kemungkinan salah.

Materi

1 Apa itu big data, dan empat V

Big data adalah data yang terlalu besar, terlalu cepat, terlalu beragam, atau terlalu tidak pasti untuk alat konvensional seperti spreadsheet dan membaca manual.

Data

500 jawaban survei: muat di satu spreadsheet, bisa dibaca kurang dari dua jam.

vs

Big data

2.000.000 posting tentang satu merek dalam sebulan: butuh **231 hari** membaca tanpa henti (2.000.000 × 10 detik = 20 juta detik).

Kuncinya

Data menjadi big data ketika melebihi kemampuan alat atau orang biasa, bukan pada ukuran tertentu.

V	Pertanyaan	Contoh media sosial	Penjelasan
Volume	Berapa banyak data dihasilkan?	Jutaan posting	Satu worksheet Excel maksimal 1.048.576 baris. Aplikasi belanja dengan 1 juta pengguna harian × 50 klik = 50 juta baris per hari ≈ 48 worksheet.
Velocity	Seberapa cepat data datang?	Posting baru setiap detik	Keluhan naik di hari ke-3; laporan bulanan baru melihatnya 27 hari kemudian, data media sosial melihatnya dalam hitungan menit.
Variety	Berapa banyak bentuk data?	Teks, gambar, video	Sebagian besar big data tidak terstruktur. Membaca 10.000 posting × 10 detik = ±28 jam.
Veracity	Seberapa bisa dipercaya?	Bot, spam, duplikat	Data internet harus disaring dan dicek sebelum dianalisis.

	Terstruktur	Tidak terstruktur
Bentuk	Baris dan kolom	Teks bebas, gambar, video, interaksi
Contoh	Pesanan online, page view	Posting, ulasan, foto, video
Analisis	Query dan statistik	Text mining, network analysis

Empat masalah veracity (contoh posting yang harus dibuang sebelum menganalisis opini tentang BrandX):

Spam atau bot

"PROMO!!! Klik link ini, voucher BrandX 1 juta" — diposting otomatis, bukan oleh pelanggan.

Duplikat

"Pengiriman BrandX lambat, jangan belanja di sini" — teks sama diposting 40 akun.

Tidak relevan

"Nonton konser BrandX Band semalam, keren" — nama sama, subjek berbeda.

Ulasan palsu

"Produk terbaik!!! Recommended seller, bintang 5" — ditulis akun yang baru dibuat hari ini.

2 Internet sebagai sumber big data: manfaat dan contoh

Setiap pencarian, klik, ulasan, dan posting di internet meninggalkan jejak. Sumbernya: media sosial (posting, komentar, share), e-commerce (produk, harga, pesanan), ulasan online (rating), berita online (artikel, komentar), mesin pencari (query), dan platform video (video, komentar). Sebagian besar publik dan bisa dikumpulkan dengan kata kunci.

Manfaat	Contoh	Data → analisis → hasil	Pelajaran
Kecepatan: sinyal muncul sebelum statistik resmi	Google Flu Trends	Jutaan pencarian gejala flu di AS → dibandingkan dengan laporan flu resmi per wilayah → aktivitas flu diperkirakan 1–2 minggu lebih awal. Tetapi di 2013 perkiraannya lebih dari dua kali angka resmi.	Volume dan velocity membuatnya cepat; veracity yang lemah membuatnya tidak akurat.
Cakupan murah: jutaan observasi tanpa tim survei	Billion Prices Project	Harga jutaan produk dikumpulkan harian dari situs ritel online → indeks inflasi harian → di Argentina, inflasi harga online jauh di atas angka resmi.	Situs web menggantikan tim survei harga; indeks diperbarui setiap hari.

Suara yang tidak diminta: opini pelanggan tanpa ditanya	Boston dan Yelp	Ulasan restoran Yelp di Boston (2015) → model mempelajari kata yang menandakan masalah kebersihan → inspektur mendatangi lebih dulu restoran yang paling mungkin gagal inspeksi.	Teks tidak terstruktur yang dianalisis dalam skala besar mengarahkan kerja inspektur.
Peringatan dini: kejadian dilaporkan saat terjadi	PetaBencana.id	Laporan banjir warga Jakarta di media sosial → dicek dan dipetakan saat masuk → peta banjir real-time untuk warga dan BPBD DKI.	Laporan masuk dalam hitungan menit, lebih cepat dari survei mana pun.

Kenapa big data butuh metode berbeda:

	Data konvensional	Data internet	Metode yang dibutuhkan
Jumlah	Ratusan baris	Jutaan posting	Pemrosesan otomatis
Struktur	Baris dan kolom	Teks dan interaksi	Text mining, network analysis
Kualitas	Dicek saat diinput	Bot, spam, duplikat	Penyaringan dan pengecekan

Setiap posting membawa dua jenis data: **teks** (apa yang dikatakan → text mining) dan **interaksi** (siapa merespons siapa → network analysis).

Kumpulkan: posting yang cocok dengan kata kunci

→ Konversi: teks jadi angka yang bisa dibaca model

→ Analisis: sentimen dan topik

Text mining mengubah teks tidak terstruktur menjadi data terstruktur yang bisa dihitung dan dimodelkan.

3 Kasus BrandX dan analisis sentimen

Kasus: BrandX menjual produk konsumen secara online. Posting yang menyebut BrandX di X, Instagram, TikTok, dan Google Maps dikumpulkan dengan kata kunci selama September 2026: **11.488 posting** berbahasa Indonesia. Merek, akun, dan semua data fiktif.

Metode	Pertanyaan
Analisis sentimen	Bagaimana perasaan pelanggan?
Topic modeling (BERTopic)	Apa yang mereka bicarakan?
Social network analysis	Siapa yang menyebarkan percakapan?

Motivasi: membaca 11.488 posting × 10 detik = **32 jam**. Analisis sentimen memberi label setiap posting secara otomatis: **positif, netral, atau negatif**.

Posting	Sentimen
Kurirnya ramah, paket sampai dengan aman	Positif
Estimasi pengiriman ke Medan berapa hari ya?	Netral
Chat CS dari kemarin gak dibalas	Negatif

Berbasis leksikon

Menjumlahkan skor kata yang ada di kamus sentimen. **Kelebihan:** transparan, tidak butuh data berlabel. **Kelemahan:** gagal membaca negasi, sarkasme, dan slang.

vs

Machine learning

Model belajar dari posting yang dilabeli manusia. **Kelebihan:** membaca setiap kata dalam konteks kalimat. **Kelemahan:** butuh data berlabel, lebih sulit dijelaskan.

Skoring leksikon: bagus +1, cepat +1, ramah +1, lambat −1, rusak −1, kecewa −1. Skor > 0 = positif, 0 = netral, < 0 = negatif.

Posting	Skor	Label
pengiriman cepat dan barang bagus	+1 +1 = +2	Positif

pengiriman cepat tapi barangnya rusak	+1 −1 = 0	Netral (manusia akan menyebutnya negatif)
promonya bagus, pengirimannya cepat, tapi cs lambat	+1 +1 −1 = +1	Positif

Batasan leksikon	Contoh	Hasil yang salah
Negasi	pelayanannya tidak ramah	+1 → positif
Sarkasme	mantap, paketnya cuma telat seminggu	0 → netral
Slang	pengirimannya cpt bgt	0 → "cpt" tidak ada di kamus

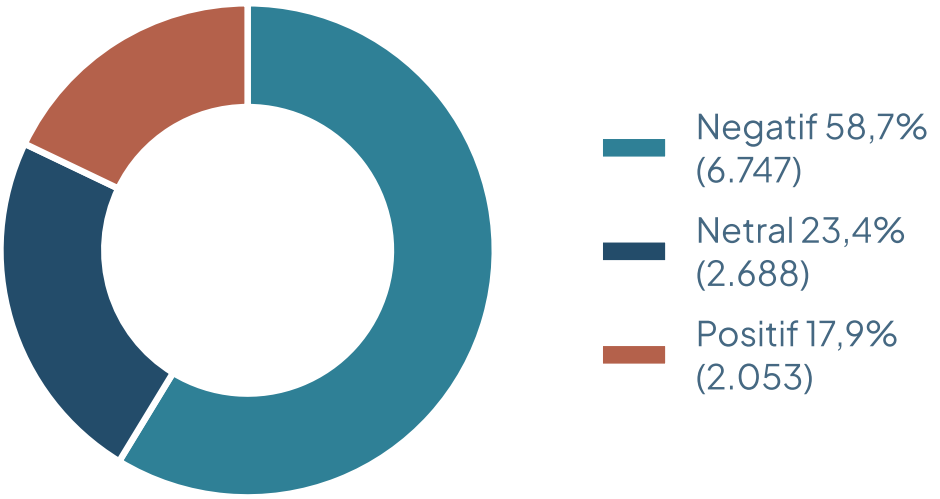
Leksikon membaca kata satu per satu, tidak membaca konteks. Karena itu dipakai **IndoBERT**:

1. **Model:** model bahasa transformer yang dilatih awal (pre-trained) dengan kumpulan besar teks berbahasa Indonesia.
2. **Fine-tuning:** dilatih lagi dengan posting yang sudah dilabeli positif, netral, atau negatif.
3. **Prediksi:** untuk posting baru, model memberi label beserta peluangnya, dengan membaca setiap kata dalam konteks kalimat.

Posting	Label IndoBERT	Peluang
CS @BrandX lambat banget balasnya	Negatif	0,95
Barang sampai aman, makasih @BrandX	Positif	0,97
@BrandX ada promo akhir bulan gak?	Netral	0,92
mantap, paketnya cuma telat seminggu	Negatif	0,64

Posting sarkastik yang diberi skor 0 oleh leksikon kini dilabeli negatif, walau dengan peluang lebih rendah (0,64).

Sentimen 11.488 posting BrandX (IndoBERT)



Lebih dari separuh posting negatif. Tinggi atau rendahnya baru bermakna jika dibandingkan baseline.

Hasil: negatif **58,7%** (6.747), netral 23,4% (2.688), positif 17,9% (2.053). Lebih dari separuh posting negatif.

Cara membaca	Penjelasan
Baseline	58,7% negatif tinggi atau rendah hanya bila dibandingkan: hari lain, bulan lain, atau pesaing.
Tren	Porsi negatif yang naik menunjukkan kapan keluhan membesar. Tanggal 18 September: 75% negatif vs 54% di hari lain → saat keluhan menjadi krisis.
Alasan	Sentimen menunjukkan perasaan, bukan penyebab. Penyebabnya dicari dengan topic modeling.
Kesalahan	Label adalah prediksi. Cek sampel posting, mulai dari yang peluangnya rendah.

! **Apa yang tidak bisa disimpulkan dari sentimen saja**

Bahwa sebagian besar keluhan soal pengiriman (perlu topik), bahwa penjualan turun (tidak ada data penjualan), atau bahwa semua posting

negatif dari pelanggan asli (perlu cek veracity). Yang bisa: 18 September lebih negatif dari biasanya.

4 Topic modeling dengan BERTopic

Motivasi: ada 6.747 posting negatif. Masalah apa yang diangkat pelanggan, mana yang paling sering, dan mana yang harus diperbaiki dulu? Topic modeling menemukan tema tanpa membaca setiap posting.

Topic modeling adalah metode *unsupervised* yang mengelompokkan dokumen ke dalam topik berdasarkan kemiripan isi. Tidak butuh label: topiknya ditemukan dari data. Contoh: "paket belum sampai, kurir lambat" dan "resi tidak bergerak sejak senin" → topik 1 (paket, kurir, resi, sampai); "refund belum masuk ke saldo" dan "dana retur dijanjikan tiga hari" → topik 2 (refund, dana, retur, saldo).

Embed: posting jadi embedding → Reduce: UMAP mengurangi dimensi

→ Cluster: HDBSCAN mengelompokkan posting mirip

→ Describe: c-TF-IDF mencari kata khas

Posting yang tidak masuk klaster mana pun diklasifikasikan sebagai **outlier**.

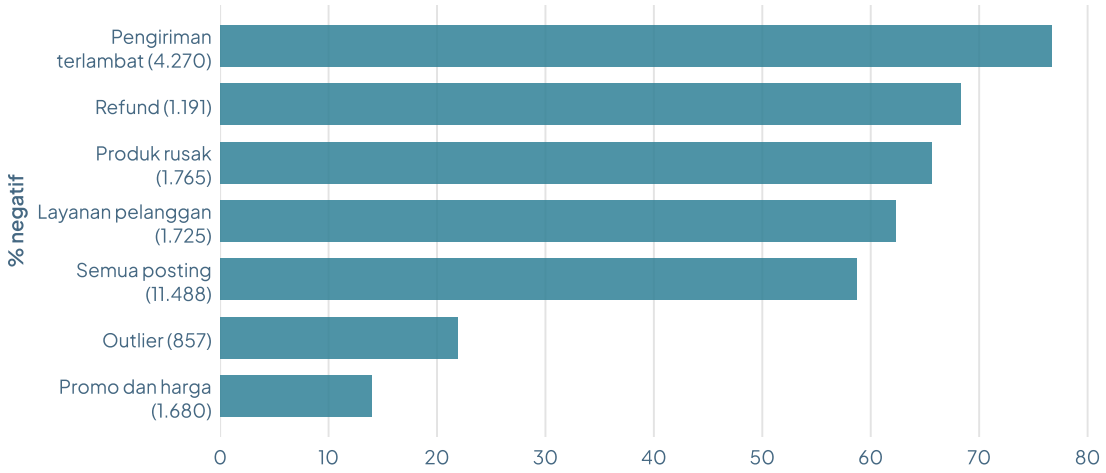
Apa itu embedding?
Vektor angka yang mewakili *makna* sebuah posting. Posting yang maknanya mirip letaknya berdekatan, walau kata-katanya berbeda. Contoh: "barangnya rusak pas dibuka" dan "produknya cacat, beda sama foto" berdekatan (keduanya produk rusak), sedangkan "admin gak bales chat dari pagi" jauh (layanan pelanggan).

Topik	Kata khas	Posting	Porsi	Negatif
Pengiriman terlambat	kirim, telat, kurir, paket, resi	4.270	37,2%	76,7%
Produk rusak	rusak, barang, sesuai, cacat, foto	1.765	15,4%	65,6%

Layanan pelanggan	cs, balas, chat, lambat, admin	1.725	15,0%	62,3%
Promo dan harga	promo, diskon, voucher, harga, murah	1.680	14,6%	14,0%
Refund	refund, dana, retur, proses, saldo	1.191	10,4%	68,3%
Outlier	tidak ada tema tunggal	857	7,5%	21,9%

Nama topik diberikan analis setelah membaca kata-kata khasnya. Setiap posting masuk satu topik atau outlier.

Porsi posting negatif per topik (%)



Empat topik di atas rata-rata 58,7%. Pengiriman terlambat paling besar dan paling negatif.

Cara membaca	Penjelasan
Ukuran	Porsi posting menunjukkan seberapa luas masalah dibicarakan. Pengiriman terlambat 37,2%.
Sentimen	Bandingkan porsi negatif tiap topik dengan 58,7% (semua posting) untuk tahu masalah mana yang paling merugikan merek.
Nama	Nama topik adalah tafsiran analis; dicek dengan contoh posting.
Outlier	7,5% posting di luar semua topik bisa menyimpan isu baru yang masih kecil.

Kesimpulan

Empat dari lima topik lebih negatif dari percakapan secara keseluruhan. Pengiriman terlambat adalah topik terbesar *dan* paling negatif: masalah pertama yang harus ditangani. Promo dan harga justru jauh lebih positif (14% negatif).

5 Social network analysis

Motivasi: sentimen dan topik menunjukkan *apa* yang dikatakan, bukan *siapa* yang menyebarkannya. Contoh: posting u07 "Paket belum sampai, @BrandX gimana?" di-retweet atau di-mention 0 akun; posting Influencer dengan isi mirip di-retweet atau di-mention 10 akun. Siapa yang menyebarkan keluhan paling jauh? Siapa yang menghubungkan kelompok yang terpisah? Apakah balasan merek sampai ke para pengkritik?

Unsur	Arti
Node	Akun: pelanggan, merek, influencer, atau media berita
Edge	Retweet, mention, atau reply, berarah dari akun yang merespons ke akun yang memposting

Ukuran (dari Week 9)	Arti
In-degree	Seberapa sering akun di-retweet atau di-mention
Betweenness	Seberapa sering akun berada di jalur terpendek antar akun lain (menjadi jembatan)
Komunitas	Kelompok akun yang kebanyakan berinteraksi satu sama lain

Jaringan retweet BrandX: 23 akun, 29 edge berarah (ukuran node = in-degree; pengguna dianonimkan).

Akun	In-degree	Betweenness
Influencer	**10**	0,57
BrandX	7	0,44

News	6	**0,68**

Komunitas (algoritma Leiden, modularity 0,50): komunitas 1 = 9 dari 10 akun negatif (pengkritik, berpusat di Influencer); komunitas 2 = 7 dari 8 positif (pendukung, berpusat di BrandX); komunitas 3 = 5 dari 5 netral (pembaca berita).

Cara membaca	Penjelasan
In-degree	Influencer (10) paling sering di-retweet: keluhannya menjangkau paling banyak akun.
Betweenness	News (0,68) menghubungkan kelompok-kelompok: informasi berpindah antar komunitas lewat akun ini.
Komunitas	Pengkritik, pendukung, dan pembaca berita membentuk kelompok terpisah yang melihat posting berbeda.
Edge yang hilang	Tidak ada edge langsung antara BrandX dan komunitas pengkritik: balasan BrandX tidak sampai ke mereka.

! **Implikasi bisnis**

BrandX hanya "berbicara" dengan pendukungnya sendiri. Satu-satunya jalur ke pengkritik melalui News. Langkah yang masuk akal: membalas langsung keluhan Influencer dan pengkritik utama, dan memberi klarifikasi ke media berita sebagai jembatan.

Praktik di SocialX Studio (socialx.id): (1) pilih sumber data (X, Instagram, TikTok, atau berita online); (2) masukkan kata kunci, misalnya nama merek; (3) kumpulkan posting yang cocok; (4) jalankan analisis sentimen (IndoBERT); (5) jalankan topic modeling (BERTopic); (6) jalankan social network analysis.

Poin kunci

1. Big data = data yang melebihi kemampuan alat atau orang biasa, bukan ukuran tertentu.
2. Empat V: volume (jumlah), velocity (kecepatan), variety (bentuk), veracity (bisa dipercaya).
3. Satu worksheet Excel = 1.048.576 baris; 50 juta klik per hari ≈ 48 worksheet.
4. Sebagian besar big data tidak terstruktur (teks, gambar, video, interaksi) → butuh text mining dan network analysis.
5. Masalah veracity: spam/bot, duplikat, tidak relevan, ulasan palsu → saring sebelum analisis.
6. Manfaat data internet: kecepatan (Google Flu Trends), cakupan murah (Billion Prices Project), suara tidak diminta (Yelp Boston), peringatan dini (PetaBencana.id).
7. Google Flu Trends: cepat karena volume dan velocity, tidak akurat karena veracity lemah (2013 lebih dari dua kali angka resmi).
8. Sentimen: leksikon (transparan, gagal pada negasi, sarkasme, slang) vs machine learning seperti IndoBERT (membaca konteks, butuh data berlabel).
9. BrandX: 58,7% negatif; baca dengan baseline, tren (18 September 75%), alasan (topik), dan kesalahan (cek sampel).
10. BERTopic: embed → UMAP → HDBSCAN → c-TF-IDF; unsupervised; outlier bisa menyimpan isu baru.
11. Pengiriman terlambat: topik terbesar (37,2%) dan paling negatif (76,7%) → prioritas pertama.
12. SNA: node = akun, edge = retweet/mention/reply. In-degree = jangkauan, betweenness = jembatan, komunitas = kelompok. BrandX tidak terhubung langsung ke pengkritik.

Studi kasus

Kasus & pembahasan

Latihan: dari 11.488 posting ke rencana aksi BrandX

Latihan menggabungkan tiga metode; angka dari slide, rekomendasi adalah analisis. Direksi BrandX bertanya: "Apa yang harus kita lakukan minggu ini?"

1. **Bersihkan data (veracity):** buang spam/bot, duplikat (misalnya teks sama dari 40 akun), posting tidak relevan (BrandX Band, BrandX FC), dan ulasan palsu sebelum menghitung apa pun.
2. **Sentimen:** 58,7% negatif. Bandingkan dengan baseline bulan lalu atau pesaing. Lonjakan 18 September (75% vs 54%) menandai kapan keluhan menjadi krisis; baca posting hari itu untuk tahu pemicunya.
3. **Topik:** pengiriman terlambat terbesar (37,2%) dan paling negatif (76,7%) → prioritas 1. Refund (68,3%) dan produk rusak (65,6%) berikutnya. Promo dan harga tidak bermasalah (14%). Cek outlier 7,5% untuk isu baru.
4. **Jaringan:** Influencer (in-degree 10) menyebarkan keluhan paling jauh; News (betweenness 0,68) adalah jembatan; tidak ada edge BrandX ke komunitas pengkritik.
5. **Rencana aksi:** (a) perbaiki SLA kurir dan beri update resi proaktif; (b) percepat proses refund dan umumkan target waktunya; (c) tim CS membalas langsung posting Influencer dan pengkritik, bukan hanya pendukung; (d) beri klarifikasi ke media berita.
6. **Ukur ulang:** pantau porsi negatif topik pengiriman dan apakah BrandX kini punya edge langsung ke komunitas pengkritik bulan depan.

Contoh soal dan pembahasan

Soal 1 · Mudah **Volume: berapa worksheet?**

Aplikasi belanja punya 1 juta pengguna harian; setiap pengguna menghasilkan 50 klik. Satu worksheet Excel maksimal 1.048.576 baris. Berapa worksheet untuk data satu hari, dan untuk satu bulan (30 hari)?

1. `Jumlah worksheet = baris data ÷ 1.048.576`
2. Baris per hari = 1.000.000 × 50 = 50.000.000
3. Worksheet per hari = 50.000.000 ÷ 1.048.576 = 47,7 → 48
4. Per bulan = 50.000.000 × 30 = 1,5 miliar baris ÷ 1.048.576 = 1.431 worksheet

Jawaban: ±48 worksheet per hari; ±1.431 per bulan. Jelas butuh alat big data, bukan spreadsheet.

Soal 2 Mudah **Waktu membaca manual**

Berapa lama membaca (a) 10.000 posting, (b) 11.488 posting BrandX, dan (c) 2.000.000 posting, jika satu posting butuh 10 detik dan membaca tanpa henti?

1.
```
Waktu = jumlah posting × 10 detik
```
2. (a) 10.000 × 10 = 100.000 detik ÷ 3.600 = 27,8 jam ≈ 28 jam
3. (b) 11.488 × 10 = 114.880 detik ÷ 3.600 = 31,9 jam ≈ 32 jam
4. (c) 2.000.000 × 10 = 20.000.000 detik ÷ 86.400 = 231 hari

Jawaban: ±28 jam, ±32 jam, dan ±231 hari. Karena itu pelabelan otomatis dibutuhkan.

Soal 3 Mudah **Skor sentimen leksikon**

Leksikon: bagus +1, cepat +1, ramah +1, lambat −1, rusak −1, kecewa −1. Hitung skor dan label: (a) "kurirnya ramah tapi barangnya rusak, kecewa"; (b) "pengiriman cepat, barang bagus, cs ramah"; (c) "pelayanannya tidak ramah". Mana yang salah dibaca leksikon?

1. ```
   Skor = Σ skor kata · > 0 positif, 0 netral, < 0 negatif
   ```
2. (a) ramah +1, rusak −1, kecewa −1 = −1 → negatif
3. (b) cepat +1, bagus +1, ramah +1 = +3 → positif
4. (c) ramah +1 = +1 → positif, padahal maknanya negatif (negasi "tidak" tidak terbaca)

Jawaban: (a) −1 negatif; (b) +3 positif; (c) +1 positif tetapi salah: contoh kelemahan negasi.
   ```

Soal 4 Sedang **Porsi dan jumlah posting negatif per topik**

Dari tabel topik BrandX, hitung jumlah posting negatif untuk pengiriman terlambat (4.270; 76,7%), refund (1.191; 68,3%), dan promo (1.680; 14,0%). Lalu cek: apakah total negatif semua topik cocok dengan 6.747?

1. `Posting negatif = jumlah posting topik × porsi negatif`
2. Pengiriman: 4.270 × 0,767 = 3.275
3. Refund: 1.191 × 0,683 = 813; Promo: 1.680 × 0,140 = 235
4. Lainnya: produk rusak 1.765 × 0,656 = 1.158; CS 1.725 × 0,623 = 1.075; outlier 857 × 0,219 = 188
5. Total = 3.275 + 1.158 + 1.075 + 235 + 813 + 188 = 6.744 ≈ 6.747 (selisih karena pembulatan persen)

Jawaban: Pengiriman 3.275 negatif (hampir separuh dari semua keluhan negatif); total cocok ±6.747.

Soal 5 Sedang **Menghitung in-degree**

Edge retweet berarah (dari yang me-retweet ke yang diposting): A→C, B→C, D→C, E→C, C→F, D→F, E→D. Hitung in-degree setiap akun. Akun mana paling berpengaruh dalam jangkauan?

1. ```
   In-degree = jumlah panah yang masuk ke akun
   ```
2. C: dari A, B, D, E = 4
3. F: dari C, D = 2
4. D: dari E = 1
5. A, B, E: 0

Jawaban: C punya in-degree tertinggi (4): paling sering di-retweet, jangkauannya paling luas. C juga menyambungkan A/B ke F, jadi berpotensi jadi jembatan.

Latihan soal

Coba jawab dulu, kunci jawaban ada di bawah tiap soal.

1. Data menjadi big data ketika…

A. Melebihi 1 juta baris
B. Melebihi kemampuan alat atau orang biasa untuk menanganinya
C. Disimpan di cloud
D. Berasal dari internet

Jawaban: B. Bukan ukuran tertentu, tetapi melebihi kemampuan alat konvensional.
   ```

2. Mana yang tidak lagi muat di satu worksheet Excel (1.048.576 baris)?

A. Data 300 karyawan
B. 50.000 ulasan produk
C. 2.000.000 posting tentang satu merek
D. 1.000 jawaban survei

Jawaban: C. 2 juta > 1.048.576 baris.

---

3. Mana yang harus dianalisis dalam hitungan menit (velocity)?

A. Laporan tahunan tahun lalu
B. Keluhan yang menyebar di media sosial
C. Angka penjualan kuartalan
D. Survei pelanggan tahunan

Jawaban: B. Keluhan bisa menjadi krisis dalam hitungan jam.

---

4. Mana contoh data tidak terstruktur?

A. Pesanan online: nomor, produk, harga
B. Ulasan produk di marketplace
C. Page view harian per halaman
D. Tabel stok gudang

Jawaban: B. Ulasan dan foto pembeli tidak punya baris dan kolom yang ditentukan.

---

5. "Gratis pulsa 100rb! Follow dan RT akun ini #BrandX" sebaiknya dibuang karena masalah…

A. Volume
B. Velocity
C. Variety
D. Veracity (spam/bot)

Jawaban: D. Bukan opini pelanggan tentang BrandX.

---

6. Pelajaran dari Google Flu Trends adalah…

A. Big data selalu akurat
B. Cepat karena volume dan velocity, tetapi tidak akurat karena veracity lemah
C. Pencarian tidak berhubungan dengan flu
D. Data resmi selalu terlambat 1 tahun

Jawaban: B. Di 2013 perkiraannya lebih dari dua kali angka resmi.

---

7. PetaBencana.id adalah contoh manfaat data internet berupa…

A. Cakupan murah
B. Peringatan dini
C. Suara yang tidak diminta
D. Penghematan pajak

Jawaban: B. Laporan banjir warga masuk dalam hitungan menit dan dipetakan real-time.

---

8. Billion Prices Project menunjukkan bahwa…

A. Harga online selalu lebih murah
B. Situs web bisa menggantikan tim survei harga, dan inflasi online Argentina jauh di atas angka resmi
C. Inflasi tidak bisa diukur
D. Survei manual lebih cepat

Jawaban: B. Contoh cakupan murah.

---

9. Kelemahan analisis sentimen berbasis leksikon adalah…

A. Butuh data berlabel
B. Gagal membaca negasi, sarkasme, dan slang
C. Sulit dijelaskan
D. Terlalu lambat

Jawaban: B. Leksikon membaca kata satu per satu, bukan konteks.

---

10. Leksikon: bagus +1, cepat +1, lambat −1. "promonya bagus, pengirimannya cepat, tapi cs lambat" mendapat…

A. −1, negatif
B. 0, netral
C. +1, positif
D. +3, positif

Jawaban: C. +1 +1 −1 = +1 > 0 → positif.

---

11. "pelayanannya tidak ramah" diberi label positif oleh leksikon karena…

A. Sarkasme
B. Negasi yang tidak terbaca
C. Slang
D. Duplikat

Jawaban: B. "ramah" +1 dihitung, "tidak" diabaikan.

---

12. Hebat @BrandX, chat CS dibalas setelah tiga hari. Label yang tepat…

A. Positif
B. Netral
C. Negatif (sarkasme)
D. Tidak bisa dilabeli

Jawaban: C. "Hebat" dipakai secara sarkastik; model kontekstual seperti IndoBERT lebih mungkin menangkapnya.

---

13. Langkah IndoBERT yang melatih model lagi dengan posting berlabel disebut…

A. Pre-training
B. Fine-tuning
C. Clustering
D. Embedding

Jawaban: B. Pre-training dengan teks Indonesia umum; fine-tuning dengan posting berlabel sentimen.

---

14. Kesimpulan apa yang didukung hasil sentimen saja?

A. Sebagian besar keluhan soal pengiriman
B. 18 September lebih negatif dari biasanya
C. Penjualan turun 18 September
D. Semua posting negatif dari pelanggan asli

Jawaban: B. Penyebab butuh topik; penjualan butuh data lain; keaslian butuh cek veracity.

---

15. Urutan langkah BERTopic adalah…

A. Cluster → embed → describe → reduce
B. Embed → reduce (UMAP) → cluster (HDBSCAN) → describe (c-TF-IDF)
C. Label → train → predict
D. Collect → label → score

Jawaban: B. Posting yang tidak masuk klaster mana pun menjadi outlier.

---

16. Topic modeling termasuk metode…

A. Supervised: butuh label
B. Unsupervised: topik ditemukan dari data
C. Lexicon-based
D. Network analysis

Jawaban: B. Nama topik baru diberikan analis setelah membaca kata khasnya.

---

17. Dua posting yang paling dekat di ruang makna (embedding)…

A. "barangnya rusak pas dibuka" dan "admin gak bales chat"
B. "barangnya rusak pas dibuka" dan "produknya cacat, beda sama foto"
C. "admin gak bales chat" dan "produknya cacat"
D. Semua sama dekat

Jawaban: B. Maknanya sama (produk rusak) walau kata-katanya berbeda.

---

18. "Dana refund dijanjikan 3 hari kerja, sekarang udah 2 minggu" masuk topik dan sentimen…

A. Promo dan harga, positif
B. Refund, negatif
C. Pengiriman terlambat, netral
D. Outlier, netral

Jawaban: B. Kata khas: refund, dana; keluhan janji yang tidak ditepati.

---

19. Topik mana yang harus ditangani pertama di kasus BrandX?

A. Promo dan harga
B. Pengiriman terlambat: terbesar (37,2%) dan paling negatif (76,7%)
C. Outlier
D. Layanan pelanggan

Jawaban: B. Gabungkan ukuran dan porsi negatif.

---

20. Dalam jaringan retweet, in-degree mengukur…

A. Seberapa sering akun me-retweet orang lain
B. Seberapa sering akun di-retweet atau di-mention
C. Seberapa sering akun jadi jembatan
D. Jumlah komunitas

Jawaban: B. Influencer punya in-degree tertinggi (10).

---

21. Akun News punya betweenness tertinggi (0,68). Artinya…

A. Paling sering di-retweet
B. Jembatan utama: informasi antar komunitas lewat akun ini
C. Paling negatif
D. Akun bot

Jawaban: B. Betweenness = sering berada di jalur terpendek antar akun lain.

---

22. Temuan "edge yang hilang" di jaringan BrandX adalah…

A. BrandX tidak punya pengikut
B. Tidak ada edge langsung antara BrandX dan komunitas pengkritik, jadi balasannya tidak sampai ke mereka
C. News tidak terhubung ke siapa pun
D. Influencer tidak aktif

Jawaban: B. Satu-satunya jalur ke pengkritik lewat News.

Sumber

- P3MD MK6 Week 10 — Business Analytics: Big Data Analytics (kasus BrandX fiktif; SocialX)
- Contoh di slide: Google Flu Trends; Billion Prices Project; Yelp dan inspeksi restoran Boston (2015); PetaBencana.id; IndoBERT; BERTopic